

Lecture 4: Attention Alternatives and Mixture of Experts

Spring 2026 中文精讲笔记

主讲: Tatsunori Hashimoto


From linear attention to Mamba-2

Let's generalize linear attention a little bit and add per-position weights..

$$S_t = S_{t-1} + k_t v_t^T \text{ and } y_t = q_t^T S_t \text{ (Linear attention)}$$
$$S_t = \gamma_t S_{t-1} + k_t v_t^T \text{ and } y_t = q_t^T S_t + v_t^T D \text{ with } \gamma_t = f(x_t) \text{ (Mamba-2)}$$

There is a lot more words to justify this (go read the mamba 2 paper) but the mechanics is that we can make linear attention more expressive via gating (gating is good!)

This continues to have duality properties (compute γ in parallel, apply duality)



频道: Stanford Online

发布日期: 2026-04-15

时长: 1:26:20

视频: https://www.youtube.com/watch?v=cKSwj_qZ8Jg

官方主页: <https://cs336.stanford.edu/>

目录

1 导读：问题、证据与阅读方法	2
2 长上下文为何迫使注意力改变	3
3 线性注意力与递归状态	9
4 混合结构与稀疏注意力	15
5 MoE 的计算语义	21
6 路由函数与专家组织	27
7 离散路由的训练	33
8 MoE 系统实现与稳定性	38
9 DeepSeek 配方与模型升级	43
10 代码化复现：最小机制	48
11 总结与延伸	49
12 资料来源与审计边界	49

1 导读：问题、证据与阅读方法

本讲主问题

怎样在保持语言模型质量的同时，把注意力和前馈网络中最昂贵的稠密计算改写为可扩展的稀疏或递归计算？

本讲把算法、训练目标和系统实现放在同一条因果链上：先改变信息流，再检查可训练性，最后核算设备通信和数值稳定性。本笔记以课程视频、人工字幕和 Stanford 官方讲义或代码为共同证据源。图像均来自每十五秒抽帧后的人工接触表审查，时间脚注可回到原视频复核；公式区分课程机制关系和本笔记的决策分析框架。学习时建议先读主问题，再沿“机制-资源-失败模式-验证指标”四列整理自己的实验。

首先排除的误读

稀疏化并不自动带来端到端加速；路由不均衡、通信放大、容量限制和微调过拟合都可能吞掉理论收益。

1.1 关键数字核对

主张	数值或关系	视频时间
标准注意力核心计算随序列长度增长	二次 $O(n^2 d)$	00:06:45
线性注意力重排后的主要复杂度	约 $O(nd^2)$	00:06:45
Minimax M1 混合比例	7 个线性层配 1 个全注意力层	00:12:00
Qwen 新模型的混合比例	约 3:1 GDN/Attention	00:18:45
MoE 训练曲线示例的速度优势	约 7x speedup	00:38:15
Switch Transformer 激活专家数	1	00:50:00
GShard 与 Mixtral 激活专家数	top-2	00:50:00
DeepSeek-V1 专家配置	64 routed、6 active、2 shared、1/4 细粒度比	00:57:15
Qwen 1.5 专家配置	60 routed、4 active、4 shared、1/8 细粒度比	00:57:15
DeepSeek-V3 专家配置	256 routed、8 active、1 shared、1/14 细粒度比	00:57:15
OLMoE 专家配置	64 routed、8 active、0 shared、1/8 细粒度比	00:57:15
MiniMax 专家配置	32 routed、2 active、约 1/4 细粒度比	00:57:15
路由器稳定性建议	路由计算使用 FP32	01:17:15
DeepSeek 微调数据量示例	约 1.4M SFT 样本	01:18:45
MiniCPM upcycling 配置	top-k=2、8 experts、约 4B active params	01:20:15
MiniCPM upcycling 训练 token	约 520B tokens	01:20:15
Qwen MoE 初始化模型	Qwen 1.8B	01:21:30
Qwen MoE 专家配置	top-k=4、60 experts、4 shared	01:21:30
DeepSeek MoE V1 规模	16B total、2.8B active	01:22:15
DeepSeek MoE V2 规模	236B total、21B active	01:22:45
DeepSeek MoE V3 规模	671B total、37B active	01:23:15

1.2 本章小结

本章建立证据边界：视频解释提供因果和强调，官方材料提供公式与代码，精选帧提供可核查的视觉状态。后文每个主题都同时回答“为何重要、怎样工作、怎样失败、怎样验证”，避免把课程压缩成术语目录。

2 长上下文为何迫使注意力改变

本节路线

本节依次处理：上下文长度增长使标准注意力成本快速上升、局部全局混合与系统优化的基础工具箱、线性注意力利用乘法结合律改变计算顺序、线性注意力的递归状态与训练推理对偶、Mamba-2 在线性状态更新中加入位置门控。它们共享一个资源与信息流边界，因而必须联合

阅读，不能把其中某张图当成独立结论。

$$C_{\text{attn}} = \Theta(T^2 D), \quad M_{\text{attn}} = \Theta(T^2)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_1 = \frac{B_1}{C_1 + \lambda R_1 + \varepsilon}$$

- B_1 是本节方法带来的质量、吞吐或覆盖收益。
- C_1 是新增计算、显存、通信、数据或标注成本。
- R_1 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_1 \leq C_{\max}, \quad R_1 \leq R_{\max}, \quad Q_1 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

2.1 上下文长度增长使标准注意力成本快速上升

核心判断。“上下文长度增长使标准注意力成本快速上升”是“长上下文为何迫使注意力改变”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 1 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“上下文长度增长使标准注意力成本快速上升”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Attention alternatives

Cost of attention rises with large context sizes... how do we control those costs?




图 1: 上下文长度增长使标准注意力成本快速上升¹

2.2 局部全局混合与系统优化的基础工具箱

核心判断。“局部全局混合与系统优化的基础工具箱”是“长上下文为何迫使注意力改变”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 2 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“局部全局混合与系统优化的基础工具箱”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹视频画面时间区间：00:02:00–00:02:15。

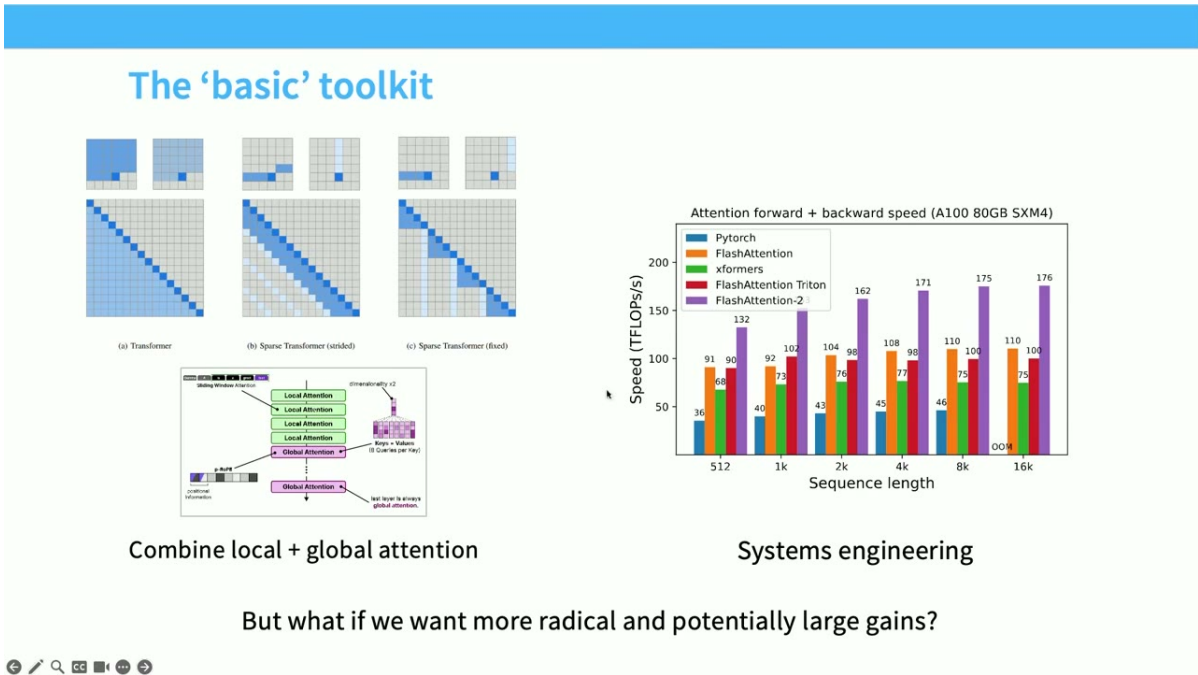


图 2: 局部全局混合与系统优化的基础工具箱²

2.3 线性注意力利用乘法结合律改变计算顺序

核心判断。“线性注意力利用乘法结合律改变计算顺序”是“长上下文为何迫使注意力改变”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 3 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“线性注意力利用乘法结合律改变计算顺序”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²视频画面时间区间：00:04:15–00:04:30。

Linear attention

Consider the usual attention operation.. $Q \in R^{n \times d_k}, K \in R^{n \times d_k}, V \in R^{n \times d_v}$

$$\text{Attn}(Q, K, V) = \rho(QK^T)V$$

This is quadratic due to QK^T ($n^2 d_k$). Can we do better (when ρ is the identity)?

$$(QK^T)V = Q(K^T V)$$

This is very silly, but surprisingly important.. We get from $n^2 d_k + n^2 d_v$ to $2nd_v d_k$

[Shen et al 2018, Katharopoulos 2020 for kernel version. Also connections to things like fast weight programmers]

图 3: 线性注意力利用乘法结合律改变计算顺序³

2.4 线性注意力的递归状态与训练推理对偶

核心判断。“线性注意力的递归状态与训练推理对偶”是“长上下文为何迫使注意力改变”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 4 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“线性注意力的递归状态与训练推理对偶”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

³视频画面时间区间：00:06:45–00:07:00。

Recurrent form of linear attention

Recall that in purely linear attention, we consider the reordering

$$(QK^T)V = Q(K^TV)$$

This is linear time (great) but the even nicer thing is that this looks like a RNN.

$$S_t = S_{t-1} + k_t v_t^T \text{ and } y_t = q_t^T S_t$$

This ‘duality’ allows us to train efficiently (using the parallel, quadratic form) and inference efficiently (using the serial, linear form)

(Note: if one weights S_{t-1} by γ , you get a RetNet)

图 4: 线性注意力的递归状态与训练推理对偶⁴

2.5 Mamba-2 在线性状态更新中加入位置门控

核心判断。“Mamba-2 在线性状态更新中加入位置门控”是“长上下文为何迫使注意力改变”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 5 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Mamba-2 在线性状态更新中加入位置门控”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁴视频画面时间区间：00:09:15–00:09:30。

From linear attention to Mamba-2

Let's generalize linear attention a little bit and add per-position weights..

$$S_t = S_{t-1} + k_t v_t^T \text{ and } y_t = q_t^T S_t \text{ (Linear attention)}$$

$$S_t = \gamma_t S_{t-1} + k_t v_t^T \text{ and } y_t = q_t^T S_t + v_t^T D \text{ with } \gamma_t = f(x_t) \text{ (Mamba-2)}$$

There is a lot more words to justify this (go read the mamba 2 paper) but the mechanics is that we can make linear attention more expressive via gating (gating is good!)

This continues to have duality properties (compute γ in parallel, apply duality)




图 5: Mamba-2 在线性状态更新中加入位置门控⁵

2.6 本章小结

“长上下文为何迫使注意力改变”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。稀疏化并不自动带来端到端加速；路由不均衡、通信放大、容量限制和微调过拟合都可能吞掉理论收益。

3 线性注意力与递归状态

本节路线

本节依次处理：Nemotron 3 的 Mamba 与注意力混合结构、Gated Delta Net 的写入擦除状态更新、Qwen 3.5 与 Qwen Next 的混合注意力方案、混合线性注意力性能与比例证据、稠密短上下文预训练后的稀疏适配。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$\phi(Q)(\phi(K)^T V) \equiv (\phi(Q)\phi(K)^T) V$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。

⁵视频画面时间区间：00:12:00–00:12:15。

- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_2 = \frac{B_2}{C_2 + \lambda R_2 + \varepsilon}$$

- B_2 是本节方法带来的质量、吞吐或覆盖收益。
- C_2 是新增计算、显存、通信、数据或标注成本。
- R_2 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_2 \leq C_{\max}, \quad R_2 \leq R_{\max}, \quad Q_2 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

3.1 Nemotron 3 的 Mamba 与注意力混合结构

核心判断。“Nemotron 3 的 Mamba 与注意力混合结构”是“线性注意力与递归状态”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 6 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“Nemotron 3 的 Mamba 与注意力混合结构”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Nemotron 3




Figure 1 | Nemotron 3 models (e.g., Nemotron Nano 3) leverage a hybrid Mamba-Transformer MoE architecture consisting predominantly of interleaved Mamba-2 and MoE layers, with a select few self attention layers.




Figure 2 | The hybrid Mamba-Transformer MoE architecture used by Nemotron 3 models can achieve state-of-the-art accuracy on leading reasoning benchmarks and ultra-long-context tasks while providing throughput improvements over similarly sized Transformer MoEs. For details, please see the Nemotron Nano 3 technical report.

Mamba attention hybrid (3-1 ish) – comparable (or better) pref to other similar models

图 6: Nemotron 3 的 Mamba 与注意力混合结构⁶

3.2 Gated Delta Net 的写入擦除状态更新

核心判断。“Gated Delta Net 的写入擦除状态更新”是“线性注意力与递归状态”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 7 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Gated Delta Net 的写入擦除状态更新”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁶视频画面时间区间：00:14:00–00:14:15。

Gated delta net (and friends)

Let's generalize things further – gate the input and selectively erase the state.

$$S_t = \gamma_t S_{t-1} + k_t v_t^\top \text{ and } y_t = q_t^\top S_t + v_t^\top D \text{ with } \gamma_t = f(x_t) \text{ (Mamba-2)}$$

$$S_t = \gamma_t (I - \beta_t k_t k_t^\top) S_{t-1} + \beta_t k_t v_t^\top \text{ and } y_t = q_t^\top S_t \text{ with } \gamma_t = f(x_t), \beta_t = f(x_t) \text{ (Gated Delta Net)}$$

The gated delta net adds a 'no input operation' gate ($\beta = 0$)
And erases anything in the direction of the current key ($I - \beta_t k_t k_t^\top$)

Close relationships to various fast weight programming / test time training ideas.

图 7: Gated Delta Net 的写入擦除状态更新⁷

3.3 Qwen 3.5 与 Qwen Next 的混合注意力方案

核心判断。“Qwen 3.5 与 Qwen Next 的混合注意力方案”是“线性注意力与递归状态”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 8 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“Qwen 3.5 与 Qwen Next 的混合注意力方案”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁷视频画面时间区间：00:17:15–00:17:30。

Qwen 3.5 / Qwen Next



The newest qwen are 3-1 GDN / Attention hybrids.
Once again, pretty reasonable performance with good inference characteristics

图 8: Qwen 3.5 与 Qwen Next 的混合注意力方案⁸

3.4 混合线性注意力性能与比例证据

核心判断。“混合线性注意力性能与比例证据”是“线性注意力与递归状态”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 9 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“混合线性注意力性能与比例证据”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁸视频画面时间区间：00:18:45–00:19:00。

Hybrid performance

ByteDance | Seed

UC SANTA CRUZ

A Systematic Analysis of Hybrid Linear Attention

Dustin Wang^{*1}, Rui-Jie Zhu^{*1,2},
Steven Abreu³, Yong Shan³, Taylor Kergan¹, Yuqi Pan^{2,4}, Yuhong Chou³, Zheng Li³,
Ge Zhang^{2,5,†}, Wenhao Huang³, Jason Eshraghian^{1,†}

¹UC Santa Cruz, ²ByteDance Seed, ³University of Groningen, ⁴CASIA, ⁵PolyU, [†]M-A-P





Figure 4. RULER sub-task results based on ratio. RotNet and HGRN model families are omitted as their recall benchmark results were insufficient.

Model	Update rule (S_t)	Read-out (o_t)
Vector-valued hidden state (classical / gated RNNs)		
HGRN[4]	$h_t = \alpha_t \odot h_{t-1} + (1 - \alpha_t) \odot v_t$	$o_t = h_t \odot q_t$
Hawk (RG-LRU)[33]	$h_t = \gamma_t h_{t-1} + \delta_t \odot v_t$	$o_t = h_t \odot q_t$
Matrix-valued state via outer products		
RotNet/Lightning [11, 17]	$S_t = \gamma S_{t-1} + v_t k_t^T$	$o_t = S_t q_t$
GLA[34]	$S_t = S_{t-1} \odot (1 \otimes \gamma_t^T) + v_t k_t^T$	$o_t = S_t q_t$
Mamba-2[35]	$S_t = \gamma_t S_{t-1} + v_t k_t^T$	$o_t = S_t q_t$
RWKV-6[36]	$S_t = S_{t-1} \text{Diag}(\alpha_t) + v_t k_t^T$	$o_t = (S_{t-1} + (d \odot v_t) k_t^T) q_t$
HGRN-2/MetaL[6, 37]	$S_t = S_{t-1} \text{Diag}(\alpha_t) + v_t (1 - \alpha_t)^T$	$o_t = S_t q_t$
Delta-rule / controlled-forgetting family		
DeltaNet[32]	$S_t = S_{t-1} (1 - \beta_t k_t k_t^T) + \beta_t v_t k_t^T$	$o_t = S_t q_t$
Gated DeltaNet[14]	$S_t = \alpha_t S_{t-1} (1 - \beta_t k_t k_t^T) + \beta_t v_t k_t^T$	$o_t = S_t q_t$



Not many controlled ablations, but some evidence of low losses at small hybrid ratios

图 9: 混合线性注意力性能与比例证据⁹

3.5 稠密短上下文预训练后的稀疏适配

核心判断。“稠密短上下文预训练后的稀疏适配”是“线性注意力与递归状态”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 10 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“稠密短上下文预训练后的稀疏适配”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁹视频画面时间区间：00:20:30–00:20:45。

Alternative to hybrids: sparse adaptation

Instead of attending to every token, do sparse attention (DSA)

Prototype of DSA. The prototype of DSA primarily consists of two components: a lightning indexer and a fine-grained token selection mechanism.

The **lightning indexer** computes the index score $I_{i,j}$ between the query token $\mathbf{h}_i \in \mathbb{R}^d$ and a preceding token $\mathbf{h}_j \in \mathbb{R}^d$, determining which tokens to be selected by the query token:

$$I_{i,j} = \sum_{j=1}^{H^I} w_{i,j}^I \cdot \text{ReLU}(\mathbf{q}_{i,j}^I \cdot \mathbf{k}_j^I), \quad (1)$$

where H^I denotes the number of indexer heads; $\mathbf{q}_{i,j}^I \in \mathbb{R}^{d^I}$ and $w_{i,j}^I \in \mathbb{R}$ are derived from the query token $\mathbf{h}_i$; and $\mathbf{k}_j^I \in \mathbb{R}^{d^I}$ is derived from the preceding token $\mathbf{h}_j$. We choose ReLU as the activation function for throughput consideration. Given that the lightning indexer has a small number of heads and can be implemented in FP8, its computational efficiency is remarkable.

Given the index scores $\{I_{i,j}\}$ for each query token $\mathbf{h}_i$, our **fine-grained token selection mechanism** retrieves only the key-value entries $\{c_i\}$ corresponding to the top-k index scores. Then, the attention output $\mathbf{u}_i$ is computed by applying the attention mechanism between the query token $\mathbf{h}_i$ and the sparsely selected key-value entries $\{c_i\}$:

$$\mathbf{u}_i = \text{Attn}(\mathbf{h}_i, \{c_i \mid I_{i,j} \in \text{Top-k}(I_{i,:})\}). \quad (2)$$

The indexer can be very lightweight, giving significant gains
Can be ‘post hoc’ adapted after dense short context pretraining

图 10: 稠密短上下文预训练后的稀疏适配¹⁰

3.6 本章小结

“线性注意力与递归状态”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。稀疏化并不自动带来端到端加速；路由不均衡、通信放大、容量限制和微调过拟合都可能吞掉理论收益。

4 混合结构与稀疏注意力

本节路线

本节依次处理：DeepSeek Sparse Attention 的检索与解码收益、稠密前馈层与稀疏专家层的结构对比、相同计算量下 MoE 训练速度优势、专家在多设备之间的并行映射、早期 DeepSeek MoE 的消融与评测结果。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$S_t = \gamma_t S_{t-1} + k_t^\top v_t, \quad y_t = q_t S_t$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。

¹⁰ 视频画面时间区间：00:23:45–00:24:00。

- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_3 = \frac{B_3}{C_3 + \lambda R_3 + \varepsilon}$$

- B_3 是本节方法带来的质量、吞吐或覆盖收益。
- C_3 是新增计算、显存、通信、数据或标注成本。
- R_3 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_3 \leq C_{\max}, \quad R_3 \leq R_{\max}, \quad Q_3 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

4.1 DeepSeek Sparse Attention 的检索与解码收益

核心判断。“DeepSeek Sparse Attention 的检索与解码收益”是“混合结构与稀疏注意力”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 11 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“DeepSeek Sparse Attention 的检索与解码收益”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 11: DeepSeek Sparse Attention 的检索与解码收益¹¹

4.2 稠密前馈层与稀疏专家层的结构对比

核心判断。“稠密前馈层与稀疏专家层的结构对比”是“混合结构与稀疏注意力”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 12 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“稠密前馈层与稀疏专家层的结构对比”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹¹视频画面时间区间：00:25:45–00:26:00。

What's a MoE?



[Fedus et al 2022]

Replace big feedforward with (many) big feedforward networks and a selector layer

You can increase the # experts without affecting FLOPs



图 12: 稠密前馈层与稀疏专家层的结构对比¹²

4.3 相同计算量下 MoE 训练速度优势

核心判断。“相同计算量下 MoE 训练速度优势”是“混合结构与稀疏注意力”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 13 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“相同计算量下 MoE 训练速度优势”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹²视频画面时间区间：00:36:00–00:36:15。

Why are MoEs getting popular?

Faster to train MoEs




图 13: 相同计算量下 MoE 训练速度优势¹³

4.4 专家在多设备之间的并行映射

核心判断。“专家在多设备之间的并行映射”是“混合结构与稀疏注意力”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 14 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“专家在多设备之间的并行映射”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹³视频画面时间区间：00:38:15–00:38:30。

Why are MoEs getting popular?

Parallelizable to many devices




图 14: 专家在多设备之间的并行映射¹⁴

4.5 早期 DeepSeek MoE 的消融与评测结果

核心判断。“早期 DeepSeek MoE 的消融与评测结果”是“混合结构与稀疏注意力”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 15 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“早期 DeepSeek MoE 的消融与评测结果”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁴视频画面时间区间：00:40:00–00:40:15。

Earlier MoE results from Chinese groups - DeepSeek

There's also some good recent ablation work on MoEs showing they're generally good

Metric	# Shot	Dense	Hash Layer	Switch
# Total Params	N/A	0.2B	2.0B	2.0B
# Activated Params	N/A	0.2B	0.2B	0.2B
FLOPs per 2K Tokens	N/A	2.9T	2.9T	2.9T
# Training Tokens	N/A	100B	100B	100B
Pile (Loss)	N/A	2.060	1.932	1.881
HellaSwag (Acc.)	0-shot	38.8	46.2	49.1
PIQA (Acc.)	0-shot	66.8	68.4	70.5
ARC-easy (Acc.)	0-shot	41.0	45.3	45.9
ARC-challenge (Acc.)	0-shot	26.0	28.2	30.2
RACE-middle (Acc.)	5-shot	38.8	38.8	43.6
RACE-high (Acc.)	5-shot	29.0	30.0	30.9
HumanEval (Pass@1)	0-shot	0.0	1.2	2.4
MBPP (Pass@1)	3-shot	0.2	0.6	0.4
TriviaQA (EM)	5-shot	4.9	6.5	8.9
NaturalQuestions (EM)	5-shot	1.4	1.4	2.5

图 15: 早期 DeepSeek MoE 的消融与评测结果¹⁵

4.6 本章小结

“混合结构与稀疏注意力”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。稀疏化并不自动带来端到端加速；路由不均衡、通信放大、容量限制和微调过拟合都可能吞掉理论收益。

5 MoE 的计算语义

本节路线

本节依次处理：MoE 训练目标与基础设施的稳定性问题、MLP 专家与注意力头专家的布局、token 选专家、专家选 token 与全局分配、Top-k 与哈希路由的常见实现、Top-k 门控得分、选择与专家聚合公式。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$y_t = \sum_{i \in \text{TopK}(g_t)} p_{t,i} E_i(x_t)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。

¹⁵视频画面时间区间：00:44:45–00:45:00。

- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_4 = \frac{B_4}{C_4 + \lambda R_4 + \varepsilon}$$

- B_4 是本节方法带来的质量、吞吐或覆盖收益。
- C_4 是新增计算、显存、通信、数据或标注成本。
- R_4 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_4 \leq C_{\max}, \quad R_4 \leq R_{\max}, \quad Q_4 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

5.1 MoE 训练目标与基础设施的稳定性问题

核心判断。“MoE 训练目标与基础设施的稳定性问题”是“MoE 的计算语义”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 16 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“MoE 训练目标与基础设施的稳定性问题”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。


Why haven't MoEs been more popular?

Infrastructure is complex / advantages on multi node

At a high level, sparsity is good when you have many accelerators (e.g. GPU/TPU) to host all the additional parameters that comes when using sparsity. Typically models are trained using data-parallelism where different machines will get different slices of the training/inference data. The machines used for operating on the different slices of data can now be used to host many more model parameters. Therefore, sparse models are good when training with data parallelism and/or have high throughput while serving: training/serving on many machines which can host all of the parameters.

[Fedus et al 2022]

Training objectives are somewhat heuristic (and sometimes unstable)



[Zoph et al 2022]

图 16: MoE 训练目标与基础设施的稳定性问题¹⁶

5.2 MLP 专家与注意力头专家的布局

核心判断。“MLP 专家与注意力头专家的布局”是“MoE 的计算语义”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 17 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


复现实验记录

围绕“MLP 专家与注意力头专家的布局”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。


¹⁶视频画面时间区间：00:45:45–00:46:00。

What MoEs generally look like

Typical: replace MLP with MoE layer



Less common: MoE for attention heads



[ModuleFormer, JetMoE]

图 17: MLP 专家与注意力头专家的布局¹⁷

5.3 token 选专家、专家选 token 与全局分配

核心判断。“token 选专家、专家选 token 与全局分配”是“MoE 的计算语义”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 18 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


常见失效模式

围绕“token 选专家、专家选 token 与全局分配”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁷视频画面时间区间：00:46:45–00:47:00。

Routing function - overview

Many of the routing algorithms boil down to 'choose top k'



[Fedus et al 2022]

图 18: token 选专家、专家选 token 与全局分配¹⁸

5.4 Top-k 与哈希路由的常见实现

核心判断。“Top-k 与哈希路由的常见实现”是“MoE 的计算语义”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 19 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“Top-k 与哈希路由的常见实现”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁸视频画面时间区间：00:48:30–00:48:45。

Common routing variants in detail




图 19: Top-k 与哈希路由的常见实现¹⁹

5.5 Top-k 门控得分、选择与专家聚合公式

核心判断。“Top-k 门控得分、选择与专家聚合公式”是“MoE 的计算语义”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 20 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Top-k 门控得分、选择与专家聚合公式”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁹视频画面时间区间：00:50:00–00:50:15。

Top-K routing in detail.

Most papers do the old and classic top-k routing. How does this work?

$$\mathbf{h}_t^l = \sum_{i=1}^N \left(\overset{\text{Gating}}{\downarrow} g_{i,t} \text{FFN}_i(\mathbf{u}_t^l) \right) + \mathbf{u}_t^l,$$

$$g_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} \in \text{Topk}(\{s_{j,t} | 1 \leq j \leq N\}, K), \\ 0, & \text{otherwise,} \end{cases}$$

$$s_{i,t} = \text{Softmax}_i(\mathbf{u}_t^{lT} \mathbf{e}_i^l),$$

↑
Gates selected by a logistic regressor

This is the
DeepSeek (V1-2) router
(Grok, Qwen do this too)

Mixtral, DBRX,
DeepSeek v3
softmaxes after the
TopK

[Dai et al 2024]

图 20: Top-k 门控得分、选择与专家聚合公式²⁰

5.6 本章小结

“MoE 的计算语义”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。稀疏化并不自动带来端到端加速；路由不均衡、通信放大、容量限制和微调过拟合都可能吞掉理论收益。

6 路由函数与专家组织

本节路线

本节依次处理：DeepSeek 细粒度专家切分与共享专家、专家数量与共享专家的消融结果、近期 MoE 的路由专家配置表、离散路由训练的三类方案、高斯扰动产生可训练的随机 Top-k 近似。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$p_{t,i} = \frac{\exp g_{t,i}}{\sum_j \exp g_{t,j}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²⁰视频画面时间区间：00:53:45–00:54:00。

$$G_5 = \frac{B_5}{C_5 + \lambda R_5 + \epsilon}$$

- B_5 是本节方法带来的质量、吞吐或覆盖收益。
- C_5 是新增计算、显存、通信、数据或标注成本。
- R_5 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_5 \leq C_{\max}, \quad R_5 \leq R_{\max}, \quad Q_5 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

6.1 DeepSeek 细粒度专家切分与共享专家


核心判断。“DeepSeek 细粒度专家切分与共享专家”是“路由函数与专家组织”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 21 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“DeepSeek 细粒度专家切分与共享专家”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Recent variations from DeepSeek and other Chinese LMs



Smaller, larger number of experts + a few shared experts that are always on.

(Used in DeepSeek / Qwen, originally from DeepSpeed MoE)

图 21: DeepSeek 细粒度专家切分与共享专家²¹

6.2 专家数量与共享专家的消融结果

核心判断。“专家数量与共享专家的消融结果”是“路由函数与专家组织”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 22 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“专家数量与共享专家的消融结果”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²¹视频画面时间区间：00:54:45–00:55:00。

Various ablations from the DeepSeek paper




Figure 3 | Ablation studies for DeepSeekMoE. The performance is normalized by the best performance for clarity in presentation. All compared models have the same number of parameters and activated parameters. We can find that fine-grained expert segmentation and shared expert isolation both contribute to stronger overall performance.

More experts, shared experts all seem to generally help

图 22: 专家数量与共享专家的消融结果²²

6.3 近期 MoE 的路由专家配置表

核心判断。“近期 MoE 的路由专家配置表”是“路由函数与专家组织”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 23 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“近期 MoE 的路由专家配置表”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²²视频画面时间区间：00:56:00–00:56:15。

Expert routing setups for recent MoEs

Model	Routed	Active	Shared	Fine-grained ratio
GShard	2048	2	0	
Switch Transformer	64	1	0	
ST-MOE	64	2	0	
Mixtral	8	2	0	
DBRX	16	4	0	
Grok	8	2	0	
DeepSeek v1	64	6	2	1/4
Qwen 1.5	60	4	4	1/8
DeepSeek v3	256	8	1	1/14
OLMoE	64	8	0	1/8
MiniMax	32	2	0	~1/4
Llama 4 (maverick)	128	1	1	1/2

图 23: 近期 MoE 的路由专家配置表²³

6.4 离散路由训练的三类方案

核心判断。“离散路由训练的三类方案”是“路由函数与专家组织”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 24 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“离散路由训练的三类方案”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²³视频画面时间区间：00:57:15–00:57:30。

How do we train MoEs?

Major challenge: we need sparsity for training-time efficiency...

But sparse gating decisions are not differentiable!

Solutions?

1. Reinforcement learning to optimize gating policies
2. Stochastic perturbations
3. Heuristic 'balancing' losses.

Guess which one people use in practice?

图 24: 离散路由训练三类方案²⁴

6.5 高斯扰动产生可训练的随机 Top-k 近似

核心判断。“高斯扰动产生可训练的随机 Top-k 近似”是“路由函数与专家组织”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 25 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“高斯扰动产生可训练的随机 Top-k 近似”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁴视频画面时间区间：00:59:30–00:59:45。

Stochastic approximations

$$\begin{aligned} G(x) &= \text{Softmax}(\text{KeepTopK}(H(x), k)) \\ H(x)_i &= (x \cdot W_g)_i + \text{StandardNormal}() \cdot \text{Softplus}((x \cdot W_{\text{noise}})_i) \\ \text{KeepTopK}(v, k)_i &= \begin{cases} v_i & \text{if } v_i \text{ is in the top } k \text{ elements of } v. \\ -\infty & \text{otherwise.} \end{cases} \end{aligned}$$

From Shazeer et al 2017 – routing decisions are *stochastic* with gaussian perturbations.

1. This naturally leads to experts that are a bit more robust.
2. The softmax means that the model learns how to rank K experts

图 25: 高斯扰动产生可训练的随机 Top-k 近似²⁵

6.6 本章小结

“路由函数与专家组织”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。稀疏化并不自动带来端到端加速；路由不均衡、通信放大、容量限制和微调过拟合都可能吞掉理论收益。

7 离散路由的训练

本节路线

本节依次处理：Switch Transformer 的启发式负载均衡损失、DeepSeek-V3 按专家偏置实现无辅助损失平衡、MoE 数据模型专家混合并行的切分方式、MegaBlocks 稀疏矩阵乘与通信压缩结构。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L = L_{\text{LM}} + \lambda L_{\text{balance}} + \beta L_z$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²⁵视频画面时间区间：01:01:30–01:01:45。

$$G_6 = \frac{B_6}{C_6 + \lambda R_6 + \varepsilon}$$

- B_6 是本节方法带来的质量、吞吐或覆盖收益。
- C_6 是新增计算、显存、通信、数据或标注成本。
- R_6 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_6 \leq C_{\max}, \quad R_6 \leq R_{\max}, \quad Q_6 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

7.1 Switch Transformer 的启发式负载均衡损失

核心判断。“Switch Transformer 的启发式负载均衡损失”是“离散路由的训练”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 26 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“Switch Transformer 的启发式负载均衡损失”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Heuristic balancing losses

Another key issue – systems efficiency requires that we use experts evenly..

For each Switch layer, this auxiliary loss is added to the total model loss during training. Given N experts indexed by $i = 1$ to N and a batch $\mathcal{B}$ with T tokens, the auxiliary loss is computed as the scaled dot-product between vectors f and P ,

$$\text{loss} = \alpha \cdot N \cdot \sum_{i=1}^N f_i \cdot P_i \quad (4)$$

where f_i is the fraction of tokens dispatched to expert i ,

$$f_i = \frac{1}{T} \sum_{x \in \mathcal{B}} \mathbb{1}\{\arg\max p(x) = i\} \quad (5)$$

and P_i is the fraction of the router probability allocated for expert i ,²

$$P_i = \frac{1}{T} \sum_{x \in \mathcal{B}} p_i(x). \quad (6)$$

From the Switch Transformer [Fedus et al 2022]

The derivative with respect to $p_i(x)$ is $\frac{\alpha N}{T^2} \sum \mathbb{1}_{\arg\max p(x)=i}$,
so more frequent use = stronger downweighting



图 26: Switch Transformer 的启发式负载均衡损失²⁶

7.2 DeepSeek-V3 按专家偏置实现无辅助损失平衡

核心判断。“DeepSeek-V3 按专家偏置实现无辅助损失平衡”是“离散路由的训练”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 27 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“DeepSeek-V3 按专家偏置实现无辅助损失平衡”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁶视频画面时间区间：01:04:45–01:05:00。

DeepSeek v3 variation – per-expert biases

Set up a per-expert bias (making it more likely to get tokens) and use online learning

$$g'_{i,t} = \begin{cases} s_{i,t}, & s_{i,t} + b_i \in \text{Topk}(\{s_{j,t} + b_j | 1 \leq j \leq N_r\}, K_r), \\ 0, & \text{otherwise.} \end{cases}$$

They call this ‘auxiliary loss free balancing’

Complementary Sequence-Wise Auxiliary Loss. Although DeepSeek-V3 mainly relies on the auxiliary-loss-free strategy for load balance, to prevent extreme imbalance within any single sequence, we also employ a complementary sequence-wise balance loss:

$$\mathcal{L}_{\text{Bal}} = \alpha \sum_{i=1}^{N_r} f_i P_i, \quad (17)$$

$$f_i = \frac{N_r}{K_r T} \sum_{t=1}^T \mathbb{1}(s_{i,t} \in \text{Topk}(\{s_{j,t} | 1 \leq j \leq N_r\}, K_r)), \quad (18)$$

$$s'_{i,t} = \frac{s_{i,t}}{\sum_{j=1}^{N_r} s_{j,t}}, \quad (19)$$

$$P_i = \frac{1}{T} \sum_{t=1}^T s'_{i,t}, \quad (20)$$

(but the approach is not fully aux loss free..)

图 27: DeepSeek-V3 按专家偏置实现无辅助损失平衡²⁷

7.3 MoE 数据模型专家混合并行的切分方式

核心判断。“MoE 数据模型专家混合并行的切分方式”是“离散路由的训练”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 28 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“MoE 数据模型专家混合并行的切分方式”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁷视频画面时间区间：01:07:15–01:07:30。

Training MoEs – the systems side

MoEs parallelize nicely – Each FFN can fit in a device

Enables additional kinds of parallelism




图 28: MoE 数据模型专家混合并行的切分方式²⁸

7.4 MegaBlocks 稀疏矩阵乘与通信压缩结构

核心判断。“MegaBlocks 稀疏矩阵乘与通信压缩结构”是“离散路由的训练”中的一个可检验设计选择，而不是只需记忆的产品名。先用张量形状推出程序实例和掩码，再决定分块、向量化和片上复用；基准必须预热、同步并与高精度参考实现逐元素比较。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 29 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


应记住的判断

围绕“MegaBlocks 稀疏矩阵乘与通信压缩结构”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁸视频画面时间区间：01:09:45–01:10:00。

MoE parallelism and architecture modifications

2.2. LatentMoE: Hardware-Aware Expert Design for Improved Accuracy per Byte



New ideas from Nemotron 3 – down-projecting the activations to reduce communication

图 29: MegaBlocks 稀疏矩阵乘与通信压缩结构²⁹

7.5 本章小结

“离散路由的训练”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。稀疏化并不自动带来端到端加速；路由不均衡、通信放大、容量限制和微调过拟合都可能吞掉理论收益。

8 MoE 系统实现与稳定性

本节路线

本节依次处理：容量限制导致批次级 token 丢弃随机性、路由器数值稳定性与 FP32 加 z-loss、小规模微调时稀疏专家过拟合风险、从稠密预训练模型初始化 MoE 的 upcycling。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$b_i \leftarrow b_i + \eta(\bar{f} - f_i)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²⁹视频画面时间区间：01:14:00–01:14:15。

$$G_7 = \frac{B_7}{C_7 + \lambda R_7 + \epsilon}$$

- B_7 是本节方法带来的质量、吞吐或覆盖收益。
- C_7 是新增计算、显存、通信、数据或标注成本。
- R_7 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_7 \leq C_{\max}, \quad R_7 \leq R_{\max}, \quad Q_7 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

8.1 容量限制导致批次级 token 丢弃随机性

核心判断。“容量限制导致批次级 token 丢弃随机性”是“MoE 系统实现与稳定性”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 30 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


应记住的判断

围绕“容量限制导致批次级 token 丢弃随机性”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Fun side issue – stochasticity of MoE models

MoEs can have additional stochasticity beyond normal models..

Why would a MoE have additional randomness?



Token dropping from routing happens at a *batch* level – this means that other people’s queries can drop your token!

图 30: 容量限制导致批次级 token 丢弃随机性³⁰

8.2 路由器数值稳定性与 FP32 加 z-loss

核心判断。“路由器数值稳定性与 FP32 加 z-loss” 是 “MoE 系统实现与稳定性” 中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 31 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕 “路由器数值稳定性与 FP32 加 z-loss”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

³⁰视频画面时间区间：01:15:45–01:16:00。

Issues with MoEs - stability



⁷Exponential functions have the property that a small input perturbation can lead to a large difference in the output. As an example, consider inputting 10 logits to a softmax function with values of 128 and one logit with a value 128.5. A roundoff error of 0.5 in `bfloat16` will alter the softmax output by 36% and incorrectly make all logits equal. The calculation goes from $\frac{\exp(0)}{\exp(0)+10\exp(-0.5)} \approx 0.142$ to $\frac{\exp(0)}{\exp(0)+10\exp(0)} \approx 0.091$. This occurs because the max is subtracted from all logits (for numerical stability) in softmax operations and the roundoff error changes the number from 128.5 to 128. This example was in `bfloat16`, but analogous situations occur in `float32` with larger logit values.

[Zoph 2022]

Solution: Use Float 32 just for the expert router (sometimes with an aux z-loss)

$$L_z(x) = \frac{1}{B} \sum_{i=1}^B \left(\log \sum_{j=1}^N e^{x_j^{(i)}} \right)^2 \quad (5)$$

图 31: 路由器数值稳定性与 FP32 加 z-loss³¹

8.3 小规模微调时稀疏专家过拟合风险

核心判断。“小规模微调时稀疏专家过拟合风险”是“MoE 系统实现与稳定性”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 32 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


常见失效模式

围绕“小规模微调时稀疏专家过拟合风险”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。


³¹视频画面时间区间：01:17:15–01:17:30。

Issues with MoEs – fine-tuning

Sparse MoEs can overfit on smaller fine-tuning data



Zoph et al solution – finetune non-MoE MLPs



DeepSeek solution – use lots of data 1.4M SFT

Training Data. For training the chat model, we conduct supervised fine-tuning (SFT) on our in-house curated data, comprising 1.4M training examples. This dataset spans a broad range of categories including math, code, writing, question answering, reasoning, summarization, and more. The majority of our SFT training data is in English and Chinese, rendering the chat model versatile and applicable in bilingual scenarios.

图 32: 小规模微调时稀疏专家过拟合风险³²

8.4 从稠密预训练模型初始化 MoE 的 upcycling

核心判断。“从稠密预训练模型初始化 MoE 的 upcycling”是“MoE 系统实现与稳定性”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 33 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“从稠密预训练模型初始化 MoE 的 upcycling”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

³²视频画面时间区间：01:18:45–01:19:00。

Other training methods - upcycling



Can we use a pre-trained LM to initialize a MoE?

图 33: 从稠密预训练模型初始化 MoE 的 upcycling³³

8.5 本章小结

“MoE 系统实现与稳定性”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。稀疏化并不自动带来端到端加速；路由不均衡、通信放大、容量限制和微调过拟合都可能吞掉理论收益。

9 DeepSeek 配方与模型升级

本节路线

本节依次处理：DeepSeek MoE V3 的专家规模与无辅助损失路由、MLA 用潜在表示压缩键值缓存、多 token 预测头与辅助训练目标、稀疏模型离散路由与成本效率总结。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$M_{KV} \propto BTLKH$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

³³ 视频画面时间区间：01:20:15–01:20:30。

$$G_8 = \frac{B_8}{C_8 + \lambda R_8 + \epsilon}$$

- B_8 是本节方法带来的质量、吞吐或覆盖收益。
- C_8 是新增计算、显存、通信、数据或标注成本。
- R_8 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_8 \leq C_{\max}, \quad R_8 \leq R_{\max}, \quad Q_8 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

9.1 DeepSeek MoE V3 的专家规模与无辅助损失路由

核心判断。“DeepSeek MoE V3 的专家规模与无辅助损失路由”是“DeepSeek 配方与模型升级”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 34 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“DeepSeek MoE V3 的专家规模与无辅助损失路由”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

DeepSeek MoE v3

V2 (671B – 37 active):




图 34: DeepSeek MoE V3 的专家规模与无辅助损失路由³⁴

9.2 MLA 用潜在表示压缩键值缓存

核心判断。“MLA 用潜在表示压缩键值缓存”是“DeepSeek 配方与模型升级”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 35 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


复现实验记录

围绕“MLA 用潜在表示压缩键值缓存”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

³⁴视频画面时间区间：01:23:15–01:23:30。

Bonus: What else do you need to make DeepSeek MoE v3?

MLA: Multihead, latent attention



Basic idea: express the Q, K, V as functions of a lower-dim, ‘latent’ activation

图 35: MLA 用潜在表示压缩键值缓存³⁵

9.3 多 token 预测头与辅助训练目标

核心判断。“多 token 预测头与辅助训练目标”是“DeepSeek 配方与模型升级”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 36 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


常见失效模式

围绕“多 token 预测头与辅助训练目标”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

³⁵视频画面时间区间：01:24:15–01:24:30。

What else do you need to make DeepSeek MoE v3?

MTP: Have small, lightweight models that predict multiple steps ahead



$$\mathbf{h}_i^k = M_k[\text{RMSNorm}(\mathbf{h}_i^{k-1}); \text{RMSNorm}(\text{Emb}(t_{i+k}))],$$

$$\mathbf{h}_{1:T-k}^k = \text{TRM}_k(\mathbf{h}_{1:T-k}^k),$$

$$p_{i+k+1}^k = \text{OutHead}(\mathbf{h}_i^k).$$

(See paper for ablations)

图 36: 多 token 预测头与辅助训练目标³⁶

9.4 稀疏模型离散路由与成本效率总结

核心判断。“稀疏模型离散路由与成本效率总结”是“DeepSeek 配方与模型升级”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 37 个图像证据在本讲 37 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“稀疏模型离散路由与成本效率总结”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

³⁶视频画面时间区间：01:25:00–01:25:15。

MoE summary

- ❖ MoEs take advantage of sparsity – not all inputs need the full model
- ❖ Discrete routing is hard, but top-k heuristics seem to work
- ❖ Lots of empirical evidence now that MoEs work, and are cost-effective

图 37: 稀疏模型离散路由与成本效率总结³⁷

9.5 本章小结

“DeepSeek 配方与模型升级”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。稀疏化并不自动带来端到端加速；路由不均衡、通信放大、容量限制和微调过拟合都可能吞掉理论收益。

10 代码化复现：最小机制

下面的片段保留本讲最核心的程序结构，用于把公式和系统过程落到可执行对象。它不是生产实现；实际复现还需补充张量形状断言、数值精度、同步、随机种子、数据版本和端到端测试。

Listing 1: Lecture 4 机制伪代码

```
1 def topk_moe(x, router, experts, k=2):
2     logits = router(x).float()
3     prob = logits.softmax(-1)
4     weight, expert_id = prob.topk(k, dim=-1)
5     return dispatch_and_combine(x, experts, expert_id, weight)
```

复现检查单

先写正确性基线，再记录资源基线；每次只改变一个机制；同时保存直接中间量和最终指标；对随机算法报告多次运行；对数据与评测保存不可变版本标识。

³⁷视频画面时间区间：01:25:45–01:26:00。

10.1 本章小结

代码的价值在于暴露状态、顺序和边界。若一个概念无法写成输入、变换、状态、输出和断言，它通常还没有被真正理解。

11 总结与延伸

一页压缩

本讲的主问题是：怎样在保持语言模型质量的同时，把注意力和前馈网络中最昂贵的稠密计算改写为可扩展的稀疏或递归计算？统一答案是：本讲把算法、训练目标和系统实现放在同一条因果链上：先改变信息流，再检查可训练性，最后核算设备通信和数值稳定性。

第一，优先理解机制而不是产品名。模型、硬件、数据和评测不断更新，但张量形状、状态位置、目标函数、通信边界和测量误差仍然是稳定的分析对象。第二，所有优化都要写出代价守恒：减少某一种成本通常会增加另一种成本或风险。第三，把小规模实验推广到大规模之前，必须检查瓶颈是否改变、数据分布是否改变、实现常数是否仍在同一数量级。第四，最可靠的课程笔记应允许读者沿时间轴注回到原视频，并沿官方材料找到公式或代码出处。

开放问题

稀疏化并不自动带来端到端加速；路由不均衡、通信放大、容量限制和微调过拟合都可能吞掉理论收益。后续实验应把这一风险写成可观测量和停止条件，而不是留在讨论部分。

11.1 本章小结

完成本讲后，读者应能用统一语言解释每个主题的输入、状态、变换、输出、资源成本和失败模式，并据此设计一个含基线、消融、误差条和证据记录的最小实验。

12 资料来源与审计边界

- 课程主页：<https://cs336.stanford.edu/>。
- 视频：https://www.youtube.com/watch?v=cKSwj_qZ8Jg。
- Stanford 官方材料：lecture_04.pdf；客座讲座若无官方文件则以视频和字幕为主。
- 本地证据：audio.srt、figure_manifest.tsv、figure_verification.txt、teaching_atoms.tsv、numerical_claims.tsv。

12.1 本章小结

本笔记覆盖播放列表中的本讲内容与课程主页当日可取得的官方材料。没有官方讲义的客座讲座不会被伪装成有讲义；讲者口头推测、本笔记分析框架和官方公式在文字中分别标明。