

Stanford CS336: Language Modeling from Scratch

Lecture 8: Parallelism 2

Spring 2026 中文精讲笔记

主讲: Tatsunori Hashimoto



频道: Stanford Online

发布日期: 2026-04-28

时长: 1:20:10

视频: <https://www.youtube.com/watch?v=6-cXp-a0mdg>

官方主页: <https://cs336.stanford.edu/>

目录

1 导读：问题、证据与阅读方法	2
2 并行原语与网络层级	2
3 数据并行的状态成本	6
4 ZeRO 与 FSDP	10
5 通信计算重叠	14
6 流水线和零气泡调度	18
7 张量与序列并行	22
8 专家并行	26
9 四维组合与重计算	30
10 代码化复现：最小机制	34
11 总结与延伸	35
12 资料来源与审计边界	35

1 导读：问题、证据与阅读方法

本讲主问题

怎样把 ZeRO/FSDP、流水线、张量、序列和专家并行组合为能训练超大稠密或 MoE 模型的方案？

第二讲并行 ism 把参数状态、激活状态和 token 路由分别放进设备网格，重点是组合后的通信是否落在正确的高速链路上。本笔记以课程视频、人工字幕和 Stanford 官方讲义或代码为共同证据源。图像均来自每十五秒抽帧后的人工接触表审查，时间脚注可回到原视频复核；公式区分课程机制关系和本笔记的决策分析框架。学习时建议先读主问题，再沿“机制-资源-失败模式-验证指标”四列整理自己的实验。

首先排除的误解

维度越多并不越好；过细切分会增加集合通信和调度复杂度，错误的设备映射还会把节点内通信推到低速网络。

1.1 关键数字核对

主张	数值或关系	视频时间
混合精度 Adam 数据并行状态	约 16 bytes/parameter	00:14:00
ZeRO 阶段	1/2/3	00:19:00
Mixtral 专家配置	$8 \times 22B$	01:18:00
组合并行维度	$DP \times TP \times PP \times EP$	01:08:00

1.2 本章小结

本章建立证据边界：视频解释提供因果和强调，官方材料提供公式与代码，精选帧提供可核查的视觉状态。后文每个主题都同时回答“为何重要、怎样工作、怎样失败、怎样验证”，避免把课程压缩成术语目录。

2 并行原语与网络层级

本节路线

本节依次处理：集合通信原语与分布式训练回顾、TPU 与 GPU 集群互连拓扑、TPU v8 机架与切片级网络结构。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$M_{DP} \approx 16N \text{ bytes}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。

- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_1 = \frac{B_1}{C_1 + \lambda R_1 + \varepsilon}$$

- B_1 是本节方法带来的质量、吞吐或覆盖收益。
- C_1 是新增计算、显存、通信、数据或标注成本。
- R_1 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_1 \leq C_{\max}, \quad R_1 \leq R_{\max}, \quad Q_1 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

2.1 集合通信原语与分布式训练回顾

核心判断。“集合通信原语与分布式训练回顾”是“并行原语与网络层级”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 1 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断


围绕“集合通信原语与分布式训练回顾”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

But first.. Some basics about collective communication


All reduce




Broadcast



Reduce



All Gather



Reduce Scatter




图 1: 集合通信原语与分布式训练回顾¹

2.2 TPU 与 GPU 集群互连拓扑

核心判断。“TPU 与 GPU 集群互连拓扑”是“并行原语与网络层级”中的一个可检验设计选择，而不是只需记忆的产品名。把算子映射到线程或矩阵单元，并明确数据位于寄存器、片上 SRAM 还是 HBM；瓶颈判断依赖算术强度，而不是只比较峰值 FLOP/s。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 2 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


复现实验记录

围绕“TPU 与 GPU 集群互连拓扑”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹视频画面时间区间：00:02:45–00:03:00。

TPUs vs GPUs – design differences at the comm level

TPU networking
toroidal mesh



GPU networking
All-to-all (up to 256)




图 2: TPU 与 GPU 集群互连拓扑²

2.3 TPU v8 机架与切片级网络结构

核心判断。“TPU v8 机架与切片级网络结构”是“并行原语与网络层级”中的一个可检验设计选择，而不是只需记忆的产品名。把算子映射到线程或矩阵单元，并明确数据位于寄存器、片上 SRAM 还是 HBM；瓶颈判断依赖算术强度，而不是只比较峰值 FLOP/s。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 3 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“TPU v8 机架与切片级网络结构”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²视频画面时间区间：00:05:30–00:05:45。

But then things change.. TPU8i/t



TPU8i networking – closer to tree-style topologies (maybe for MoEs?)

TPU8t scale-out networking – ‘Virgo’ with switched networks

图 3: TPU v8 机架与切片级网络结构³

2.4 本章小结

“并行原语与网络层级”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。维度越多并不越好；过细切分会增加集合通信和调度复杂度，错误的设备映射还会把节点内通信推到低速网络。

3 数据并行的状态成本

本节路线

本节依次处理：数据张量流水线专家并行基本原语、数据并行每参数十六字节状态成本、ZeRO分阶段切分优化器梯度和参数。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$M_{\text{ZeRO3}} \approx \frac{16N}{p}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

³视频画面时间区间：00:08:15–00:08:30。

$$G_2 = \frac{B_2}{C_2 + \lambda R_2 + \epsilon}$$

- B_2 是本节方法带来的质量、吞吐或覆盖收益。
- C_2 是新增计算、显存、通信、数据或标注成本。
- R_2 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_2 \leq C_{\max}, \quad R_2 \leq R_{\max}, \quad Q_2 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

3.1 数据张量流水线专家并行基本原语

核心判断。“数据张量流水线专家并行基本原语”是“数据并行的状态成本”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 4 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“数据张量流水线专家并行基本原语”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Part 2 – Standard LLM parallelization primitives

How do we parallelize LLMs? 3 important ideas

- **Data parallelism**
 - Naïve data parallel
 - ZeRO levels 1-3
- **Model parallelism**
 - Pipeline parallel
 - Tensor parallel
- **Activation parallelism**
 - Sequence parallel

图 4: 数据张量流水线专家并行基本原语⁴

3.2 数据并行每参数十六字节状态成本

核心判断。“数据并行每参数十六字节状态成本”是“数据并行的状态成本”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 5 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“数据并行每参数十六字节状态成本”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁴视频画面时间区间：00:11:00–00:11:15。

What's wrong with naïve data parallelism? - Memory

Our memory situation is actually terrible.

Depending on our precision..

We need 5 copies of weights and 16 bytes per param!

- 2 bytes for FP/BF 16 model parameters
- 2 bytes for FP/BF 16 gradients
- 4 bytes for FP32 master weights (the thing you accumulate into in SGD)
- 4 (or 2) bytes for FP32/BF16 Adam first moment estimates
- 4 (or 2) bytes for FP32/BF16 Adam second moment estimates

“Optimizer state”

图 5: 数据并行每参数十六字节状态成本⁵

3.3 ZeRO 分阶段切分优化器梯度和参数

核心判断。“ZeRO 分阶段切分优化器梯度和参数”是“数据并行的状态成本”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 6 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“ZeRO 分阶段切分优化器梯度和参数”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁵视频画面时间区间：00:13:45–00:14:00。

ZeRO – solving the memory overhead issue of DP

Core idea: split up the expensive parts (state) and use the reduce-scatter equivalence.




图 6: ZeRO 分阶段切分优化器梯度和参数⁶

3.4 本章小结

“数据并行的状态成本”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。维度越多并不越好；过细切分会增加集合通信和调度复杂度，错误的设备映射还会把节点内通信推到低速网络。

4 ZeRO 与 FSDP

本节路线

本节依次处理：ZeRO-2 的优化器与梯度分片、FSDP 按需 all-gather 参数并 reduce-scatter 梯度、通信与前向反向计算重叠。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$T_{\text{step}} = \max(T_{\text{compute}}, T_{\text{comm}}) + T_{\text{unhidden}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁶视频画面时间区间：00:16:30–00:16:45。

$$G_3 = \frac{B_3}{C_3 + \lambda R_3 + \epsilon}$$

- B_3 是本节方法带来的质量、吞吐或覆盖收益。
- C_3 是新增计算、显存、通信、数据或标注成本。
- R_3 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_3 \leq C_{\max}, \quad R_3 \leq R_{\max}, \quad Q_3 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

4.1 ZeRO-2 的优化器与梯度分片

核心判断。“ZeRO-2 的优化器与梯度分片”是“ZeRO 与 FSDP”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 7 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“ZeRO-2 的优化器与梯度分片”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

ZeRO stage 2. the simple extension to gradient sharding



Emboldened by our success, let's shard even more stuff

High level idea

- Also keep the gradients (pink slices) sharded across the machines.
- Use the same (rough) tricks as stage 1.

Complexity – we can never instantiate a full gradient vector, but each worker must compute a full gradient (since we're data parallel)

图 7: ZeRO-2 的优化器与梯度分片⁷

4.2 FSDP 按需 all-gather 参数并 reduce-scatter 梯度

核心判断。“FSDP 按需 all-gather 参数并 reduce-scatter 梯度”是“ZeRO 与 FSDP”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 8 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“FSDP 按需 all-gather 参数并 reduce-scatter 梯度”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁷视频画面时间区间：00:19:15–00:19:30。

ZeRO stage 3 (aka FSDP) how it works (baby version)



Communication cost – 2 all gather (#param), 1 reduce-scatter (#param).

https://pytorch.org/tutorials/intermediate/FSDP_tutorial.html

图 8: FSDP 按需 all-gather 参数并 reduce-scatter 梯度⁸

4.3 通信与前向反向计算重叠

核心判断。“通信与前向反向计算重叠”是“ZeRO 与 FSDP”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 9 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“通信与前向反向计算重叠”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁸视频画面时间区间：00:22:00–00:22:15。

Actual picture of how FSDP / ZeRO stage 3 works

Let's walk through a FSDP example to see some important ideas

Incremental computation / communication

- Parameters / gradients are requested / sent and then immediately freed

Overlapping communication and computation ($W_1 W_0 + W_2 W_0$) $x = y$

- The all-gathers happen all at once while forward happens, masking the comm cost.




图 9: 通信与前向反向计算重叠⁹

4.4 本章小结

“ZeRO 与 FSDP” 的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。维度越多并不越好；过细切分会增加集合通信和调度复杂度，错误的设备映射还会把节点内通信推到低速网络。

5 通信计算重叠

本节路线

本节依次处理：纯数据并行受模型副本显存限制、流水线并行按层切分模型、microbatch 数和阶段数决定流水线效率。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$\eta_{\text{pipe}} = \frac{m}{m + p - 1}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁹视频画面时间区间：00:24:45–00:25:00。

$$G_4 = \frac{B_4}{C_4 + \lambda R_4 + \epsilon}$$

- B_4 是本节方法带来的质量、吞吐或覆盖收益。
- C_4 是新增计算、显存、通信、数据或标注成本。
- R_4 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_4 \leq C_{\max}, \quad R_4 \leq R_{\max}, \quad Q_4 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

5.1 纯数据并行受模型副本显存限制

核心判断。“纯数据并行受模型副本显存限制”是“通信计算重叠”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 10 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


应记住的判断

围绕“纯数据并行受模型副本显存限制”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Issues remain with data parallel – models don't fit

Zero stages 1 and 2 don't let you scale memory

Zero stage 3 is nice in principle, but *does not reduce activation memory*



Better ways to split up the model is needed...

图 10: 纯数据并行受模型副本显存限制¹⁰

5.2 流水线并行按层切分模型

核心判断。“流水线并行按层切分模型”是“通信计算重叠”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 11 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“流水线并行按层切分模型”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁰视频画面时间区间：00:30:15–00:30:30。

A solution: pipeline parallel



Solution: Pipeline-parallel.

Process 'micro-batches' (in this case, 4).
Send off the first microbatch and start computing the second.

The ratio of bubble time to useful compute is .. $\frac{n_{stages}-1}{n_{micro}}$ so we need a big batch size!

图 11: 流水线并行按层切分模型¹¹

5.3 microbatch 数和阶段数决定流水线效率

核心判断。“microbatch 数和阶段数决定流水线效率”是“通信计算重叠”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 12 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“microbatch 数和阶段数决定流水线效率”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹¹视频画面时间区间：00:33:00–00:33:15。

Pipeline performance is highly dependent on batch size



Batch sizes are key to hiding the bubble – otherwise pipeline rapidly degrades perf

图 12: microbatch 数和阶段数决定流水线效率¹²

5.4 本章小结

“通信计算重叠”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。维度越多并不越好；过细切分会增加集合通信和调度复杂度，错误的设备映射还会把节点内通信推到低速网络。

6 流水线和零气泡调度

本节路线

本节依次处理：零气泡调度重新排列前向与反向任务、张量并行切分矩阵乘输入输出维度、张量并行的通信频率与内存收益。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$M_{\text{act}} \propto BTLD$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹²视频画面时间区间：00:35:45–00:36:00。

$$G_5 = \frac{B_5}{C_5 + \lambda R_5 + \epsilon}$$

- B_5 是本节方法带来的质量、吞吐或覆盖收益。
- C_5 是新增计算、显存、通信、数据或标注成本。
- R_5 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_5 \leq C_{\max}, \quad R_5 \leq R_{\max}, \quad Q_5 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

6.1 零气泡调度重新排列前向与反向任务

核心判断。“零气泡调度重新排列前向与反向任务”是“流水线 and 零气泡调度”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 13 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“零气泡调度重新排列前向与反向任务”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

‘Zero bubble’ pipelining

Split up backwards into two parts

1. Backpropagating activations (z,x)
2. Computing weight gradients (W)

The second part can be done whenever




Figure 1: Computation Graph for MLP.




Figure 2: 1F1B pipeline schedule.




Figure 3: Handcrafted pipeline schedules, top: ZB-H1; bottom: ZB-H2

图 13: 零气泡调度重新排列前向与反向任务¹³

6.2 张量并行切分矩阵乘输入输出维度

核心判断。“张量并行切分矩阵乘输入输出维度”是“流水线和零气泡调度”中的一个可检验设计选择，而不是只需记忆的产品名。先用张量形状推出程序实例和掩码，再决定分块、向量化和片上复用；基准必须预热、同步并与高精度参考实现逐元素比较。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 14 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“张量并行切分矩阵乘输入输出维度”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹³视频画面时间区间：00:38:30–00:38:45。

Row vs Column tensor parallel



How do we split up in tensor parallel across a transformer block?

- Columnwise – QKV, up-projection
- Rowwise – Attention output, down-projection
- Replicated – norms, routers, etc

图 14: 张量并行切分矩阵乘输入输出维度¹⁴

6.3 张量并行的通信频率与内存收益

核心判断。“张量并行的通信频率与内存收益”是“流水线和零气泡调度”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 15 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“张量并行的通信频率与内存收益”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁴视频画面时间区间：00:41:30–00:41:45。

Tensor parallel – pros and cons vs pipeline parallel

How do things compare to pipeline parallel?

Pros – no bubble. If your network is fast enough, there's no waiting for others.
– low complexity – simple to 'wrap' models without major infra changes
– doesn't need large batch sizes to work well

Cons – *much* larger communication than pipeline parallel.
• Pipeline: bsh point-to-point communication per microbatch
• Tensor: $8bsh \left(\frac{n_{devices}-1}{n_{devices}} \right)$ per layer and all-reduce communication.

Use tensor parallel whenever we have low-latency, high-bandwidth interconnects

图 15: 张量并行的通信频率与内存收益¹⁵

6.4 本章小结

“流水线和零气泡调度”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。维度越多并不越好；过细切分会增加集合通信和调度复杂度，错误的设备映射还会把节点内通信推到低速网络。

7 张量与序列并行

本节路线

本节依次处理：激活显存公式与序列长度依赖、序列并行进一步切分归一化和 dropout 激活、专家并行把不同专家放到不同设备。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$Y = \sum_{r=1}^p X_r W_r$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁵视频画面时间区间：00:44:15–00:44:30。

$$G_6 = \frac{B_6}{C_6 + \lambda R_6 + \varepsilon}$$

- B_6 是本节方法带来的质量、吞吐或覆盖收益。
- C_6 是新增计算、显存、通信、数据或标注成本。
- R_6 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_6 \leq C_{\max}, \quad R_6 \leq R_{\max}, \quad Q_6 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

7.1 激活显存公式与序列长度依赖

核心判断。“激活显存公式与序列长度依赖”是“张量与序列并行”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 16 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“激活显存公式与序列长度依赖”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

What's the activation memory per layer?

Starting point: activation memory needed if storing everything

$$\text{Activations memory per layer} = sbh \left(34 + 5 \frac{as}{h} \right).$$

- The $5 \frac{as}{h}$ terms come from the quadratic attention terms incl dropout
- As with flash attention, we can drop this term via recomputation

a	number of attention heads	p	pipeline parallel size
b	microbatch size	s	sequence length
h	hidden dimension size	t	tensor parallel size
L	number of transformer layers	v	vocabulary size

图 16: 激活显存公式与序列长度依赖¹⁶

7.2 序列并行进一步切分归一化和 dropout 激活

核心判断。“序列并行进一步切分归一化和 dropout 激活”是“张量与序列并行”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 17 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“序列并行进一步切分归一化和 dropout 激活”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁶视频画面时间区间：00:47:00–00:47:15。

Making memory truly linear – sequence parallel



- Observation:** all the 10sbh terms are pointwise ops over the sequence
 ... so split up the layer norm/dropout layers along the sequence axis.
- In the forward pass, ' g ' is an all gather, ' $\bar{g}$ ' is reduce-scatter
 - In the backward pass, the two are reversed.

图 17: 序列并行进一步切分归一化和 dropout 激活¹⁷

7.3 专家并行把不同专家放到不同设备

核心判断。“专家并行把不同专家放到不同设备”是“张量与序列并行”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 18 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“专家并行把不同专家放到不同设备”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁷视频画面时间区间：00:49:45–00:50:00。

Why EP?

EP is *roughly* like TP in behavior for MLPs – high bandwidth, reduces activation

Guideline 4: Prefer EP over TP for Expert Layers	
EP Advantages	Details
Better GEMM efficiency	Larger local matrix sizes improve GPU utilization
Lower communication	EP has less communication overhead than TP for MoE layers
Simpler computation graph	Easier to overlap communication with computation
Token permutation	When $EP = \text{num_experts}$, local token permutation is eliminated
Example: For Mixtral 8x7B, $EP8 \times TP1$ outperforms $EP4 \times TP2$.	

But, splitting matmuls can reduce efficiency vs routing activations

图 18: 专家并行把不同专家放到不同设备¹⁸

7.4 本章小结

“张量与序列并行”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。维度越多并不越好；过细切分会增加集合通信和调度复杂度，错误的设备映射还会把节点内通信推到低速网络。

8 专家并行

本节路线

本节依次处理：专家并行与数据并行的组合、注意力并行与专家并行解耦、数据张量流水线专家四维并行。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$y_t = \sum_{i \in \text{TopK}} p_i E_i(x_t)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁸视频画面时间区间：00:55:15–00:55:30。

$$G_7 = \frac{B_7}{C_7 + \lambda R_7 + \epsilon}$$

- B_7 是本节方法带来的质量、吞吐或覆盖收益。
- C_7 是新增计算、显存、通信、数据或标注成本。
- R_7 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_7 \leq C_{\max}, \quad R_7 \leq R_{\max}, \quad Q_7 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

8.1 专家并行与数据并行的组合

核心判断。“专家并行与数据并行的组合”是“专家并行”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 19 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“专家并行与数据并行的组合”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Complexity – combining EP and others

Naively – we can compose EP and all other strategies..

But there are important notes – DP usually shares replicas with EP splits (so EP<DP)

DP and TP can interact badly to lower utilization




Fig. 8. Schematic depiction of diverse parallel strategies for MoE. For clarity and conciseness, this illustration omits some All-to-All, All-Reduce, Point-to-Point communication within parallelism, and Normalization, Encode, Decode, Gate in subfigures (b), (c), and (d).

图 19: 专家并行与数据并行的组合¹⁹

8.2 注意力并行与专家并行解耦

核心判断。“注意力并行与专家并行解耦”是“专家并行”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 20 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“注意力并行与专家并行解耦”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁹视频画面时间区间：00:58:00–00:58:15。

Complexity: Decoupling attention / expert parallelism

Recall: MoEs apply to the MLPs, not the attention (with some exotic exceptions)

This can lead to some imbalance between attention and MLPs for parallelism

- High TP – useful for attention parallelization (since we can't use EP)
- Low TP – useful for MLP parallelization (we'd rather EP than TP)

What to do? More flexible parallelism strategies (i.e. in Megatron)

MoE Parallel Folding is Megatron Core's solution that decouples attention and MoE parallelism:

Parallelism Group	Attention Layers	MoE Layers
Dimensions	$TP \times CP \times DP \times PP$	$ETP \times EP \times EDP \times PP$

Separates out TP/CP/DP (for attention) and (ETP/EP/EDP) for MLPs

<https://docs.nvidia.com/megatron-core/developer-guide/latest/user-guide/features/moe.html>

图 20: 注意力并行与专家并行解耦²⁰

8.3 数据张量流水线专家四维并行

核心判断。“数据张量流水线专家四维并行”是“专家并行”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 21 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“数据张量流水线专家四维并行”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁰视频画面时间区间：01:00:45–01:01:00。

‘3D (4D) parallelism’ – putting it all together

Simple rules of thumb from the literature.

1. Until your model fits in memory..
 - Tensor / expert parallel up to GPUs / machine
 - Pipeline parallel across machines
 - › (Or use Zero-3, depending on BW)

2. Then until you run out of GPUs
 - Scale the rest of the way with data parallel

If your batch size is small.. gradient accumulate to trade higher batch sizes for better communication efficiency.




图 21: 数据张量流水线专家四维并行²¹

8.4 本章小结

“专家并行”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。维度越多并不越好；过细切分会增加集合通信和调度复杂度，错误的设备映射还会把节点内通信推到低速网络。

9 四维组合与重计算

本节路线

本节依次处理：选择性重计算降低激活峰值、Yi 模型训练采用的并行配置、Mixtral 八乘二十二 B 的并行配置。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$P_{\text{world}} = P_{\text{DP}} P_{\text{TP}} P_{\text{PP}} P_{\text{EP}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²¹视频画面时间区间：01:06:15–01:06:30。

$$G_8 = \frac{B_8}{C_8 + \lambda R_8 + \epsilon}$$

- B_8 是本节方法带来的质量、吞吐或覆盖收益。
- C_8 是新增计算、显存、通信、数据或标注成本。
- R_8 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_8 \leq C_{\max}, \quad R_8 \leq R_{\max}, \quad Q_8 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

9.1 选择性重计算降低激活峰值


核心判断。“选择性重计算降低激活峰值”是“四维组合与重计算”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 22 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“选择性重计算降低激活峰值”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Activation recomputation can pay for itself (via memory)



Activation recomputation enables larger batches, improving throughput (t=8, p=16)

图 22: 选择性重计算降低激活峰值²²

9.2 Yi 模型训练采用的并行配置

核心判断。“Yi 模型训练采用的并行配置”是“四维组合与重计算”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 23 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Yi 模型训练采用的并行配置”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²²视频画面时间区间：01:11:45–01:12:00。

Performance and Cost Efficiency

Memory and communication restrictions are the two major technical challenges of large scale model training requiring integrated solutions beyond adding more GPUs. We use and improve upon the following techniques to tackle the memory and communication restrictions: (1) ZeRO-1 [69] to remove the memory consumption by partitioning optimizer states cross data-parallel processes; (2) tensor parallel combined with pipeline parallel [70] within each compute node to avoid inter-node communication bottleneck, and the 3D parallel strategy is well designed and optimized to avoid using activation checkpointing and minimize the pipeline bubbles; (3) kernel fusion techniques like flash attention [35] [14] and JIT kernels to reduce redundant global memory access and consumption; (4) topology-aware resource allocation (ranking strategy) to minimize the communication across different layers of switches, which is the limitation of a typical fat-tree-topology.

Yi - ZeRO stage 1 + Tensor + Pipeline parallel

Yi-lightning (2025) – Tensor replaced by Expert parallelism

图 23: Yi 模型训练采用的并行配置²³

9.3 Mixtral 八乘二十二 B 的并行配置

核心判断。“Mixtral 八乘二十二 B 的并行配置”是“四维组合与重计算”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 24 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“Mixtral 八乘二十二 B 的并行配置”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²³视频画面时间区间：01:14:30–01:14:45。

Mixtral 8x22B

From megatron docs –

TP / PP / CP / EP (4/4/1/8) – DP likely 2 (to add up to 256 GPUs)

Mixture-of-Experts Models							
Model	Size	GPUs	TP	PP	CP	EP	Configuration Notes
Mixtral	8x7B	64	1	4	1	8	EP=8 for 8 experts
Mixtral	8x22B	256	4	4	1	8	TP+PP+EP for large MoE
DeepSeek-V3	671B	1024	2	16	1	64	Massive MoE with 256 experts

图 24: Mixtral 八乘二十二 B 的并行配置²⁴

9.4 本章小结

“四维组合与重计算”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。维度越多并不越好；过细切分会增加集合通信和调度复杂度，错误的设备映射还会把节点内通信推到低速网络。

10 代码化复现：最小机制

下面的片段保留本讲最核心的程序结构，用于把公式和系统过程落到可执行对象。它不是生产实现；实际复现还需补充张量形状断言、数值精度、同步、随机种子、数据版本和端到端测试。

Listing 1: Lecture 8 机制伪代码

```
1 with fsdp.summon_full_params(model, recurse=False):
2     out = layer(x)                # 前向前按需 all-gather
3 out.backward()                   # 反向后 reduce-scatter 梯度分片
```

复现检查单

先写正确性基线，再记录资源基线；每次只改变一个机制；同时保存直接中间量和最终指标；对随机算法报告多次运行；对数据与评测保存不可变版本标识。

²⁴视频画面时间区间：01:17:15–01:17:30。

10.1 本章小结

代码的价值在于暴露状态、顺序和边界。若一个概念无法写成输入、变换、状态、输出和断言，它通常还没有被真正理解。

11 总结与延伸

一页压缩

本讲的主问题是：怎样把 ZeRO/FSDP、流水线、张量、序列和专家并行组合为能训练超大稠密或 MoE 模型的方案？统一答案是：第二讲并行 ism 把参数状态、激活状态和 token 路由分别放进设备网格，重点是组合后的通信是否落在正确的高速链路上。

第一，优先理解机制而不是产品名。模型、硬件、数据和评测不断更新，但张量形状、状态位置、目标函数、通信边界和测量误差仍然是稳定的分析对象。第二，所有优化都要写出代价守恒：减少某一种成本通常会增加另一种成本或风险。第三，把小规模实验推广到大规模之前，必须检查瓶颈是否改变、数据分布是否改变、实现常数是否仍在同一数量级。第四，最可靠的课程笔记应允许读者沿时间脚注回到原视频，并沿官方材料找到公式或代码出处。

开放问题

维度越多并不越好；过细切分会增加集合通信和调度复杂度，错误的设备映射还会把节点内通信推到低速网络。后续实验应把这一风险写成可观测量和停止条件，而不是留在讨论部分。

11.1 本章小结

完成本讲后，读者应能用统一语言解释每个主题的输入、状态、变换、输出、资源成本和失败模式，并据此设计一个含基线、消融、误差条和证据记录的最小实验。

12 资料来源与审计边界

- 课程主页：<https://cs336.stanford.edu/>。
- 视频：<https://www.youtube.com/watch?v=6-cXp-a0mdg>。
- Stanford 官方材料：lecture_08.pdf；客座讲座若无官方文件则以视频和字幕为主。
- 本地证据：audio.srt、figure_manifest.tsv、figure_verification.txt、teaching_atoms.tsv、numerical_claims.tsv。

12.1 本章小结

本笔记覆盖播放列表中的本讲内容与课程主页当日可取得的官方材料。没有官方讲义的客座讲座不会被伪装成有讲义；讲者口头推测、本笔记分析框架和官方公式在文字中分别标明。