

Stanford CS336: Language Modeling from Scratch

Lecture 9: Scaling Laws 1

Spring 2026 中文精讲笔记

主讲: Tatsunori Hashimoto



频道: Stanford Online

发布日期: 2026-04-30

时长: 1:17:57

视频: <https://www.youtube.com/watch?v=Q15rhEWZPQ4>

官方主页: <https://cs336.stanford.edu/>

目录

1 导读：问题、证据与阅读方法	2
2 缩放定律的预测任务	2
3 幂律与统计收敛	7
4 架构和优化器的影响	12
5 深度宽度与 MoE	17
6 临界批大小	21
7 数据模型联合缩放	25
8 计算最优训练	29
9 Kaplan 与 Chinchilla 争议	33
10 代码化复现：最小机制	37
11 总结与延伸	38
12 资料来源与审计边界	38

1 导读：问题、证据与阅读方法

本讲主问题

怎样用一组便宜的小规模实验预测昂贵训练的损失，并据此选择模型规模、数据量和计算预算？

缩放律不是自然常数，而是给定数据分布、架构、优化器和训练配方下的经验响应面。本笔记以课程视频、人工字幕和 Stanford 官方讲义或代码为共同证据源。图像均来自每十五秒抽帧后的人工接触表审查，时间脚注可回到原视频复核；公式区分课程机制关系和本笔记的决策分析框架。学习时建议先读主问题，再沿“机制-资源-失败模式-验证指标”四列整理自己的实验。

首先排除的误读

外推区间过长、只取最佳点、混用不同训练配方或忽略下游指标都会让漂亮直线给出错误决策。

1.1 关键数字核对

主张	数值或关系	视频时间
Transformer 训练近似计算量	C 6ND FLOPs	00:56:00
联合缩放变量	模型参数 N 与 token 数 D	00:55:00
临界批大小定义	统计收益与并行收益的转折点	00:43:00
拟合坐标	通常使用 $\log\text{-}\log$	00:12:00

1.2 本章小结

本章建立证据边界：视频解释提供因果和强调，官方材料提供公式与代码，精选帧提供可核查的视觉状态。后文每个主题都同时回答“为何重要、怎样工作、怎样失败、怎样验证”，避免把课程压缩成术语目录。

2 缩放定律的预测任务

本节路线

本节依次处理：缩放定律用小规模实验预测大模型表现、统计学习率与样本复杂度的幂律关系、早期语言模型数据缩放经验、数据量与损失的对数线性曲线。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L(N) = L_{\infty} + aN^{-\alpha}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。

- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_1 = \frac{B_1}{C_1 + \lambda R_1 + \varepsilon}$$

- B_1 是本节方法带来的质量、吞吐或覆盖收益。
- C_1 是新增计算、显存、通信、数据或标注成本。
- R_1 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_1 \leq C_{\max}, \quad R_1 \leq R_{\max}, \quad Q_1 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

2.1 缩放定律用小规模实验预测大模型表现

核心判断。“缩放定律用小规模实验预测大模型表现”是“缩放定律的预测任务”中的一个可检验设计选择，而不是只需记忆的产品名。在 $\log$ 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 1 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“缩放定律用小规模实验预测大模型表现”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Today: simple, predictive ‘laws’ for behaviors of LMs

The approach -

scaling laws which are simple, predictive rules for model performance

Old and unpleasant: tune hyperparameters on big models

New (over?) optimism: tune on small models, extrapolate to large ones




图 1: 缩放定律用小规模实验预测大模型表现¹

2.2 统计学习率与样本复杂度的幂律关系

核心判断。“统计学习率与样本复杂度的幂律关系”是“缩放定律的预测任务”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 2 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“统计学习率与样本复杂度的幂律关系”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹视频画面时间区间：00:02:45–00:03:00。

Sample complexity and rates

Theorists have thought about ‘scaling’ for a long time..

$$\epsilon(\hat{h}) \leq \left(\min_{h \in H} \epsilon(h) \right) + 2\sqrt{\frac{1}{m} \log \frac{2k}{\delta}}$$

(learning in a finite set of k hypotheses)

Under the assumptions of Theorem 1.5, the rate of convergence of the estimator $\hat{p}_n(x_0)$ is $\psi_n = n^{-\frac{\beta}{2\beta+1}}$, which means that for a finite constant C and for all $n \geq 1$ we have

$$\sup_{p \in \mathcal{P}(\beta, L)} \mathbb{E}_p \left[(\hat{p}_n(x_0) - p(x_0))^2 \right] \leq C \psi_n^2.$$

(generative modeling for smooth densities)

But these are upper bounds, not actual, realized loss values.

<https://www.cs.cmu.edu/~epxing/Class/10701/slides/lecture16-VC.pdf>
Hall, 1989

图 2: 统计学习率与样本复杂度的幂律关系²

2.3 早期语言模型数据缩放经验

核心判断。“早期语言模型数据缩放经验”是“缩放定律的预测任务”中的一个可检验设计选择，而不是只需记忆的产品名。在 $\log$ 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 3 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“早期语言模型数据缩放经验”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²视频画面时间区间：00:05:15–00:05:30。

Early history of scaling laws – data scaling



Model	Formula
Exp ₃	$y = c - e^{-ax+b}$
Exp ₄	$y = c - e^{-ax^\alpha+b}$
ExpP ₃	$y = c - e^{(x-b)^\alpha}$
Pow ₃	$y = c - ax^{-\alpha}$
Pow ₄	$y = c - (-ax + b)^{-\alpha}$
ILog ₂	$y = c - (a/\log x)$

Table 1: Curve families.

Early tests of functional forms

Kolachina et al 2012 – power law relation between data and downstream performance



图 3: 早期语言模型数据缩放经验³

2.4 数据量与损失的对数线性曲线

核心判断。“数据量与损失的对数线性曲线”是“缩放定律的预测任务”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 4 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“数据量与损失的对数线性曲线”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

³视频画面时间区间：00:08:00–00:08:15。


Data vs performance

What's a data scaling law?

Data scaling laws : simple formula that maps dataset size (n) to error

What do we expect out of scaling laws?

Monotonic, logistic-like curves



[Hestness+ 2017]

图 4: 数据量与损失的对数线性曲线⁴

2.5 本章小结

“缩放定律的预测任务”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。外推区间过长、只取最佳点、混用不同训练配方或忽略下游指标都会让漂亮直线给出错误决策。

3 幂律与统计收敛

本节路线

本节依次处理：均值估计误差随样本数下降、非参数学习的幂律收敛、缩放律成立所需的分布与容量假设、数据混合选择改变有效缩放曲线。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L(D) = L_{\infty} + bD^{-\beta}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁴视频画面时间区间：00:13:30–00:13:45。

$$G_2 = \frac{B_2}{C_2 + \lambda R_2 + \epsilon}$$

- B_2 是本节方法带来的质量、吞吐或覆盖收益。
- C_2 是新增计算、显存、通信、数据或标注成本。
- R_2 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_2 \leq C_{\max}, \quad R_2 \leq R_{\max}, \quad Q_2 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

3.1 均值估计误差随样本数下降

核心判断。“均值估计误差随样本数下降”是“幂律与统计收敛”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 5 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“均值估计误差随样本数下降”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Toy example: mean estimation

Input: $x_1 \dots x_n \sim N(\mu, \sigma^2)$

Task: estimate the average as $\hat{\mu} = \frac{\sum_i x_i}{n}$

What's the error? By standard arguments..

$$E[(\hat{\mu} - \mu)^2] = \frac{\sigma^2}{n}$$

This is a 'scaling law'

$$\log(\text{Error}) = -\log n + 2 \log \sigma$$

More generally, any polynomial rate $1/n^\alpha$ is a scaling law



图 5: 均值估计误差随样本数下降⁵

3.2 非参数学习的幂律收敛

核心判断。“非参数学习的幂律收敛”是“幂律与统计收敛”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 6 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“非参数学习的幂律收敛”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁵视频画面时间区间：00:16:00–00:16:15。

Detour: scaling laws for (nonparametric) learning

Neural nets can approximate arbitrary functions. Lets turn that into an example.

Input: $x_1 \dots x_n$ uniform in 2D unit box. $y_i = f(x_i) + N(0,1)$

Task: estimate $f(x)$

Approach: cut up the 2D space into boxes with length $n^{-\frac{1}{4}}$

What's our estimation error?

Informally, we have $\sqrt{n}$ boxes, each box gets $\sqrt{n}$ samples.

$$Error \approx \frac{1}{\sqrt{n}} + (other\ smoothness\ terms)$$

In d -dimensions, this becomes $Error = n^{-1/d}$ - **This means scaling is $y = -\frac{1}{d}x + C$**

Takeaway: flexible 'nonparametric' learning has dimension dependent scaling laws.



图 6: 非参数学习的幂律收敛⁶

3.3 缩放律成立所需的分布与容量假设

核心判断。“缩放律成立所需的分布与容量假设”是“幂律与统计收敛”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 7 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“缩放律成立所需的分布与容量假设”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。


⁶视频画面时间区间：00:18:45–00:19:00。

Conceptual foundations of data scaling laws.

Q: Why do scaling laws show up?

We know error should be monotone

But why is it a power law / linear in log-log?



A (?): Estimation error naturally decays polynomially.

But this answer may take a moment to understand. Let's work through an example.

Example: If our task is to estimate the mean of a dataset, what's the scaling law?



图 7: 缩放律成立所需的分布与容量假设⁷

3.4 数据混合选择改变有效缩放曲线

核心判断。“数据混合选择改变有效缩放曲线”是“幂律与统计收敛”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 8 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“数据混合选择改变有效缩放曲线”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁷视频画面时间区间：00:21:30–00:21:45。

In practice: data mixture selection via scaling is hard



Data Mixing Laws: Optimizing Data Mixtures by Predicting Language Modeling Performance

Jiasheng Ye^{1,2}, Feijia Liu^{1,2}, Tiansiang Sun¹, Jun Zhan³, Yunhua Zhou², Xipeng Qiu^{1,2}
 {jsye23, pjliu23}@fudan.edu.cn, zhouyunhua@pjlab.org.cn, xqiu@fudan.edu.cn
¹Fudan University ²Shanghai AI Laboratory

DataDecide

How to Predict Best Pretraining Data with Small Experiments

San Magagnoli^{1,2}, Nguyen Tai^{1,2}, Ben Boger^{1,2}, David Holzman¹, Jesse Hoang¹, Luca Soldati¹, Abhishek Bhagya¹, Jiacheng Liu¹, Dirk Groenewald¹, Oyvind Tafjord¹, Noah A. Smith^{1,2}, Pang Wei Koh^{1,2}, Jesse Dodge¹



Natural idea – build data scaling laws

Empirical eval – just take the best small dataset



图 8: 数据混合选择改变有效缩放曲线⁸

3.5 本章小结

“幂律与统计收敛”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。外推区间过长、只取最佳点、混用不同训练配方或忽略下游指标都会让漂亮直线给出错误决策。

4 架构和优化器的影响

本节路线

本节依次处理：计算不受限时模型和数据的缩放、固定计算预算下寻找最优模型数据配比、Transformer 与 LSTM 的缩放曲线比较、优化器选择改变可观测的缩放常数。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L(N, D) = L_{\infty} + aN^{-\alpha} + bD^{-\beta}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁸视频画面时间区间：00:24:15–00:24:30。

$$G_3 = \frac{B_3}{C_3 + \lambda R_3 + \epsilon}$$

- B_3 是本节方法带来的质量、吞吐或覆盖收益。
- C_3 是新增计算、显存、通信、数据或标注成本。
- R_3 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_3 \leq C_{\max}, \quad R_3 \leq R_{\max}, \quad Q_3 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

4.1 计算不受限时模型和数据的缩放

核心判断。“计算不受限时模型和数据的缩放”是“架构和优化器的影响”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 9 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“计算不受限时模型和数据的缩放”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 9: 计算不受限时模型和数据的缩放⁹

4.2 固定计算预算下寻找最优模型数据配比

核心判断。“固定计算预算下寻找最优模型数据配比”是“架构和优化器的影响”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 10 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“固定计算预算下寻找最优模型数据配比”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁹视频画面时间区间：00:26:45–00:27:00。




图 10: 固定计算预算下寻找最优模型数据配比¹⁰

4.3 Transformer 与 LSTM 的缩放曲线比较

核心判断。“Transformer 与 LSTM 的缩放曲线比较”是“架构和优化器的影响”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 11 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“Transformer 与 LSTM 的缩放曲线比较”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁰视频画面时间区间：00:29:30–00:29:45。

1. Architecture: transformers vs LSTMs

Q: Are transformers better than LSTMs?

Brute force way: spend tens of millions to train a LSTM GPT-3

Scaling law way:




图 11: Transformer 与 LSTM 的缩放曲线比较¹¹

4.4 优化器选择改变可观测的缩放常数

核心判断。“优化器选择改变可观测的缩放常数”是“架构和优化器的影响”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 12 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


应记住的判断

围绕“优化器选择改变可观测的缩放常数”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹¹视频画面时间区间：00:32:15–00:32:30。

2. Optimizer choice

What about ADAM vs SGD?



[Hestness+ 2017]

(Note, this is in 2017, so pre-transformers. RHN is recurrent highway nets)

图 12: 优化器选择改变可观测的缩放常数¹²

4.5 本章小结

“架构和优化器的影响”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。外推区间过长、只取最佳点、混用不同训练配方或忽略下游指标都会让漂亮直线给出错误决策。

5 深度宽度与 MoE

本节路线

本节依次处理：深度和宽度对同参数量模型的影响、MoE 总参数和激活参数的缩放价值、临界批大小连接梯度噪声与并行效率。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$C \approx 6ND$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹²视频画面时间区间：00:34:45–00:35:00。

$$G_4 = \frac{B_4}{C_4 + \lambda R_4 + \epsilon}$$

- B_4 是本节方法带来的质量、吞吐或覆盖收益。
- C_4 是新增计算、显存、通信、数据或标注成本。
- R_4 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_4 \leq C_{\max}, \quad R_4 \leq R_{\max}, \quad Q_4 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

5.1 深度和宽度对同参数量模型的影响

核心判断。“深度和宽度对同参数量模型的影响”是“深度宽度与 MoE”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 13 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“深度和宽度对同参数量模型的影响”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

3. Depth/Width: But not all parameters are made equal

We've been thinking about 'parameters' but not all parameters are equal



Embedding layer parameters don't behave the same!

Related: recent papers on scaling laws for mixtures of experts.

图 13: 深度和宽度对同参数量模型的影响¹³

5.2 MoE 总参数和激活参数的缩放价值

核心判断。“MoE 总参数和激活参数的缩放价值”是“深度宽度与 MoE”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 14 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


复现实验记录

围绕“MoE 总参数和激活参数的缩放价值”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹³视频画面时间区间：00:37:30–00:37:45。

Side note – ‘Value of parameters’

With MoEs, we expect parameter scaling to change



Parameters vs FLOPs: Scaling Laws for Optimal Sparsity for Mixture-of-Experts Language Models

Samira Ahnari* Apple
Harshay Shah* MIT
Dan Bushbridge Apple
Alaaeldin Mohamed Elnouby Ali Apple
Josh Susskind Apple
Vimal Thilak* Apple




图 14: MoE 总参数和激活参数的缩放价值¹⁴

5.3 临界批大小连接梯度噪声与并行效率

核心判断。“临界批大小连接梯度噪声与并行效率”是“深度宽度与 MoE”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 15 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“临界批大小连接梯度噪声与并行效率”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁴视频画面时间区间：00:40:15–00:40:30。

4. Batch size: Critical batch size


An Empirical Model of Large-Batch Training

Sam McCandlish*
OpenAI
sam@openai.com

Jared Kaplan
Johns Hopkins University, OpenAI
jared@jhu.edu

Dario Amodei
OpenAI
dario@openai.com

and the OpenAI Dota Team¹



Batch size – known to have strong diminishing returns past a certain point.

Critical batch = min number of examples before diminishing returns (what does that mean?)

🔍 🔗 📄 📊 📈 📉

图 15: 临界批大小连接梯度噪声与并行效率¹⁵

5.4 本章小结

“深度宽度与 MoE”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。外推区间过长、只取最佳点、混用不同训练配方或忽略下游指标都会让漂亮直线给出错误决策。

6 临界批大小

本节路线

本节依次处理：临界批大小的定义和估计公式、批大小变化对训练效率和最终损失的影响、预训练损失与下游能力之间的差异。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$B_{\text{crit}} \propto L^{-\gamma}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁵视频画面时间区间：00:43:00–00:43:15。

$$G_5 = \frac{B_5}{C_5 + \lambda R_5 + \epsilon}$$

- B_5 是本节方法带来的质量、吞吐或覆盖收益。
- C_5 是新增计算、显存、通信、数据或标注成本。
- R_5 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_5 \leq C_{\max}, \quad R_5 \leq R_{\max}, \quad Q_5 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

6.1 临界批大小的定义和估计公式

核心判断。“临界批大小的定义和估计公式”是“临界批大小”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 16 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“临界批大小的定义和估计公式”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

4. Critical batch size definitions..

What is critical batch size, more precisely?

- Pick a target loss and train 1). Steps needed (S), 2). Examples needed.
- Sweep over batches

The curve should follow roughly..

$$\frac{S}{S_{\min}} - 1 = \left(\frac{E}{E_{\min}} - 1 \right)^{-1}$$

Fit for $S_{\min}, E_{\min}$ on this curve and pick

$$B_{\text{crit}} = \frac{E_{\min}}{S_{\min}}.$$

This balances both sides of the equation, giving roughly 2x the steps / passes optimal

(this is claimed to be close to the ratio of the trace of the gradient covariance and squared norm of the gradient)



图 16: 临界批大小的定义和估计公式¹⁶

6.2 批大小变化对训练效率和最终损失的影响

核心判断。“批大小变化对训练效率和最终损失的影响”是“临界批大小”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 17 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“批大小变化对训练效率和最终损失的影响”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁶视频画面时间区间：00:45:30–00:45:45。

4. Batch size: critical batch size



The smaller the loss target,
The bigger the batch

$$C_{\min}(C) \equiv \frac{C}{1 + B/B_{\text{crit}}(L)} \quad (\text{minimum compute, at } B \ll B_{\text{crit}})$$

🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍

图 17: 批大小变化对训练效率和最终损失的影响¹⁷

6.3 预训练损失与下游能力之间的差异

核心判断。“预训练损失与下游能力之间的差异”是“临界批大小”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 18 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“预训练损失与下游能力之间的差异”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁷视频画面时间区间：00:48:15–00:48:30。

Caution – scaling behaviors can differ downstream

Thus far: scaling is predictable and depends mainly on parameters

Catch: downstream scaling can often be much less predictable




图 18: 预训练损失与下游能力之间的差异¹⁸

6.4 本章小结

“临界批大小”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。外推区间过长、只取最佳点、混用不同训练配方或忽略下游指标都会让漂亮直线给出错误决策。

7 数据模型联合缩放

本节路线

本节依次处理：利用缩放律设计训练实验的步骤、不同架构曲线不可直接共用常数、数据量和模型规模的联合损失模型。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$N_{\star}(C) \propto C^{\frac{\beta}{\alpha+\beta}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁸视频画面时间区间：00:51:00–00:51:15。

$$G_6 = \frac{B_6}{C_6 + \lambda R_6 + \varepsilon}$$

- B_6 是本节方法带来的质量、吞吐或覆盖收益。
- C_6 是新增计算、显存、通信、数据或标注成本。
- R_6 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_6 \leq C_{\max}, \quad R_6 \leq R_{\max}, \quad Q_6 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

7.1 利用缩放律设计训练实验的步骤

核心判断。“利用缩放律设计训练实验的步骤”是“数据模型联合缩放”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 19 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“利用缩放律设计训练实验的步骤”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Some surprising takeaways

The effect of hyperparameters on big LMs can be predicted *before* training!

- Optimizer choice
- Model depth
- Architecture choice

The scaling law based design procedure.

1. Train a few smaller models
2. Establish a scaling law (e.g. ADAM vs SGD scaling law)
3. Select optimal hyperparam based on the scaling law prediction.



图 19: 利用缩放律设计训练实验的步骤¹⁹

7.2 不同架构曲线不可直接共用常数

核心判断。“不同架构曲线不可直接共用常数”是“数据模型联合缩放”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 20 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“不同架构曲线不可直接共用常数”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁹视频画面时间区间：00:53:30–00:53:45。




图 20: 不同架构曲线不可直接共用常数²⁰

7.3 数据量和模型规模的联合损失模型

核心判断。“数据量和模型规模的联合损失模型”是“数据模型联合缩放”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 21 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“数据量和模型规模的联合损失模型”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁰视频画面时间区间：00:56:15–00:56:30。

One important use of scaling laws

Q: Do we need more data or bigger models?

Clearly, lots of data is wasted on small models

Joint data-model scaling laws describe how the two relate



From Rosenfeld+ 2020,

$$Error = n^{-\alpha} + m^{-\beta} + C$$

From Kaplan+ 2020

$$Error = [m^{-\alpha} + n^{-1}]^{\beta}$$

Provides surprisingly good fits to model-data joint error.



(a) Wiki103 error (cross entropy) landscape.

图 21: 数据量和模型规模的联合损失模型²¹

7.4 本章小结

“数据模型联合缩放”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。外推区间过长、只取最佳点、混用不同训练配方或忽略下游指标都会让漂亮直线给出错误决策。

8 计算最优训练

本节路线

本节依次处理：计算最优的数据模型权衡、对多条训练曲线取下包络拟合、Kaplan 与 Chinchilla 结论差异。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$D_{\star}(C) \propto C^{\frac{\alpha}{\alpha+\beta}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²¹视频画面时间区间：00:59:00–00:59:15。

$$G_7 = \frac{B_7}{C_7 + \lambda R_7 + \epsilon}$$

- B_7 是本节方法带来的质量、吞吐或覆盖收益。
- C_7 是新增计算、显存、通信、数据或标注成本。
- R_7 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_7 \leq C_{\max}, \quad R_7 \leq R_{\max}, \quad Q_7 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

8.1 计算最优的数据模型权衡

核心判断。“计算最优的数据模型权衡”是“计算最优训练”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 22 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断


围绕“计算最优的数据模型权衡”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

‘Optimal’ compute and data tradeoffs as a case study.

Rosenfeld, Kaplan both predict relationship of data, model and perf.

Kaplan claims: $N_{opt} = C^{0.73}$, $D_{opt} = C^{0.27}$ (tokens per param decreases w/ C)

Chinchilla [Hoffman et al] argue these fits are quite off.



Hoffman+ 2022

🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍

图 22: 计算最优的数据模型权衡²²

8.2 对多条训练曲线取下包络拟合

核心判断。“对多条训练曲线取下包络拟合”是“计算最优训练”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 23 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“对多条训练曲线取下包络拟合”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²²视频画面时间区间：01:01:45–01:02:00。




图 23: 对多条训练曲线取下包络拟合²³

8.3 Kaplan 与 Chinchilla 结论差异

核心判断。“Kaplan 与 Chinchilla 结论差异”是“计算最优训练”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 24 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


常见失效模式

围绕“Kaplan 与 Chinchilla 结论差异”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²³视频画面时间区间：01:04:15–01:04:30。

Why do we have this big difference?

Kaplan claims: $N_{opt} = C^{0.73}$, $D_{opt} = C^{0.27}$ (tokens per param decreases w/ C)



Why such a big difference (when both fit joint scaling laws?)

🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍

图 24: Kaplan 与 Chinchilla 结论差异²⁴

8.4 本章小结

“计算最优训练”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。外推区间过长、只取最佳点、混用不同训练配方或忽略下游指标都会让漂亮直线给出错误决策。

9 Kaplan 与 Chinchilla 争议

本节路线

本节依次处理：优化预算和拟合方法解释缩放差异、Chinchilla 方法三的拟合误差来源、训练最优与推理最优 token 参数比。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L_{\star}(C) = L_{\infty} + kC^{-\delta}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²⁴视频画面时间区间：01:07:00–01:07:15。

$$G_8 = \frac{B_8}{C_8 + \lambda R_8 + \epsilon}$$

- B_8 是本节方法带来的质量、吞吐或覆盖收益。
- C_8 是新增计算、显存、通信、数据或标注成本。
- R_8 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_8 \leq C_{\max}, \quad R_8 \leq R_{\max}, \quad Q_8 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

9.1 优化预算和拟合方法解释缩放差异


核心判断。“优化预算和拟合方法解释缩放差异”是“Kaplan 与 Chinchilla 争议”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 25 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“优化预算和拟合方法解释缩放差异”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Explanation 1



- Kaplan removed last layer param from the count
- Warmup at very small compute budgets was too high
- (Decay itself is maybe not critical if batch / LR is properly tuned)

图 25: 优化预算和拟合方法解释缩放差异²⁵

9.2 Chinchilla 方法三的拟合误差来源

核心判断。“Chinchilla 方法三的拟合误差来源”是“Kaplan 与 Chinchilla 争议”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 26 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


复现实验记录

围绕“Chinchilla 方法三的拟合误差来源”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁵视频画面时间区间：01:09:45–01:10:00。

Fun addendum – errors in chinchilla method 3

Note that this method three was likely flawed in the original paper. Some authors did data forensics, recovered the raw data, and re-did the fit and got results more consistent with methods 1 and 2



[Besiroglu et al 2024]

图 26: Chinchilla 方法三的拟合误差来源²⁶

9.3 训练最优与推理最优 token 参数比

核心判断。“训练最优与推理最优 token 参数比”是“Kaplan 与 Chinchilla 争议”中的一个可检验设计选择，而不是只需记忆的产品名。prefill 可以沿序列并行而 decode 逐 token 串行；服务评估要同时报告首 token、token 间隔、吞吐、尾延迟和显存峰值。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 27 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“训练最优与推理最优 token 参数比”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁶视频画面时间区间：01:12:30–01:12:45。

Important note – train-optimal is likely not what you want

Chinchilla aims to tell you what gives the best model for fixed training compute..
But most of the compute in a real deployment is inference.. So we should ‘over’ train

- **GPT3** – 2 tokens / param
- **Chinchilla** – 20 tokens / param
- **LLaMA65B** – 22 tokens / param
- **Llama 2 70B** – 29 tokens / param
- **Mistral 7B** – 110 tokens / param
- **Llama 3 70B** – 215 tokens / param
- ... etc etc

The more usage we expect, the more it becomes worth it to pay the upfront cost



图 27: 训练最优与推理最优 token 参数比²⁷

9.4 本章小结

“Kaplan 与 Chinchilla 争议”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。外推区间过长、只取最佳点、混用不同训练配方或忽略下游指标都会让漂亮直线给出错误决策。

10 代码化复现：最小机制

下面的片段保留本讲最核心的程序结构，用于把公式和系统过程落到可执行对象。它不是生产实现；实际复现还需补充张量形状断言、数值精度、同步、随机种子、数据版本和端到端测试。

Listing 1: Lecture 9 机制伪代码

```
1 # 在 log 空间拟合  $L = L_{inf} + a * N^{(-alpha)}$ 
2 def scaling_loss(N, L_inf, log_a, alpha):
3     return L_inf + exp(log_a) * N ** (-alpha)
```

复现检查单

先写正确性基线，再记录资源基线；每次只改变一个机制；同时保存直接中间量和最终指标；对随机算法报告多次运行；对数据与评测保存不可变版本标识。

²⁷视频画面时间区间：01:15:00–01:15:15。

10.1 本章小结

代码的价值在于暴露状态、顺序和边界。若一个概念无法写成输入、变换、状态、输出和断言，它通常还没有被真正理解。

11 总结与延伸

一页压缩

本讲的主问题是：怎样用一组便宜的小规模实验预测昂贵训练的损失，并据此选择模型规模、数据量和计算预算？统一答案是：缩放律不是自然常数，而是给定数据分布、架构、优化器和训练配方下的经验响应面。

第一，优先理解机制而不是产品名。模型、硬件、数据和评测不断更新，但张量形状、状态位置、目标函数、通信边界和测量误差仍然是稳定的分析对象。第二，所有优化都要写出代价守恒：减少某一种成本通常会增加另一种成本或风险。第三，把小规模实验推广到大规模之前，必须检查瓶颈是否改变、数据分布是否改变、实现常数是否仍在同一数量级。第四，最可靠的课程笔记应允许读者沿时间脚注回到原视频，并沿官方材料找到公式或代码出处。

开放问题

外推区间过长、只取最佳点、混用不同训练配方或忽略下游指标都会让漂亮直线给出错误决策。后续实验应把这一风险写成可观测量和停止条件，而不是留在讨论部分。

11.1 本章小结

完成本讲后，读者应能用统一语言解释每个主题的输入、状态、变换、输出、资源成本和失败模式，并据此设计一个含基线、消融、误差条和证据记录的最小实验。

12 资料来源与审计边界

- 课程主页：<https://cs336.stanford.edu/>。
- 视频：<https://www.youtube.com/watch?v=Q15rhEWZPQ4>。
- Stanford 官方材料：lecture_09.pdf；客座讲座若无官方文件则以视频和字幕为主。
- 本地证据：audio.srt、figure_manifest.tsv、figure_verification.txt、teaching_atoms.tsv、numerical_claims.tsv。

12.1 本章小结

本笔记覆盖播放列表中的本讲内容与课程主页当日可取得的官方材料。没有官方讲义的客座讲座不会被伪装成有讲义；讲者口头推测、本笔记分析框架和官方公式在文字中分别标明。