


Stanford CS336: Language Modeling from Scratch

Lecture 11: Scaling Laws 2

Spring 2026 中文精讲笔记

主讲: Tatsunori Hashimoto



频道: Stanford Online

发布日期: 2026-05-19

时长: 1:17:03

视频: <https://www.youtube.com/watch?v=vTfEy0yzV9E>

官方主页: <https://cs336.stanford.edu/>

目录

1 导读：问题、证据与阅读方法	2
2 从损失预测转向决策	2
3 计算最优缩放	7
4 训练预算分配	12
5 推理成本进入目标	17
6 数据质量与重复 epoch	21
7 代理实验和外推	25
8 不确定性与敏感性	29
9 可执行的缩放计划	33
10 代码化复现：最小机制	37
11 总结与延伸	38
12 资料来源与审计边界	38

1 导读：问题、证据与阅读方法

本讲主问题

当训练和部署成本同时存在时，怎样把经验缩放曲线变成可执行的模型、数据和 token 预算决策？

第二讲缩放律强调决策层：拟合只是中间步骤，最终要把训练 FLOPs、推理次数、数据上限和误差条放在同一目标中。本笔记以课程视频、人工字幕和 Stanford 官方讲义或代码为共同证据源。图像均来自每十五秒抽帧后的人工接触表审查，时间脚注可回到原视频复核；公式区分课程机制关系和本笔记的决策分析框架。学习时建议先读主问题，再沿“机制-资源-失败模式-验证指标”四列整理自己的实验。

首先排除的误读

忽略推理生命周期、把低质量 token 当成等价数据、或把点估计当成确定结论，都会选择错误的训练规模。

1.1 关键数字核对

主张	数值或关系	视频时间
训练 FLOPs 近似	6ND	00:08:00
总生命周期成本	训练加 Q 次推理	00:31:00
拟合要求	多个规模与多个 token 预算	00:50:00
外推结果	必须同时报告不确定性区间	01:02:00

1.2 本章小结

本章建立证据边界：视频解释提供因果和强调，官方材料提供公式与代码，精选帧提供可核查的视觉状态。后文每个主题都同时回答“为何重要、怎样工作、怎样失败、怎样验证”，避免把课程压缩成术语目录。

2 从损失预测转向决策

本节路线

本节依次处理：初始化优化器学习率与批大小具有尺度敏感性、muP 通过参数化规则稳定跨尺度超参数、muP 使不同模型宽度的最优学习率接近、拟合模型数据权衡需要完整训练曲线。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L(N, D) = L_{\infty} + aN^{-\alpha} + bD^{-\beta}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。

- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_1 = \frac{B_1}{C_1 + \lambda R_1 + \varepsilon}$$

- B_1 是本节方法带来的质量、吞吐或覆盖收益。
- C_1 是新增计算、显存、通信、数据或标注成本。
- R_1 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_1 \leq C_{\max}, \quad R_1 \leq R_{\max}, \quad Q_1 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

2.1 初始化优化器学习率与批大小具有尺度敏感性

核心判断。“初始化优化器学习率与批大小具有尺度敏感性”是“从损失预测转向决策”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 1 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“初始化优化器学习率与批大小具有尺度敏感性”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Initialization and optimizers

Initialization, optimizers, and various hyperparams (LR/batch) can be scale sensitive




图 1: 初始化优化器学习率与批大小具有尺度敏感性¹

2.2 muP 通过参数化规则稳定跨尺度超参数

核心判断。“muP 通过参数化规则稳定跨尺度超参数”是“从损失预测转向决策”中的一个可检验设计选择，而不是只需记忆的产品名。共享块通过多次递归增加计算深度而不增加同等参数量；必须检查残差动力学、谱半径、梯度传播和固定 FLOPs 下的最优循环次数。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 2 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“muP 通过参数化规则稳定跨尺度超参数”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹视频画面时间区间：00:02:45–00:03:00。

Techique 1: muP to stabilize scaling

Scale_emb = 12, scale_depth = 1.4, init_std = 0.1, lr = 0.01

Name	Specific Operation
Embedding Output Scaling	Multiply the output of the embedding by $scale_emb$
Residual Connection Scaling	Scale the increment at each residual connection in each layer by $scale_depth / \sqrt{num_layers}$
Initialization of Tensors	Set the initialization standard deviation of each two-dimensional tensor parameter to $init_std / \sqrt{d_m / d_{base}}$, and set other parameters' initialization to 0.1
Learning Rate Scaling of Tensors	Adjust the learning rate of each two-dimensional tensor parameter to $1 / (d_m / d_{base})$ times the learning rate of other parts (or the overall learning rate)
LM Head Scaling	Adjust the output logits to $1 / (d_m / d_{base})$ times the original value

Table 7: List of operations used when applying tensor program techniques.

图 2: muP 通过参数化规则稳定跨尺度超参数²

2.3 muP 使不同模型宽度的最优学习率接近

核心判断。“muP 使不同模型宽度的最优学习率接近”是“从损失预测转向决策”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 3 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“muP 使不同模型宽度的最优学习率接近”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²视频画面时间区间：00:05:15–00:05:30。

Optimal LR

According to muP – optimal learning rate should be (roughly) stable. Is it?




Figure 3: Loss vs Learning Rate. After applying for the Tensor Program, the learning rate shift becomes minimal.

图 3: muP 使不同模型宽度的最优学习率接近³

2.4 拟合模型数据权衡需要完整训练曲线

核心判断。“拟合模型数据权衡需要完整训练曲线”是“从损失预测转向决策”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 4 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


应记住的判断

围绕“拟合模型数据权衡需要完整训练曲线”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

³视频画面时间区间：00:08:00–00:08:15。

What remains – model size vs data tradeoffs.

From chinchilla – to fit a scaling law, we need to train from scratch, not just early stop



This turns the cost of fitting a scaling law from n to n^2 . Can we avoid this?

图 4: 拟合模型数据权衡需要完整训练曲线⁴

2.5 本章小结

“从损失预测转向决策”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。忽略推理生命周期、把低质量 token 当成等价数据、或把点估计当成确定结论，都会选择错误的训练规模。

3 计算最优缩放

本节路线

本节依次处理：WSD 学习率在 miniCPM 中的缩放表现、DeepSeek 用小模型拟合学习率和最终损失、学习率缩放曲线及其可疑拟合区间、小规模缩放曲线预测最终模型损失。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$C_{\text{train}} \approx 6ND$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁴视频画面时间区间：00:10:30–00:10:45。

$$G_2 = \frac{B_2}{C_2 + \lambda R_2 + \epsilon}$$

- B_2 是本节方法带来的质量、吞吐或覆盖收益。
- C_2 是新增计算、显存、通信、数据或标注成本。
- R_2 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_2 \leq C_{\max}, \quad R_2 \leq R_{\max}, \quad Q_2 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

3.1 WSD 学习率在 miniCPM 中的缩放表现

核心判断。“WSD 学习率在 miniCPM 中的缩放表现”是“计算最优缩放”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 5 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“WSD 学习率在 miniCPM 中的缩放表现”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

WSD learning rates work well in miniCPM

Slower during the stable phase, rapid loss decay during decay phase. Decay ~ 10%.




图 5: WSD 学习率在 miniCPM 中的缩放表现⁵

3.2 DeepSeek 用小模型拟合学习率和最终损失

核心判断。“DeepSeek 用小模型拟合学习率和最终损失”是“计算最优缩放”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 6 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


复现实验记录

围绕“DeepSeek 用小模型拟合学习率和最终损失”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁵视频画面时间区间：00:13:15–00:13:30。

DeepSeek

DeepSeek (2024) – another LM with careful scaling analysis



7 and 67B param models – generally high performance compared to other open LM

图 6: DeepSeek 用小模型拟合学习率和最终损失⁶

3.3 学习率缩放曲线及其可疑拟合区间

核心判断。“学习率缩放曲线及其可疑拟合区间”是“计算最优缩放”中的一个可检验设计选择，而不是只需记忆的产品名。在 $\log$ 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 7 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


常见失效模式

围绕“学习率缩放曲线及其可疑拟合区间”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁶视频画面时间区间：00:16:00–00:16:15。

Scaling analysis of learning rates

Small scale runs + collect 'near optimal' (within 0.25% of min) models.



Learning rate fit looks a bit questionable..

图 7: 学习率缩放曲线及其可疑拟合区间⁷

3.4 小规模缩放曲线预测最终模型损失

核心判断。“小规模缩放曲线预测最终模型损失”是“计算最优缩放”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 8 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“小规模缩放曲线预测最终模型损失”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁷视频画面时间区间：00:18:30–00:18:45。

Scaling predicts final model loss

The fitted scaling models (generally) accurately predict the final model losses.

Additionally, we fitted the loss scaling curve according to compute budget C and optimal generalization error, and predicted the generalization error for DeepSeek LLM 7B and 67B, as shown in Figure 5. The results indicate that using small-scale experiments can accurately predict




Figure 5 | Performance scaling curve. The metric is the bits-per-byte on the validation set. The dotted line represents the power law fitting the smaller model (grey circles). The blue stars represent DeepSeek LLM 7B and 67B. Their performance is well-predicted by the scaling curve.

图 8: 小规模缩放曲线预测最终模型损失⁸

3.5 本章小结

“计算最优缩放”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。忽略推理生命周期、把低质量 token 当成等价数据、或把点估计当成确定结论，都会选择错误的训练规模。

4 训练预算分配

本节路线

本节依次处理：Kimi K2 用稀疏度缩放选择专家密度、Llama 3 的 isoFLOP 与下游能力缩放、近期模型的缩放律与超参数迁移配方、学习率和批大小缩放的候选自变量。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$C_{\text{total}} = C_{\text{train}} + Q C_{\text{infer}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁸视频画面时间区间：00:21:15–00:21:30。

$$G_3 = \frac{B_3}{C_3 + \lambda R_3 + \epsilon}$$

- B_3 是本节方法带来的质量、吞吐或覆盖收益。
- C_3 是新增计算、显存、通信、数据或标注成本。
- R_3 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_3 \leq C_{\max}, \quad R_3 \leq R_{\max}, \quad Q_3 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

4.1 Kimi K2 用稀疏度缩放选择专家密度

核心判断。“Kimi K2 用稀疏度缩放选择专家密度”是“训练预算分配”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 9 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“Kimi K2 用稀疏度缩放选择专家密度”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Kimi K2

Many recent papers – sparsity scaling law to find the right sparsity levels

Sparsity Scaling Law We develop a sparsity scaling law tailored for the Mixture-of-Experts (MoE) model family using Moon. Sparsity is defined as the ratio of the total number of experts to the number of activated experts. Through carefully controlled small-scale experiments, we observe that — under a fixed number of activated parameters (i.e., constant FLOPs) — increasing the total number of experts (i.e., increasing sparsity) consistently lowers both the training and validation loss, thereby enhancing overall model performance (Figure 5). Concretely, under the compute-optimal sparsity scaling law, achieving the same validation loss of 1.5, sparsity 48 reduces FLOPs by 1.69x, 1.39x, and 1.15x compared to sparsity levels 8, 16, and 32, respectively. Though increasing sparsity leads to better performance, this gain comes with increased infrastructure complexity. To balance model performance with cost, we adopt a sparsity of 48 for Kimi K2, activating 8 out of 384 experts per forward pass.




Figure 5: Sparsity Scaling Law. Increasing sparsity leads to improved model performance. We fixed the number of activated experts to 8 and the number of shared experts to 1, and varied the total number of experts, resulting in models with different sparsity levels.




Figure 6: Scaling curves for models with number of attention heads equals to number of layers and their counterparts with doubled attention heads. Doubling the number of attention heads leads to a reduction in validation loss of approximately 0.5% to 1.2%.

图 9: Kimi K2 用稀疏度缩放选择专家密度⁹

4.2 Llama 3 的 isoFLOP 与下游能力缩放

核心判断。“Llama 3 的 isoFLOP 与下游能力缩放”是“训练预算分配”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 10 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Llama 3 的 isoFLOP 与下游能力缩放”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁹视频画面时间区间：00:23:45–00:24:00。

LLaMA 3 (2024) Scaling laws




图 10: Llama 3 的 isoFLOP 与下游能力缩放¹⁰

4.3 近期模型的缩放律与超参数迁移配方

核心判断。“近期模型的缩放律与超参数迁移配方”是“训练预算分配”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 11 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“近期模型的缩放律与超参数迁移配方”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁰视频画面时间区间：00:26:30–00:26:45。

Recent scaling law recipes

DeepSeek recipe

- Assume most transformer hypers are invariant to scale
- Do a scaling analysis on batch / LR to figure out optimal scaling
- IsoFLOP analysis to figure out model sizing
 - Use a piecewise-linear schedule to make chinchilla scaling cheap.

miniCPM recipe

- Use muP to make transformer + LR invariant to scale
- Use a piecewise linear schedule to get sample for Chinchilla method 3 (curve fitting)

Recent (late 2024+) but less detailed

Qwen – Lr/batch (very few details..)

Kimi K2 – MoE scaling

LLaMA 3 / Hunyuan

- Just isoflops (no other scaling details)

Minimax

- Architecture choice / decision scaling

图 11: 近期模型的缩放律与超参数迁移配方¹¹

4.4 学习率和批大小缩放的候选自变量

核心判断。“学习率和批大小缩放的候选自变量”是“训练预算分配”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 12 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“学习率和批大小缩放的候选自变量”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹¹视频画面时间区间：00:29:00–00:29:15。

Core question – scaling rates on LR and batch

What are the right variables / functional form?

Name	Data Recipe	Model Sparsity	Learning Rate	Batch Size	Relative Error
OpenAI Law [20]	✗	✗	$3.239 \cdot 10^{-3} + -1.395 \cdot 10^{-4} \log(N)$	$2e18 \mathcal{L}^{-4.76190}$	9.51%e
Microsoft Law [2]	✗	✗	$1.3192e^{-5} N^{-0.23} D^{-0.32}$	-	9.25%e
DeepSeek Law [6]	✗	✗	$0.3188 C^{-0.1250}$	$0.2920 C^{0.3271}$	9.26%e
Porlan Law [26]	✗	✗	$3.7 N^{-0.36}$	$0.7576 N^{0.703}$	3.71%e
MiniCPM Law [18]	✗	✗	-	$\frac{2e18}{L^{0.24}}$	-
MeiTuan Law [36]	✗	✓	$\lambda \mathcal{L}^{-\alpha}$	$\lambda_B \mathcal{L}^{-\alpha_B^{-1}}$	-
Ours (Step Law)	✓	✓	$1.79 N^{-0.713} D^{0.307}$	$0.58 D^{0.571}$	0.94%e

Different views:

Critical batch: batch as a function of loss (OpenAI)

Compute power law: poly function of compute (DeepSeek)

.. Or something else?

图 12: 学习率和批大小缩放的首选自变量¹²

4.5 本章小结

“训练预算分配”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。忽略推理生命周期、把低质量 token 当成等价数据、或把点估计当成确定结论，都会选择错误的训练规模。

5 推理成本进入目标

本节路线

本节依次处理：学习率批大小损失面呈现可识别最小值、最优区域对 MoE 和数据集变化的稳健性、优化器性能随模型规模变化。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$N_{\star} = \arg \min_N L\left(N, \frac{C}{6N}\right)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹²视频画面时间区间：00:31:45–00:32:00。

$$G_4 = \frac{B_4}{C_4 + \lambda R_4 + \epsilon}$$

- B_4 是本节方法带来的质量、吞吐或覆盖收益。
- C_4 是新增计算、显存、通信、数据或标注成本。
- R_4 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_4 \leq C_{\max}, \quad R_4 \leq R_{\max}, \quad Q_4 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

5.1 学习率批大小损失面呈现可识别最小值


核心判断。“学习率批大小损失面呈现可识别最小值”是“推理成本进入目标”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 13 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“学习率批大小损失面呈现可识别最小值”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Observation 1: loss over batch/LR are convex



For pre-training losses, minimizers for LR/batch can be cleanly identified

图 13: 学习率批大小损失面呈现可识别最小值¹³

5.2 最优区域对 MoE 和数据集变化的稳健性

核心判断。“最优区域对 MoE 和数据集变化的稳健性”是“推理成本进入目标”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 14 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“最优区域对 MoE 和数据集变化的稳健性”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹³视频画面时间区间：00:34:30–00:34:45。

Observation 3 (?) robustness

Generalization to MoEs




Figure 7: Validation loss landscapes of MoE models under varying sparsity ratios (N_a/N). Left: Low sparsity ($N_a/N = 0.27$). Middle: Medium sparsity ($N_a/N = 0.58$). Right: Medium sparsity at D=8.0B. Our method consistently approximates global minima across sparsity regimes.

Generalization to other datasets




图 14: 最优区域对 MoE 和数据集变化的稳健性¹⁴

5.3 优化器性能随模型规模变化

核心判断。“优化器性能随模型规模变化”是“推理成本进入目标”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 15 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“优化器性能随模型规模变化”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁴视频画面时间区间：00:37:00–00:37:15。

Optimizers and scale



Optimization is a core part of LLMs (but also tricky, due to scale dependence!)



图 15: 优化器性能随模型规模变化¹⁵

5.4 本章小结

“推理成本进入目标”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。忽略推理生命周期、把低质量 token 当成等价数据、或把点估计当成确定结论，都会选择错误的训练规模。

6 数据质量与重复 epoch

本节路线

本节依次处理：不同优化器相对 AdamW 的速度收益、优化器与架构改动存在显著尺度依赖、不谨慎的参数化会使看似良好的缩放失效。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$D_{\text{eff}} = \sum_s q_s D_s$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁵视频画面时间区间：00:39:45–00:40:00。

$$G_5 = \frac{B_5}{C_5 + \lambda R_5 + \epsilon}$$

- B_5 是本节方法带来的质量、吞吐或覆盖收益。
- C_5 是新增计算、显存、通信、数据或标注成本。
- R_5 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_5 \leq C_{\max}, \quad R_5 \leq R_{\max}, \quad Q_5 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

6.1 不同优化器相对 AdamW 的速度收益


核心判断。“不同优化器相对 AdamW 的速度收益”是“数据质量与重复 epoch”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 16 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“不同优化器相对 AdamW 的速度收益”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Optimizers and scale



Optimization is a core part of LLMs (but also tricky, due to scale dependence!)



图 16: 不同优化器相对 AdamW 的速度收益¹⁶

6.2 优化器与架构改动存在显著尺度依赖

核心判断。“优化器与架构改动存在显著尺度依赖”是“数据质量与重复 epoch”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 17 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“优化器与架构改动存在显著尺度依赖”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁶视频画面时间区间：00:42:15–00:42:30。

Problem 2 – fairly significant scale dependence



General algorithm development note – *always* check scaling with respect to compute and chinchilla ratios. These are often major confounders to performance!

图 17: 优化器与架构改动存在显著尺度依赖¹⁷

6.3 不谨慎的参数化会使看似良好的缩放失效

核心判断。“不谨慎的参数化会使看似良好的缩放失效”是“数据质量与重复 epoch”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 18 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


常见失效模式

围绕“不谨慎的参数化会使看似良好的缩放失效”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁷视频画面时间区间：00:45:00–00:45:15。

Problem 2.5 – establishing scaling is nontrivial!

Sometimes, a good looking scaling can blow up



[From <https://oa.williamheld.com/blog/delphi/>]

Cautious AdamC + Sqrt batch-size scaling of learning rates
(Fixed with some more careful parametrization / scaling / optimizer changes)

图 18: 不谨慎的参数化会使看似良好的缩放失效¹⁸

6.4 本章小结

“数据质量与重复 epoch”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。忽略推理生命周期、把低质量 token 当成等价数据、或把点估计当成确定结论，都会选择错误的训练规模。

7 代理实验和外推

本节路线

本节依次处理：Muon 用 Newton-Schulz 近似正交化矩阵更新、Muon 从小基准到 Kimi K2 的缩放证据、最大更新参数化在深度方向保持最优区间。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$e_s = \frac{D_s^{\text{sampled}}}{D_s}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁸视频画面时间区间：00:47:45–00:48:00。

$$G_6 = \frac{B_6}{C_6 + \lambda R_6 + \epsilon}$$

- B_6 是本节方法带来的质量、吞吐或覆盖收益。
- C_6 是新增计算、显存、通信、数据或标注成本。
- R_6 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_6 \leq C_{\max}, \quad R_6 \leq R_{\max}, \quad Q_6 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

7.1 Muon 用 Newton-Schulz 近似正交化矩阵更新

核心判断。“Muon 用 Newton-Schulz 近似正交化矩阵更新”是“代理实验和外推”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 19 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“Muon 用 Newton-Schulz 近似正交化矩阵更新”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

A few slides on muon..

Muon:


Algorithm 2 Muon

Require: Learning rate η , momentum μ

```

1: Initialize  $B_0 \leftarrow 0$ 
2: for  $t = 1, \dots$  do
3:   Compute gradient  $G_t \leftarrow \nabla_{\theta} \mathcal{L}_t(\theta_{t-1})$ 
4:    $B_t \leftarrow \mu B_{t-1} + G_t$ 
5:    $O_t \leftarrow \text{NewtonSchulz5}(B_t)$ 
6:   Update parameters  $\theta_t \leftarrow \theta_{t-1} - \eta O_t$ 
7: end for
8: return  $\theta_t$ 

```



*SOAP is under active development. Future versions will significantly improve the wallclock overhead.

Optimizer for 'matrix valued' parameters.

NewtonSchulz (approximately) orthogonalizes the matrix $B_t = USV^T \rightarrow UV^T$

图 19: Muon 用 Newton-Schulz 近似正交化矩阵更新¹⁹

7.2 Muon 从小基准到 Kimi K2 的缩放证据

核心判断。“Muon 从小基准到 Kimi K2 的缩放证据”是“代理实验和外推”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 20 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Muon 从小基准到 Kimi K2 的缩放证据”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁹视频画面时间区间：00:50:15–00:50:30。

Muon and scaling



NanoGPT speedrun (very small!)

Scaling study

Kimi K2

Scaling gains are tricky to measure, but clearly muon 'works' at scale

图 20: Muon 从小基准到 Kimi K2 的缩放证据²⁰

7.3 最大更新参数化在深度方向保持最优区间

核心判断。“最大更新参数化在深度方向保持最优区间”是“代理实验和外推”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 21 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“最大更新参数化在深度方向保持最优区间”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁰视频画面时间区间：00:53:00–00:53:15。

Maximum update parametrization – in depth

Recall – the maximum update parametrization makes appealing claims




Table 2. μP function for a model M' that is r times the widths of M . If a parameter tensor has 2 dimensions that goes infinite when the model width goes infinite, it is “matrix-like” (e.g., a fully-connected hidden layer); if the number is 1 or 0, it belongs to the “others” class. Note that embedding layers are “others”. “Output” means the layer that maps an infinite dimension to a finite dimension, which is the word decoding layer (*lm.head*) in Transformers. A multiplier is a constant multiplied by a parameter tensor, which has a similar function to softmax temperature.

Hyperparameter (weight)	M	$M' \sim r$
AdamW learning rate (matrix-like)	l	l/r
AdamW learning rate (others)	l	l
Initialization variance (matrix-like)	σ	σ/r
Initialization variance (others)	σ	σ
Multiplier (output)	τ	τ/r
Multiplier (others)	τ	τ

Scale-invariant hyperparameter tuning would be very nice.

How does it work, and does it work in practice?

图 21: 最大更新参数化在深度方向保持最优区间²¹

7.4 本章小结

“代理实验和外推”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。忽略推理生命周期、把低质量 token 当成等价数据、或把点估计当成确定结论，都会选择错误的训练规模。

8 不确定性与敏感性

本节路线

本节依次处理：muP 以激活和单步变化为一阶量的条件、muP 条件 A1 的深线性网络推导、muP 条件 A2 分解权重更新和激活变化。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$\hat{L}(C) \pm z\sigma_{\hat{L}}(C)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²¹视频画面时间区间：00:58:15–00:58:30。

$$G_7 = \frac{B_7}{C_7 + \lambda R_7 + \epsilon}$$

- B_7 是本节方法带来的质量、吞吐或覆盖收益。
- C_7 是新增计算、显存、通信、数据或标注成本。
- R_7 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_7 \leq C_{\max}, \quad R_7 \leq R_{\max}, \quad Q_7 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

8.1 muP 以激活和单步变化为一阶量的条件


核心判断。“muP 以激活和单步变化为一阶量的条件”是“不确定性与敏感性”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 22 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“muP 以激活和单步变化为一阶量的条件”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

What is muP, anyway?



muP is based off the following assertion. As a function of the width of the network n_L ..

A1: The activations at initialization should remain $\Theta(1)$

A2: After one gradient step, the change in activation should be $\Theta(1)$

Note: if individual activations are $\Theta(1)$, then the norm should be $\Theta(\sqrt{n_L})$

图 22: muP 以激活和单步变化为一阶量的条件²²

8.2 muP 条件 A1 的深线性网络推导

核心判断。“muP 条件 A1 的深线性网络推导”是“不确定性与敏感性”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 23 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“muP 条件 A1 的深线性网络推导”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²²视频画面时间区间：01:00:45–01:01:00。

Deriving muP (condition A1)

Suppose that we have a simple, deep linear network ($h_l = W_l h_{l-1}$) and we init $W_l \sim N(0, \sigma^2 I_{n_l \times n_{l-1}})$ then by basic matrix concentration $\|W_l\|_* \rightarrow \sigma(\sqrt{n_{l-1}} + \sqrt{n_l})$ and,

$$\|h_l\|_2 \approx \|W_l\|_* \|h_{l-1}\|_2$$

Now let's pick $\sigma = \frac{\sqrt{n_l}}{\sqrt{n_{l-1}}} (\sqrt{n_l} + \sqrt{n_{l-1}})^{-1} = \Theta\left(\frac{1}{\sqrt{n_{l-1}}} \min\left(1, \sqrt{\frac{n_l}{n_{l-1}}}\right)\right)$. What happens?

Inductive assumption- $\|h_{l-1}\|_2 = \Theta(\sqrt{n_{l-1}})$

Inductive case - $\|W_l\|_* \rightarrow \sigma(\sqrt{n_{l-1}} + \sqrt{n_l}) = \frac{\sqrt{n_l}}{\sqrt{n_{l-1}}}$

$$\|h_l\|_2 = \sqrt{n_l} + o(\sqrt{n_l})$$



[Comments – this is a kind of ‘worst case’ derivation – the $\approx$ is an upper bound]

图 23: muP 条件 A1 的深线性网络推导²³

8.3 muP 条件 A2 分解权重更新和激活变化

核心判断。“muP 条件 A2 分解权重更新和激活变化”是“不确定性与敏感性”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 24 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“muP 条件 A2 分解权重更新和激活变化”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²³视频画面时间区间：01:03:30–01:03:45。

Deriving muP (condition A2)

Now we need to deal with updates. Suppose we have the update ΔW_l on the weights. For SGD, on a linear layer, this looks like a rank-one loss-activation outer product.

$$\Delta W_l = -\eta_l \nabla_{h_l} \ell h_{l-1}^\top$$

Thus, $\|\Delta W_l h_{l-1}\|_2 = \|\Delta W_l\|_* \|h_{l-1}\|_2$. Now note that we have the update

$$\Delta h_l = W_l \Delta h_{l-1} + \Delta W_l (h_{l-1} + \Delta h_{l-1})$$

Assuming that the leading order terms don't cancel, we see that

- $W_l \Delta h_{l-1} = \Theta(\sqrt{n_l})$ from induction assumption + condition A1 argument
- $\Delta W_l h_{l-1} = \|\Delta W_l\|_* \sqrt{n_{l-1}}$ from above, thus $\|\Delta W_l\|_* = \Theta\left(\frac{\sqrt{n_l}}{\sqrt{n_{l-1}}}\right)$
- $\Delta W_l \Delta h_{l-1} = O(\|\Delta W_l\|_* \sqrt{n_{l-1}})$



图 24: muP 条件 A2 分解权重更新和激活变化²⁴

8.4 本章小结

“不确定性与敏感性”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。忽略推理生命周期、把低质量 token 当成等价数据、或把点估计当成确定结论，都会选择错误的训练规模。

9 可执行的缩放计划

本节路线

本节依次处理：由更新范数推出宽度相关学习率、muP 初始化与学习率缩放规则总结、现代激活归一化与正则项对 muP 假设的挑战。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$\min_{N,D} C_{\text{total}} \quad \text{s.t.} \quad L(N, D) \leq L_{\text{target}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²⁴视频画面时间区间：01:06:15–01:06:30。

$$G_8 = \frac{B_8}{C_8 + \lambda R_8 + \epsilon}$$

- B_8 是本节方法带来的质量、吞吐或覆盖收益。
- C_8 是新增计算、显存、通信、数据或标注成本。
- R_8 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_8 \leq C_{\max}, \quad R_8 \leq R_{\max}, \quad Q_8 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

9.1 由更新范数推出宽度相关学习率

核心判断。“由更新范数推出宽度相关学习率”是“可执行的缩放计划”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 25 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“由更新范数推出宽度相关学习率”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Deriving muP (condition A2) part 2

Recall –the key is to pick LR such that $\|\Delta W_t\|_* \sqrt{n_{t-1}} = \Theta(\sqrt{n_t})$. How can we do that?

Suppose that the loss update *also* scales $O(1)$. Then we can write down..

$$\Delta \ell \approx \Theta(\langle \Delta W_t, \nabla_{W_t} \ell \rangle) = \Theta(\|\Delta W_t\|_F \|\nabla_{W_t} \ell\|_F) = \Theta(\|\Delta W_t\|_* \|\nabla_{W_t} \ell\|_*)$$

Where we use the fact that $\Delta W_t = -\eta \nabla_{W_t} \ell$ in standard SGD updates.

Now plug in $\Delta \ell = O(1)$, $\|\Delta W_t\|_* = \Theta\left(\frac{\sqrt{n_t}}{\sqrt{n_{t-1}}}\right)$ to get that $\|\nabla_{W_t} \ell\|_* = \Theta\left(\frac{\sqrt{n_{t-1}}}{\sqrt{n_t}}\right)$

Finally, from the previous slide, recall that $\Delta W_t = -\eta_t \nabla_{h_t} \ell h_{t-1}^\top$ and thus

$$\eta_t = \Theta\left(\frac{n_t}{n_{t-1}}\right)$$

[with Adam, $\|\Delta W_t\|_* \sqrt{n_{t-1}} = \Theta(\sqrt{n_t})$]

图 25: 由更新范数推出宽度相关学习率²⁵

9.2 muP 初始化与学习率缩放规则总结

核心判断。“muP 初始化与学习率缩放规则总结”是“可执行的缩放计划”中的一个可检验设计选择，而不是只需记忆的产品名。在 log 空间拟合之前先固定训练配方和数据分布，并保留所有运行而非只取最好点；外推时报告参数不确定性和目标区间。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 26 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“muP 初始化与学习率缩放规则总结”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁵视频画面时间区间：01:08:45–01:09:00。

muP mini recap..

So, what is (baby) muP about? Controlling activations (and changes) via W and ΔW

Initialization (stdev): Set to $\Theta\left(\frac{1}{\sqrt{n_{l-1}}} \min\left(1, \sqrt{\frac{n_l}{n_{l-1}}}\right)\right)$

Learning rates: Set to $\frac{n_l}{n_{l-1}}$ (for Adam $\frac{1}{n_{l-1}}$)

Compared to 'standard' parametrizations – these set

Initialization: Set to $\frac{1}{\sqrt{n_{l-1}}}$

Learning rates: Set to $\Theta(1)$

Differences – LR changes for Adam, also init diffs when fanout $n_l < \text{fanin}$

图 26: muP 初始化与学习率缩放规则总结²⁶

9.3 现代激活归一化与正则项对 muP 假设的挑战

核心判断。“现代激活归一化与正则项对 muP 假设的挑战”是“可执行的缩放计划”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 27 个图像证据在本讲 27 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“现代激活归一化与正则项对 muP 假设的挑战”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁶视频画面时间区间：01:11:30–01:11:45。

What is muP robust to?

Modern LMs have many components that deviate from muP's theory

- Activations – SwiGLU and squared relu
- Batch sizes – Large / small
- Initialization variations – zero attention, etc.
- RMS norm gains
- Exotic optimizers (Lion)
- Regularizers

Which of these (if any) break muP?



图 27: 现代激活归一化与正则项对 muP 假设的挑战²⁷

9.4 本章小结

“可执行的缩放计划”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。忽略推理生命周期、把低质量 token 当成等价数据、或把点估计当成确定结论，都会选择错误的训练规模。

10 代码化复现：最小机制

下面的片段保留本讲最核心的程序结构，用于把公式和系统过程落到可执行对象。它不是生产实现；实际复现还需补充张量形状断言、数值精度、同步、随机种子、数据版本和端到端测试。

Listing 1: Lecture 11 机制伪代码

```
1 def total_cost(N, D, queries, generated_tokens):
2     train = 6 * N * D
3     inference = queries * generated_tokens * 2 * N
4     return train + inference
```

复现检查单

先写正确性基线，再记录资源基线；每次只改变一个机制；同时保存直接中间量和最终指标；对随机算法报告多次运行；对数据与评测保存不可变版本标识。

²⁷视频画面时间区间：01:14:00–01:14:15。

10.1 本章小结

代码的价值在于暴露状态、顺序和边界。若一个概念无法写成输入、变换、状态、输出和断言，它通常还没有被真正理解。

11 总结与延伸

一页压缩

本讲的主问题是：当训练和部署成本同时存在时，怎样把经验缩放曲线变成可执行的模型、数据和 token 预算决策？统一答案是：第二讲缩放律强调决策层：拟合只是中间步骤，最终要把训练 FLOPs、推理次数、数据上限和误差条放在同一目标中。

第一，优先理解机制而不是产品名。模型、硬件、数据和评测不断更新，但张量形状、状态位置、目标函数、通信边界和测量误差仍然是稳定的分析对象。第二，所有优化都要写出代价守恒：减少某一种成本通常会增加另一种成本或风险。第三，把小规模实验推广到大规模之前，必须检查瓶颈是否改变、数据分布是否改变、实现常数是否仍在同一数量级。第四，最可靠的课程笔记应允许读者沿时间脚注回到原视频，并沿官方材料找到公式或代码出处。

开放问题

忽略推理生命周期、把低质量 token 当成等价数据、或把点估计当成确定结论，都会选择错误的训练规模。后续实验应把这一风险写成可观测量和停止条件，而不是留在讨论部分。

11.1 本章小结

完成本讲后，读者应能用统一语言解释每个主题的输入、状态、变换、输出、资源成本和失败模式，并据此设计一个含基线、消融、误差条和证据记录的最小实验。

12 资料来源与审计边界

- 课程主页：<https://cs336.stanford.edu/>。
- 视频：<https://www.youtube.com/watch?v=vTfEyOyzV9E>。
- Stanford 官方材料：lecture_11.pdf；客座讲座若无官方文件则以视频和字幕为主。
- 本地证据：audio.srt、figure_manifest.tsv、figure_verification.txt、teaching_atoms.tsv、numerical_claims.tsv。

12.1 本章小结

本笔记覆盖播放列表中的本讲内容与课程主页当日可取得的官方材料。没有官方讲义的客座讲座不会被伪装成有讲义；讲者口头推测、本笔记分析框架和官方公式在文字中分别标明。