


Lecture 13: Data Sources and Datasets

Spring 2026 中文精讲笔记

主讲: Percy Liang



频道: Stanford Online

发布日期: 2026-05-19

时长: 1:22:01

视频: <https://www.youtube.com/watch?v=-qm0ln33G24>

官方主页: <https://cs336.stanford.edu/>

目录

1	导读：问题、证据与阅读方法	2
2	训练数据阶段与来源	2
3	网页爬取的技术边界	7
4	版权许可和合理使用	12
5	爬虫工程与动态网页	16
6	Wikipedia arXiv 与代码	20
7	Common Crawl 清洗谱系	24
8	书籍代码和混合数据集	28
9	许可数据与开放问题	32
10	代码化复现：最小机制	36
11	总结与延伸	37
12	资料来源与审计边界	37

1 导读：问题、证据与阅读方法

本讲主问题

预训练数据究竟来自哪里，采集者怎样在规模、质量、版权、服务条款和可复现性之间做选择？

数据集是从活网页到快照、解析文本、过滤去重和混合的长流水线；每个阶段都改变最终训练分布。本笔记以课程视频、人工字幕和 Stanford 官方讲义或代码为共同证据源。图像均来自每十五秒抽帧后的人工接触表审查，时间脚注可回到原视频复核；公式区分课程机制关系和本笔记的决策分析框架。学习时建议先读主问题，再沿“机制-资源-失败模式-验证指标”四列整理自己的实验。

首先排除的误读

公开可访问不等于可自由复制，高质量来源也可能被投毒；只发布数据名称而不发布处理版本无法复现实验。

1.1 关键数字核对

主张	数值或关系	视频时间
Wikipedia 语言版本	约 361	00:37:00
Wikipedia 文章总数	约 67M	00:37:00
arXiv 提交量	约 3M	00:42:00
C4 最终文本	约 806GB	00:51:00
C4 token 数	约 156B	00:51:00
GPT-3 数据规模	约 570GB / 400B tokens	00:54:00
The Stack 结果	约 3.1TB code	01:13:00

1.2 本章小结

本章建立证据边界：视频解释提供因果和强调，官方材料提供公式与代码，精选帧提供可核查的视觉状态。后文每个主题都同时回答“为何重要、怎样工作、怎样失败、怎样验证”，避免把课程压缩成术语目录。

2 训练数据阶段与来源

本节路线

本节依次处理：预训练中训练与后训练数据的质量规模梯度、网络爬虫从种子 URL 发现并下载网页、动态内容认证和反机器人机制限制采集、robots 和服务条款限制随时间增加。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$D_{\text{raw}} = \bigcup_{u \in U} \text{fetch}(u)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。

- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_1 = \frac{B_1}{C_1 + \lambda R_1 + \varepsilon}$$

- B_1 是本节方法带来的质量、吞吐或覆盖收益。
- C_1 是新增计算、显存、通信、数据或标注成本。
- R_1 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_1 \leq C_{\max}, \quad R_1 \leq R_{\max}, \quad Q_1 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

2.1 预训练中训练与后训练数据的质量规模梯度

核心判断。“预训练中训练与后训练数据的质量规模梯度”是“训练数据阶段与来源”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 1 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“预训练中训练与后训练数据的质量规模梯度”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

In practice, the lines are blurry and there could be more stages
 ...but the basic trend is throughout training, we go from
 large amounts of lower quality data to
 small amounts of high quality data.

Terminology:

- Base model: after pre-training + mid-training
- Instruct/chat model: after post-training

(Increasingly, base models are not released - e.g., Qwen3.5-397B-A17B is an instruct model.)

Example (OLMo from AI2) [Team OLMo 2024]

1. Pre-training

Source	Type	Tokens	Words	Bytes	Docs
Pretraining + OLMo 2 1124 Mix					
DCLM-Baseline	Web pages	3.71T	3.32T	21.32T	2.95B
StarCoder filtered version from OLMo-E Mix	Code	83.0B	70.0B	459B	78.7M
peS2o from Dolma 1.7	Academic papers	58.6B	51.1B	413B	38.8M
arXiv	STEM papers	20.8B	19.3B	77.2B	3.95M

图 1: 预训练中训练与后训练数据的质量规模梯度¹

2.2 网络爬虫从种子 URL 发现并下载网页

核心判断。“网络爬虫从种子 URL 发现并下载网页”是“训练数据阶段与来源”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 2 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“网络爬虫从种子 URL 发现并下载网页”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹视频画面时间区间：00:02:45–00:03:00。




图 2: 网络爬虫从种子 URL 发现并下载网页²

2.3 动态内容认证和反机器人机制限制采集

核心判断。“动态内容认证和反机器人机制限制采集”是“训练数据阶段与来源”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 3 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“动态内容认证和反机器人机制限制采集”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²视频画面时间区间：00:05:45–00:06:00。




图 3: 动态内容认证和反机器人机制限制采集³

2.4 robots 和服务条款限制随时间增加

核心判断。“robots 和服务条款限制随时间增加”是“训练数据阶段与来源”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 4 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“robots 和服务条款限制随时间增加”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

³视频画面时间区间：00:08:30–00:08:45。




图 4: robots 和服务条款限制随时间增加⁴

2.5 本章小结

“训练数据阶段与来源”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。公开可访问不等于可自由复制，高质量来源也可能被投毒；只发布数据名称而不发布处理版本无法复现实验。

3 网页爬取的技术边界

本节路线

本节依次处理：互联网数据获取同时受技术与法律约束、版权保护表达而非抽象思想、许可证是权利人授予使用条件的合同、合理使用的目的性质数量和市场四因素。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$U_{t+1} = U_t \cup \text{links}(\text{fetch}(U_t))$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁴视频画面时间区间：00:11:15–00:11:30。

$$G_2 = \frac{B_2}{C_2 + \lambda R_2 + \epsilon}$$

- B_2 是本节方法带来的质量、吞吐或覆盖收益。
- C_2 是新增计算、显存、通信、数据或标注成本。
- R_2 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_2 \leq C_{\max}, \quad R_2 \leq R_{\max}, \quad Q_2 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

3.1 互联网数据获取同时受技术与法律约束

核心判断。“互联网数据获取同时受技术与法律约束”是“网页爬取的技术边界”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 5 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“互联网数据获取同时受技术与法律约束”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 5: 互联网数据获取同时受技术与法律约束⁵

3.2 版权保护表达而非抽象思想

核心判断。“版权保护表达而非抽象思想”是“网页爬取的技术边界”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 6 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“版权保护表达而非抽象思想”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁵视频画面时间区间：00:14:00–00:14:15。




图 6: 版权保护表达而非抽象思想⁶

3.3 许可证是权利人授予使用条件的合同

核心判断。“许可证是权利人授予使用条件的合同”是“网页爬取的技术边界”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 7 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“许可证是权利人授予使用条件的合同”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁶视频画面时间区间：00:17:00–00:17:15。




图 7: 许可证是权利人授予使用条件的合同⁷

3.4 合理使用的目的性质数量和市场四因素

核心判断。“合理使用的目的性质数量和市场四因素”是“网页爬取的技术边界”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 8 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“合理使用的目的性质数量和市场四因素”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁷视频画面时间区间：00:19:45–00:20:00。




图 8: 合理使用的目的性质数量和市场四因素⁸

3.5 本章小结

“网页爬取的技术边界”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。公开可访问不等于可自由复制，高质量来源也可能被投毒；只发布数据名称而不发布处理版本无法复现实验。

4 版权许可和合理使用

本节路线

本节依次处理：摘要重实现与模仿作品的合理使用边界、模型训练相关诉讼体现复制与市场争议、调度器队列下载器与存储构成爬虫流水线。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$D_{\text{kept}} = \{x \in D : s(x) \geq \tau\}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁸视频画面时间区间：00:22:30–00:22:45。

$$G_3 = \frac{B_3}{C_3 + \lambda R_3 + \epsilon}$$

- B_3 是本节方法带来的质量、吞吐或覆盖收益。
- C_3 是新增计算、显存、通信、数据或标注成本。
- R_3 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_3 \leq C_{\max}, \quad R_3 \leq R_{\max}, \quad Q_3 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

4.1 摘要重实现与模仿作品的合理使用边界

核心判断。“摘要重实现与模仿作品的合理使用边界”是“版权许可和合理使用”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 9 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“摘要重实现与模仿作品的合理使用边界”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 9: 摘要重实现与模仿作品的合理使用边界⁹

4.2 模型训练相关诉讼体现复制与市场争议

核心判断。“模型训练相关诉讼体现复制与市场争议”是“版权许可和合理使用”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 10 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“模型训练相关诉讼体现复制与市场争议”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁹视频画面时间区间：00:25:15–00:25:30。




图 10: 模型训练相关诉讼体现复制与市场争议¹⁰

4.3 调度器队列下载器与存储构成爬虫流水线

核心判断。“调度器队列下载器与存储构成爬虫流水线”是“版权许可和合理使用”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 11 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“调度器队列下载器与存储构成爬虫流水线”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁰视频画面时间区间：00:28:15–00:28:30。




图 11: 调度器队列下载器与存储构成爬虫流水线¹¹

4.4 本章小结

“版权许可和合理使用”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。公开可访问不等于可自由复制，高质量来源也可能被投毒；只发布数据名称而不发布处理版本无法复现实验。

5 爬虫工程与动态网页

本节路线

本节依次处理：Wikipedia 的百科范围和非原创内容政策、协作编辑带来高质量也带来投毒风险、arXiv 与 Software Heritage 提供论文和代码。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$p_s = \frac{w_s D_s}{\sum_j w_j D_j}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹¹视频画面时间区间：00:33:45–00:34:00。

$$G_4 = \frac{B_4}{C_4 + \lambda R_4 + \epsilon}$$

- B_4 是本节方法带来的质量、吞吐或覆盖收益。
- C_4 是新增计算、显存、通信、数据或标注成本。
- R_4 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_4 \leq C_{\max}, \quad R_4 \leq R_{\max}, \quad Q_4 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

5.1 Wikipedia 的百科范围和非原创内容政策

核心判断。“Wikipedia 的百科范围和非原创内容政策”是“爬虫工程与动态网页”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 12 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“Wikipedia 的百科范围和非原创内容政策”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 12: Wikipedia 的百科范围和非原创内容政策¹²

5.2 协作编辑带来高质量也带来投毒风险

核心判断。“协作编辑带来高质量也带来投毒风险”是“爬虫工程与动态网页”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 13 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“协作编辑带来高质量也带来投毒风险”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹²视频画面时间区间：00:36:45–00:37:00。




图 13: 协作编辑带来高质量也带来投毒风险¹³

5.3 arXiv 与 Software Heritage 提供论文和代码

核心判断。“arXiv 与 Software Heritage 提供论文和代码”是“爬虫工程与动态网页”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 14 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“arXiv 与 Software Heritage 提供论文和代码”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹³视频画面时间区间：00:39:30–00:39:45。




图 14: arXiv 与 Software Heritage 提供论文和代码¹⁴

5.4 本章小结

“爬虫工程与动态网页”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。公开可访问不等于可自由复制，高质量来源也可能被投毒；只发布数据名称而不发布处理版本无法复现实验。

6 Wikipedia arXiv 与代码

本节路线

本节依次处理：CCNet 用规则语言识别和质量过滤 Common Crawl、C4 以规则清洗 Common Crawl 并去除低质量页、GPT-3 混合 WebText 书籍 Wikipedia 与 Common Crawl。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$D_{\text{eff}} = \sum_s q_s D_s$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁴视频画面时间区间：00:42:15–00:42:30。

$$G_5 = \frac{B_5}{C_5 + \lambda R_5 + \epsilon}$$

- B_5 是本节方法带来的质量、吞吐或覆盖收益。
- C_5 是新增计算、显存、通信、数据或标注成本。
- R_5 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_5 \leq C_{\max}, \quad R_5 \leq R_{\max}, \quad Q_5 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

6.1 CCNet 用规则语言识别和质量过滤 Common Crawl

核心判断。“CCNet 用规则语言识别和质量过滤 Common Crawl”是“Wikipedia arXiv 与代码”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 15 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“CCNet 用规则语言识别和质量过滤 Common Crawl”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 15: CCNet 用规则语言识别和质量过滤 Common Crawl¹⁵

6.2 C4 以规则清洗 Common Crawl 并去除低质量页

核心判断。“C4 以规则清洗 Common Crawl 并去除低质量页”是“Wikipedia arXiv 与代码”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 16 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“C4 以规则清洗 Common Crawl 并去除低质量页”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁵视频画面时间区间：00:48:00–00:48:15。

```
379 def t5_c4():
380     Colossal Clean Crawled corpus (C4) [Raffel+ 2019]
381
382     Paper is more famous for Text-to-text Transfer Transformer (T5), which pushes the idea of putting all NLP tas
    into one format
383     ...but a major contribution was the C4 dataset.
384
385     Observation: Common Crawl is mostly not useful natural language
386
387     Started with one snapshot (April 2019) of Common Crawl (1.4 trillion tokens)
388
389     Manual heuristics:
390     • Keep lines that end in punctuation and have >= 5 words
391     • Remove page with fewer than 3 sentences
392     • Removed page that contains any 'bad words' [article]
393     • Removed page containing 'I' (no code), 'lorem ipsum', 'terms of use', etc.
394     • Filter out non-English text using langdetect (English with probability 0.99)
395
396     End result: 806 GB of text (156 billion tokens)
```

图 16: C4 以规则清洗 Common Crawl 并去除低质量页¹⁶

6.3 GPT-3 混合 WebText 书籍 Wikipedia 与 Common Crawl

核心判断。“GPT-3 混合 WebText 书籍 Wikipedia 与 Common Crawl”是“Wikipedia arXiv 与代码”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 17 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“GPT-3 混合 WebText 书籍 Wikipedia 与 Common Crawl”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁶视频画面时间区间：00:50:45–00:51:00。




图 17: GPT-3 混合 WebText 书籍 Wikipedia 与 Common Crawl¹⁷

6.4 本章小结

“Wikipedia arXiv 与代码”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。公开可访问不等于可自由复制，高质量来源也可能被投毒；只发布数据名称而不发布处理版本无法复现实验。

7 Common Crawl 清洗谱系

本节路线

本节依次处理：Books3 等书籍语料的规模和版权争议、MassiveText 对多来源数据进行质量过滤和去重、RefinedWeb 展示只用网页也能构造大规模语料。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$e_s = \frac{D_s^{\text{sampled}}}{D_s}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁷视频画面时间区间：00:53:30–00:53:45。

$$G_6 = \frac{B_6}{C_6 + \lambda R_6 + \epsilon}$$

- B_6 是本节方法带来的质量、吞吐或覆盖收益。
- C_6 是新增计算、显存、通信、数据或标注成本。
- R_6 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_6 \leq C_{\max}, \quad R_6 \leq R_{\max}, \quad Q_6 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

7.1 Books3 等书籍语料的规模和版权争议

核心判断。“Books3 等书籍语料的规模和版权争议”是“Common Crawl 清洗谱系”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 18 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“Books3 等书籍语料的规模和版权争议”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 18: Books3 等书籍语料的规模和版权争议¹⁸

7.2 MassiveText 对多来源数据进行质量过滤和去重

核心判断。“MassiveText 对多来源数据进行质量过滤和去重”是“Common Crawl 清洗谱系”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 19 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“MassiveText 对多来源数据进行质量过滤和去重”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁸视频画面时间区间：00:56:30–00:56:45。




图 19: MassiveText 对多来源数据进行质量过滤和去重¹⁹

7.3 RefinedWeb 展示只用网页也能构造大规模语料

核心判断。“RefinedWeb 展示只用网页也能构造大规模语料”是“Common Crawl 清洗谱系”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 20 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“RefinedWeb 展示只用网页也能构造大规模语料”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁹视频画面时间区间：00:59:15–00:59:30。




图 20: RefinedWeb 展示只用网页也能构造大规模语料²⁰

7.4 本章小结

“Common Crawl 清洗谱系”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。公开可访问不等于可自由复制，高质量来源也可能被投毒；只发布数据名称而不发布处理版本无法复现实验。

8 书籍代码和混合数据集

本节路线

本节依次处理：DCLM 建立可比较的数据处理竞赛基线、Nemotron-CC 用模型分类器筛选教育价值、主流预训练数据集的来源与方法谱系。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$\text{coverage} = \frac{|\text{unique documents}|}{|\text{downloaded documents}|}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²⁰视频画面时间区间：01:02:00–01:02:15。

$$G_7 = \frac{B_7}{C_7 + \lambda R_7 + \epsilon}$$

- B_7 是本节方法带来的质量、吞吐或覆盖收益。
- C_7 是新增计算、显存、通信、数据或标注成本。
- R_7 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_7 \leq C_{\max}, \quad R_7 \leq R_{\max}, \quad Q_7 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

8.1 DCLM 建立可比较的数据处理竞赛基线

核心判断。“DCLM 建立可比较的数据处理竞赛基线”是“书籍代码和混合数据集”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 21 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“DCLM 建立可比较的数据处理竞赛基线”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 21: DCLM 建立可比较的数据处理竞赛基线²¹

8.2 Nemotron-CC 用模型分类器筛选教育价值

核心判断。“Nemotron-CC 用模型分类器筛选教育价值”是“书籍代码和混合数据集”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 22 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Nemotron-CC 用模型分类器筛选教育价值”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²¹视频画面时间区间：01:04:45–01:05:00。

	Classifier on BGE features [185]	27.2	14.0
	AskLLM [146]	28.6	14.3
	Perplexity filtering	29.0	15.0
	Top-k average logits	29.2	14.7
	fastText [87] OH-2.5 +ELI5	30.2	15.4


```

558
559 def nemotron_cc():
560     Nemotron-CC [Su+ 2024]
561     • FineWebEdu and DCLM filter too aggressively (remove 90% of data)
562     • Need moar tokens (but preserve quality)
563     • For HTML → text, used jusText (not trafilatura) because it returned more tokens
564
565     Classifier ensembling
566     • Prompt Nemotron-340B-instruct to score FineWeb documents based on educational value, distill into fast
567       model
568     • DCLM classifier
569
570     Synthetic data rephrasing
571     • For low-quality data, use LM to rephrase
572     • For high-quality data, use LM to generate tasks (QA pairs, extract key information, etc.)

```

图 22: Nemotron-CC 用模型分类器筛选教育价值²²

8.3 主流预训练数据集的来源与方法谱系

核心判断。“主流预训练数据集的来源与方法谱系”是“书籍代码和混合数据集”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 23 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“主流预训练数据集的来源与方法谱系”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²²视频画面时间区间：01:07:45–01:08:00。




图 23: 主流预训练数据集的来源与方法谱系²³

8.4 本章小结

“书籍代码和混合数据集”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。公开可访问不等于可自由复制，高质量来源也可能被投毒；只发布数据名称而不发布处理版本无法复现实验。

9 许可数据与开放问题

本节路线

本节依次处理：The Stack 汇总代码仓库并处理许可证、Common Pile 探索许可友好的大规模数据、许可数据训练模型的基准表现与规模代价。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$\text{risk}(D) = R_{\text{copyright}} + R_{\text{privacy}} + R_{\text{poisoning}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²³视频画面时间区间：01:10:30–01:10:45。

$$G_8 = \frac{B_8}{C_8 + \lambda R_8 + \epsilon}$$

- B_8 是本节方法带来的质量、吞吐或覆盖收益。
- C_8 是新增计算、显存、通信、数据或标注成本。
- R_8 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_8 \leq C_{\max}, \quad R_8 \leq R_{\max}, \quad Q_8 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

9.1 The Stack 汇总代码仓库并处理许可证

核心判断。“The Stack 汇总代码仓库并处理许可证”是“许可数据与开放问题”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 24 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“The Stack 汇总代码仓库并处理许可证”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 24: The Stack 汇总代码仓库并处理许可证²⁴

9.2 Common Pile 探索许可友好的大规模数据

核心判断。“Common Pile 探索许可友好的大规模数据”是“许可数据与开放问题”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 25 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Common Pile 探索许可友好的大规模数据”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁴视频画面时间区间：01:13:15–01:13:30。




图 25: Common Pile 探索许可友好的大规模数据²⁵

9.3 许可数据训练模型的基准表现与规模代价

核心判断。“许可数据训练模型的基准表现与规模代价”是“许可数据与开放问题”中的一个可检验设计选择，而不是只需记忆的产品名。先定义样本分布和唯一打分规则，再检查长度归一化、提示敏感性、裁判偏差与置信区间；公开测试集还要做污染和重复样本审计。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 26 个图像证据在本讲 26 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


常见失效模式

围绕“许可数据训练模型的基准表现与规模代价”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁵视频画面时间区间：01:16:00–01:16:15。

Subtleties:

- License laundering: redistribute copyrighted work under permissive license (hard to detect)
- Collection licenses (Dolma is ODC-By) doesn't extend to individual
- Synthetic data from LMs trained on unlicensed data is unclear



• Can do decently, but tough to compete without more tokens

```
if __name__ == "__main__":  
    main()
```

图 26: 许可数据训练模型的基准表现与规模代价²⁶

9.4 本章小结

“许可数据与开放问题”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。公开可访问不等于可自由复制，高质量来源也可能被投毒；只发布数据名称而不发布处理版本无法复现实验。

10 代码化复现：最小机制

下面的片段保留本讲最核心的程序结构，用于把公式和系统过程落到可执行对象。它不是生产实现；实际复现还需补充张量形状断言、数值精度、同步、随机种子、数据版本和端到端测试。

Listing 1: Lecture 13 机制伪代码

```
1 def crawl(seed_urls):  
2     queue, seen = deque(seed_urls), set()  
3     while queue:  
4         url = queue.popleft()  
5         if url in seen or not allowed_by_policy(url):  
6             continue  
7         html = fetch(url); seen.add(url)  
8         store(url, html)  
9         queue.extend(extract_links(html))
```

²⁶视频画面时间区间：01:19:00–01:19:15。

复现检查单

先写正确性基线，再记录资源基线；每次只改变一个机制；同时保存直接中间量和最终指标；对随机算法报告多次运行；对数据与评测保存不可变版本标识。

10.1 本章小结

代码的价值在于暴露状态、顺序和边界。若一个概念无法写成输入、变换、状态、输出和断言，它通常还没有被真正理解。

11 总结与延伸

一页压缩

本讲的主问题是：预训练数据究竟来自哪里，采集者怎样在规模、质量、版权、服务条款和可复现性之间做选择？统一答案是：数据集是从活网页到快照、解析文本、过滤去重和混合的长流水线；每个阶段都改变最终训练分布。

第一，优先理解机制而不是产品名。模型、硬件、数据和评测不断更新，但张量形状、状态位置、目标函数、通信边界和测量误差仍然是稳定的分析对象。第二，所有优化都要写出代价守恒：减少某一种成本通常会增加另一种成本或风险。第三，把小规模实验推广到大规模之前，必须检查瓶颈是否改变、数据分布是否改变、实现常数是否仍在同一数量级。第四，最可靠的课程笔记应允许读者沿时间轴注回到原视频，并沿官方材料找到公式或代码出处。

开放问题

公开可访问不等于可自由复制，高质量来源也可能被投毒；只发布数据名称而不发布处理版本无法复现实验。后续实验应把这一风险写成可观测量和停止条件，而不是留在讨论部分。

11.1 本章小结

完成本讲后，读者应能用统一语言解释每个主题的输入、状态、变换、输出、资源成本和失败模式，并据此设计一个含基线、消融、误差条和证据记录的最小实验。

12 资料来源与审计边界

- 课程主页：<https://cs336.stanford.edu/>。
- 视频：<https://www.youtube.com/watch?v=-qm0ln33G24>。
- Stanford 官方材料：lecture_13.py；客座讲座若无官方文件则以视频和字幕为主。
- 本地证据：audio.srt、figure_manifest.tsv、figure_verification.txt、teaching_atoms.tsv、numerical_claims.tsv。

12.1 本章小结

本笔记覆盖播放列表中的本讲内容与课程主页当日可取得的官方材料。没有官方讲义的客座讲座不会被伪装成有讲义；讲者口头推测、本笔记分析框架和官方公式在文字中分别标明。