


Stanford CS336: Language Modeling from Scratch

Lecture 14: Data Filtering, Deduplication, Mixing, and Synthetic Data

Spring 2026 中文精讲笔记

主讲: Percy Liang



频道: Stanford Online

发布日期: 2026-05-27

时长: 1:24:46

视频: <https://www.youtube.com/watch?v=5sxHosTLPf8>

官方主页: <https://cs336.stanford.edu/>

目录

1	导读：问题、证据与阅读方法	2
2	原始内容转换为文本	2
3	语言质量与安全过滤	7
4	精确去重和哈希	11
5	Jaccard 与 MinHash	15
6	局部敏感哈希	19
7	数据混合和 epoching	23
8	回归驱动的混合优化	27
9	合成数据与可执行验证	31
10	代码化复现：最小机制	35
11	总结与延伸	36
12	资料来源与审计边界	36

1 导读：问题、证据与阅读方法

本讲主问题

怎样把抓取到的异构内容加工为可训练语料，并用过滤、去重、混合和合成数据提高每个 token 的价值？

数据处理算法既决定质量也决定分布；过滤器、去重阈值和采样权重必须作为模型配方的一部分记录。本笔记以课程视频、人工字幕和 Stanford 官方讲义或代码为共同证据源。图像均来自每十五秒抽帧后的人工接触表审查，时间脚注可回到原视频复核；公式区分课程机制关系和本笔记的决策分析框架。学习时建议先读主问题，再沿“机制-资源-失败模式-验证指标”四列整理自己的实验。

首先排除的误读

过强过滤会缩窄覆盖，过强去重会删掉合法模板，过采样稀缺源会导致 epoching 和记忆，合成数据还可能放大教师偏差。

1.1 关键数字核对

主张	数值或关系	视频时间
示例 MinHash 数量	$n=12$	00:41:00
示例 LSH bands	$b=3$	00:41:00
每个 band 的 rows	$r=4$	00:41:00
指令分类示例上限	约 100K prompts	00:14:00
SWE-smith 代码仓库数	128	01:19:00
SWE-smith 任务数	约 50K	01:19:00

1.2 本章小结

本章建立证据边界：视频解释提供因果和强调，官方材料提供公式与代码，精选帧提供可核查的视觉状态。后文每个主题都同时回答“为何重要、怎样工作、怎样失败、怎样验证”，避免把课程压缩成术语目录。

2 原始内容转换为文本

本节路线

本节依次处理：HTML 转文本需要去导航广告并保留主体、OCR 把扫描 PDF 和图像文档转为文本、过滤器从目标分布学习质量和安全边界、语言识别结合快速分类器与离线词典。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$D_{\text{text}} = \text{parse}(D_{\text{raw}})$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。

- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_1 = \frac{B_1}{C_1 + \lambda R_1 + \varepsilon}$$

- B_1 是本节方法带来的质量、吞吐或覆盖收益。
- C_1 是新增计算、显存、通信、数据或标注成本。
- R_1 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_1 \leq C_{\max}, \quad R_1 \leq R_{\max}, \quad Q_1 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

2.1 HTML 转文本需要去导航广告并保留主体

核心判断。“HTML 转文本需要去导航广告并保留主体”是“原始内容转换为文本”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 1 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“HTML 转文本需要去导航广告并保留主体”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 3: 过滤器从目标分布学习质量和安全边界³

2.4 语言识别结合快速分类器与离线词典

核心判断。“语言识别结合快速分类器与离线词典”是“原始内容转换为文本”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 4 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“语言识别结合快速分类器与离线词典”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

³视频画面时间区间：00:08:45–00:09:00。




图 4: 语言识别结合快速分类器与离线词典⁴

2.5 本章小结

“原始内容转换为文本”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。过强过滤会缩窄覆盖，过强去重会删掉合法模板，过采样稀缺源会导致 epoching 和记忆，合成数据还可能放大教师偏差。

3 语言质量与安全过滤

本节路线

本节依次处理：规则与线性模型筛选高质量网页、毒性分类与安全过滤存在尺度效应、精确重复和近似重复需要不同算法。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$D_{\text{keep}} = \{x : s_{\text{quality}}(x) \geq \tau_q, s_{\text{tox}}(x) \leq \tau_t\}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁴视频画面时间区间：00:11:45–00:12:00。

$$G_2 = \frac{B_2}{C_2 + \lambda R_2 + \epsilon}$$

- B_2 是本节方法带来的质量、吞吐或覆盖收益。
- C_2 是新增计算、显存、通信、数据或标注成本。
- R_2 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_2 \leq C_{\max}, \quad R_2 \leq R_{\max}, \quad Q_2 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

3.1 规则与线性模型筛选高质量网页

核心判断。“规则与线性模型筛选高质量网页”是“语言质量与安全过滤”中的一个可检验设计选择，而不是只需记忆的产品名。把可访问性、服务条款、版权许可和技术抓取分开记录；数据版本必须包含快照时间、URL 来源、解析器和删除策略。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 5 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“规则与线性模型筛选高质量网页”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 5: 规则与线性模型筛选高质量网页⁵

3.2 毒性分类与安全过滤存在尺度效应

核心判断。“毒性分类与安全过滤存在尺度效应”是“语言质量与安全过滤”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 6 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“毒性分类与安全过滤存在尺度效应”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁵视频画面时间区间：00:14:30–00:14:45。




图 6: 毒性分类与安全过滤存在尺度效应⁶

3.3 精确重复和近似重复需要不同算法

核心判断。“精确重复和近似重复需要不同算法”是“语言质量与安全过滤”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 7 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“精确重复和近似重复需要不同算法”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁶视频画面时间区间：00:17:30–00:17:45。




图 7: 精确重复和近似重复需要不同算法⁷

3.4 本章小结

“语言质量与安全过滤”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。过强过滤会缩窄覆盖，过强去重会删掉合法模板，过采样稀缺源会导致 epoching 和记忆，合成数据还可能放大教师偏差。

4 精确去重和哈希

本节路线

本节依次处理：去重提高训练效率并降低记忆风险、哈希函数在效率和碰撞风险间权衡、Jaccard 相似度比较集合交并比。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁷视频画面时间区间：00:23:15–00:23:30。

$$G_3 = \frac{B_3}{C_3 + \lambda R_3 + \epsilon}$$

- B_3 是本节方法带来的质量、吞吐或覆盖收益。
- C_3 是新增计算、显存、通信、数据或标注成本。
- R_3 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_3 \leq C_{\max}, \quad R_3 \leq R_{\max}, \quad Q_3 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

4.1 去重提高训练效率并降低记忆风险

核心判断。“去重提高训练效率并降低记忆风险”是“精确去重和哈希”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 8 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“去重提高训练效率并降低记忆风险”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 8: 去重提高训练效率并降低记忆风险⁸

4.2 哈希函数在效率和碰撞风险间权衡

核心判断。“哈希函数在效率和碰撞风险间权衡”是“精确去重和哈希”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 9 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“哈希函数在效率和碰撞风险间权衡”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁸视频画面时间区间：00:26:15–00:26:30。


```
178 jaccard_minhash()
179 locality_sensitive_hashing()
180
181
182 def hash_functions():
183     • Hash function h maps item to a hash value (integer or string)
184     • Hash value much smaller than item
185     • Hash collision:  $h(x) = h(y)$  for  $x \neq y$ 
186
187     Tradeoff between efficiency and collision resistance \[article\]
188     • Cryptographic hash functions (SHA-256): collision resistant, slow (used in bitcoin)
189     • DJB2, MurmurHash, CityHash: not collision resistant, fast (used for hash tables)
190
191     We will use MurmurHash:
192     h = mmh3.hash("hello")
193
194
195 def exact_deduplication():
196     Simple example
197     1. Item: string
198     2. How to match: exact match
199     3. Action: remove all but one
```

图 9: 哈希函数在效率和碰撞风险间权衡⁹

4.3 Jaccard 相似度比较集合交并比

核心判断。“Jaccard 相似度比较集合交并比”是“精确去重和哈希”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 10 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“Jaccard 相似度比较集合交并比”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁹视频画面时间区间：00:29:15–00:29:30。




图 10: Jaccard 相似度比较集合交并比¹⁰

4.4 本章小结

“精确去重和哈希”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。过强过滤会缩窄覆盖，过强去重会删掉合法模板，过采样稀缺源会导致 epoching 和记忆，合成数据还可能放大教师偏差。

5 Jaccard 与 MinHash

本节路线

本节依次处理：MinHash 用排列最小值估计 Jaccard、局部敏感哈希把相似项放入同一桶、bands 与 rows 控制候选召回和精度。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$P[h_{\min}(A) = h_{\min}(B)] = J(A, B)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁰视频画面时间区间：00:32:00–00:32:15。

$$G_4 = \frac{B_4}{C_4 + \lambda R_4 + \epsilon}$$

- B_4 是本节方法带来的质量、吞吐或覆盖收益。
- C_4 是新增计算、显存、通信、数据或标注成本。
- R_4 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_4 \leq C_{\max}, \quad R_4 \leq R_{\max}, \quad Q_4 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

5.1 MinHash 用排列最小值估计 Jaccard

核心判断。“MinHash 用排列最小值估计 Jaccard”是“Jaccard 与 MinHash”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 11 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“MinHash 用排列最小值估计 Jaccard”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 11: MinHash 用排列最小值估计 Jaccard¹¹

5.2 局部敏感哈希把相似项放入同一桶

核心判断。“局部敏感哈希把相似项放入同一桶”是“Jaccard 与 MinHash”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 12 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“局部敏感哈希把相似项放入同一桶”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹¹视频画面时间区间：00:35:00–00:35:15。




图 12: 局部敏感哈希把相似项放入同一桶¹²

5.3 bands 与 rows 控制候选召回和精度

核心判断。“bands 与 rows 控制候选召回和精度”是“Jaccard 与 MinHash”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 13 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“bands 与 rows 控制候选召回和精度”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹²视频画面时间区间：00:38:00–00:38:15。

```

277
278 Solution: use n hash functions
279 Break up into b bands of r hash functions each (n = b * r)
280
281 n = 12      # Number of hash functions
282 b = 3      # Number of bands
283 r = 4      # Number of hash functions per band
284 Hash functions:
285 h1 h2 h3 h4 | h5 h6 h7 h8 | h9 h10 h11 h12
286
287 Key: A and B collide if for some band, all its hash functions return same value
288 As we will see, the and-or structure of the bands sharpens the threshold
289
290 Given Jaccard(A, B), what is the probability that A and B collide?
291
292 def get_prob_collision(sim, b, r):
293     prob_match = sim ** r                                # Probability that a fixed band matches
294     prob_collision = 1 - (1 - prob_match) ** b           # Probability that some band matches
295     return prob_collision
296
297 Example
298 prob_collision = get_prob_collision(sim=0.8, b=5, r=10)

```

图 13: bands 与 rows 控制候选召回和精度¹³

5.4 本章小结

“Jaccard 与 MinHash”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。过强过滤会缩窄覆盖，过强去重会删掉合法模板，过采样稀缺源会导致 epoching 和记忆，合成数据还可能放大教师偏差。

6 局部敏感哈希

本节路线

本节依次处理：MinHash LSH 的碰撞概率曲线、哈希参数改变近似匹配阈值、转换过滤去重混合组成完整数据管线。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$P_{\text{candidate}}(s) = 1 - (1 - s^r)^b$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹³视频画面时间区间：00:40:45–00:41:00。

$$G_5 = \frac{B_5}{C_5 + \lambda R_5 + \epsilon}$$

- B_5 是本节方法带来的质量、吞吐或覆盖收益。
- C_5 是新增计算、显存、通信、数据或标注成本。
- R_5 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_5 \leq C_{\max}, \quad R_5 \leq R_{\max}, \quad Q_5 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

6.1 MinHash LSH 的碰撞概率曲线

核心判断。“MinHash LSH 的碰撞概率曲线”是“局部敏感哈希”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 14 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“MinHash LSH 的碰撞概率曲线”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 14: MinHash LSH 的碰撞概率曲线¹⁴

6.2 哈希参数改变近似匹配阈值

核心判断。“哈希参数改变近似匹配阈值”是“局部敏感哈希”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 15 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“哈希参数改变近似匹配阈值”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁴视频画面时间区间：00:43:45–00:44:00。




图 15: 哈希参数改变近似匹配阈值¹⁵

6.3 转换过滤去重混合组成完整数据管线

核心判断。“转换过滤去重混合组成完整数据管线”是“局部敏感哈希”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 16 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“转换过滤去重混合组成完整数据管线”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁵视频画面时间区间：00:46:30–00:46:45。




图 16: 转换过滤去重混合组成完整数据管线¹⁶

6.4 本章小结

“局部敏感哈希”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。过强过滤会缩窄覆盖，过强去重会删掉合法模板，过采样稀缺源会导致 epoching 和记忆，合成数据还可能放大教师偏差。

7 数据混合和 epoching

本节路线

本节依次处理：人工均匀和按 token 比例是混合基线、有限高质量源会因过采样产生多轮训练、回归模型预测数据混合的下游目标。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$p_s = \frac{w_s}{\sum_j w_j}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁶视频画面时间区间：00:49:30–00:49:45。

$$G_6 = \frac{B_6}{C_6 + \lambda R_6 + \epsilon}$$

- B_6 是本节方法带来的质量、吞吐或覆盖收益。
- C_6 是新增计算、显存、通信、数据或标注成本。
- R_6 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_6 \leq C_{\max}, \quad R_6 \leq R_{\max}, \quad Q_6 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

7.1 人工均匀和按 token 比例是混合基线

核心判断。“人工均匀和按 token 比例是混合基线”是“数据混合和 epoching”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 17 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“人工均匀和按 token 比例是混合基线”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 17: 人工均匀和按 token 比例是混合基线¹⁷

7.2 有限高质量源会因过采样产生多轮训练

核心判断。“有限高质量源会因过采样产生多轮训练”是“数据混合和 epoching”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 18 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“有限高质量源会因过采样产生多轮训练”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁷视频画面时间区间：00:52:30–00:52:45。




图 18: 有限高质量源会因过采样产生多轮训练¹⁸

7.3 回归模型预测数据混合的下游目标

核心判断。“回归模型预测数据混合的下游目标”是“数据混合和 epoching”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 19 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“回归模型预测数据混合的下游目标”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁸视频画面时间区间：00:55:15–00:55:30。




图 19: 回归模型预测数据混合的下游目标¹⁹

7.4 本章小结

“数据混合和 epoching”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。过强过滤会缩窄覆盖，过强去重会删掉合法模板，过采样稀缺源会导致 epoching 和记忆，合成数据还可能放大教师偏差。

8 回归驱动的混合优化

本节路线

本节依次处理：混合优化比较代理模型与精确求解、小规模最优混合迁移到大规模时可能偏移、模拟 epoching 控制稀缺数据过拟合。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$e_s = \frac{p_s T}{D_s}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁹视频画面时间区间：01:01:15–01:01:30。

$$G_7 = \frac{B_7}{C_7 + \lambda R_7 + \epsilon}$$

- B_7 是本节方法带来的质量、吞吐或覆盖收益。
- C_7 是新增计算、显存、通信、数据或标注成本。
- R_7 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_7 \leq C_{\max}, \quad R_7 \leq R_{\max}, \quad Q_7 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

8.1 混合优化比较代理模型与精确求解

核心判断。“混合优化比较代理模型与精确求解”是“回归驱动的混合优化”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 20 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“混合优化比较代理模型与精确求解”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

377	• Define regression method (e.g., linear, gradient boosted trees)						
378	• Define target based on downstream evals (careful not to overfit!)						
379	• Discrepancy between small and large scale (tradeoff cost and accuracy)						
Design Choice	RegMix (Liu et al., 2025a)	DML (Ye et al., 2025)	Au-toScale (Kang et al., 2025)	BiMix (Ge et al., 2025b)	ADMIRE-BayesOpt (Chen et al., 2025b)	CLIMB (Diao et al., 2025)	OLMIXBASE (Algorithm 1)
Swarm Construction							
Proxy model size	1M	70, 160, 305, 410M	Target	280M	1M, 60M	350M	30M
Swarm size (vs m domains)	512 ($m = 17$)	20 ($m = 7$)	$2m + 1$	4	101 ($m = 17$)	112 ($m = 21$)	$3(m + 1)$
Swarm distribution	Dirichlet with natural prior	Exponential grid	Exponential grid	Entropy-weighted	Dynamic	Dirichlet with natural prior	Dirichlet with natural prior (sparse for topics, dense for sources)
Regression Model							
Regression model family	LightGBM	Log-Linear	Power Law	Power Law	Gaussian Process	LightGBM	Log-Linear
Regression granularity	Aggregated	Aggregated	Per-Task	Per-Task	Aggregated	Aggregated	Per-Task
Mixture Optimization							
Data repetition constraints	No	No	No	No	No	No	Yes
Optimization solver	Search	Search	Gradient Descent	Exact Solver	Search	Search	Exact Solver with KL reg.
180	Hope 1: regression model is accurate at minimizer 🙏						
181	Hope 2: optimal data mixtures transfer from small to large scale 🙏						

图 20: 混合优化比较代理模型与精确求解²⁰

8.2 小规模最优混合迁移到大规模时可能偏移

核心判断。“小规模最优混合迁移到大规模时可能偏移”是“回归驱动的混合优化”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 21 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“小规模最优混合迁移到大规模时可能偏移”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁰视频画面时间区间：01:04:00–01:04:15。

Regression granularity	Aggregated	Aggregated	Per-Task	Per-Task	Aggregated	Aggregated	Per-Task
Mixture Optimization							
Data repetition constraints	No	No	No	No	No	No	Yes
Optimization solver	Search	Search	Gradient Descent	Exact Solver	Search	Search	Exact Solver with KL reg.

```

380 Hope 1: regression model is accurate at minimizer 🙏
381 Hope 2: optimal data mixtures transfer from small to large scale 🙏
382
383 Hold on. There's at least one scale-dependent effect:
384 source_token_counts = {
385     "low": trillion(10), # 10T tokens (abundant)
386     "high": billion(10), # 10B tokens (scarce)
387 }
388 • If train small models on low token counts.
389 p = {"low": 0.1, "high": 0.9} # More mass on high quality data
390 • But if train large model on this mixture, we will epoch a ton on high quality data and overfit!
391
392 Simulated epoching [Held+ 2025]
393 • General idea: make small scale look like large scale (general theme of this course)
394 • Instantiation: downsample all sources proportionally
395 small_run_tokens = billion(10)
396 large_run_tokens = trillion(1)

```

图 21: 小规模最优混合迁移到大规模时可能偏移²¹

8.3 模拟 epoching 控制稀缺数据过拟合

核心判断。“模拟 epoching 控制稀缺数据过拟合”是“回归驱动的混合优化”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 22 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“模拟 epoching 控制稀缺数据过拟合”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²¹视频画面时间区间：01:07:00–01:07:15。

```

387     }
388     • If train small models on low token counts:
389     p = {"low": 0.1, "high": 0.9} # More mass on high quality data
390     • But if train large model on this mixture, we will epoch a ton on high quality data and overfit!
391
392     Simulated epoching [Held+ 2025]
393     • General idea: make small scale look like large scale (general theme of this course)
394     • Instantiation: downsample all sources proportionally
395     small_run_tokens = billion(10)
396     large_run_tokens = trillion(1)
397     ratio = small_run_tokens / large_run_tokens
398     downsampled_source_token_counts = {s: count * ratio for s, count in source_token_counts.items()}
399     • In this downsampled mixture, models that epoch too much won't look good.
400     • So the optimum will be more balanced.
401     p = {"low": 0.7, "high": 0.3} # More mass on high quality data
402
403     Summary:
404     • Problem: how to weight different data sources (e.g., Wikipedia, general, code)
405     • Regression-based mixing: estimate mixture → loss at small scale, optimize (analogous to scaling laws)
406     • Important consideration: epoching and overfitting (solution: cap or simulated)

```

图 22: 模拟 epoching 控制稀缺数据过拟合²²

8.4 本章小结

“回归驱动的混合优化”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。过强过滤会缩窄覆盖，过强去重会删掉合法模板，过采样稀缺源会导致 epoching 和记忆，合成数据还可能放大教师偏差。

9 合成数据与可执行验证

本节路线

本节依次处理：合成题目与答案扩展高质量训练信号、SWE-smith 从代码仓库生成可执行任务、SWE 合成数据规模与验证解决率关系。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$w^* = \arg \min_w \hat{L}_{\text{downstream}}(w)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²²视频画面时间区间：01:10:00–01:10:15。

$$G_8 = \frac{B_8}{C_8 + \lambda R_8 + \epsilon}$$

- B_8 是本节方法带来的质量、吞吐或覆盖收益。
- C_8 是新增计算、显存、通信、数据或标注成本。
- R_8 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_8 \leq C_{\max}, \quad R_8 \leq R_{\max}, \quad Q_8 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

9.1 合成题目与答案扩展高质量训练信号

核心判断。“合成题目与答案扩展高质量训练信号”是“合成数据与可执行验证”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 23 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“合成题目与答案扩展高质量训练信号”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 23: 合成题目与答案扩展高质量训练信号²³

9.2 SWE-smith 从代码仓库生成可执行任务

核心判断。“SWE-smith 从代码仓库生成可执行任务”是“合成数据与可执行验证”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 24 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“SWE-smith 从代码仓库生成可执行任务”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²³视频画面时间区间：01:15:45–01:16:00。




图 24: SWE-smith 从代码仓库生成可执行任务²⁴

9.3 SWE 合成数据规模与验证解决率关系

核心判断。“SWE 合成数据规模与验证解决率关系”是“合成数据与可执行验证”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 25 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“SWE 合成数据规模与验证解决率关系”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁴视频画面时间区间：01:18:45–01:19:00。




图 25: SWE 合成数据规模与验证解决率关系²⁵

9.4 本章小结

“合成数据与可执行验证”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。过强过滤会缩窄覆盖，过强去重会删掉合法模板，过采样稀缺源会导致 epoching 和记忆，合成数据还可能放大教师偏差。

10 代码化复现：最小机制

下面的片段保留本讲最核心的程序结构，用于把公式和系统过程落到可执行对象。它不是生产实现；实际复现还需补充张量形状断言、数值精度、同步、随机种子、数据版本和端到端测试。

Listing 1: Lecture 14 机制伪代码

```
1 def lsh_candidates(signature, bands, rows):
2     buckets = []
3     for b in range(bands):
4         chunk = tuple(signature[b*rows:(b+1)*rows])
5         buckets.append(hash((b, chunk)))
6     return buckets
```

复现检查单

先写正确性基线，再记录资源基线；每次只改变一个机制；同时保存直接中间量和最终指标；对随机算法报告多次运行；对数据与评测保存不可变版本标识。

²⁵视频画面时间区间：01:21:30–01:21:45。

10.1 本章小结

代码的价值在于暴露状态、顺序和边界。若一个概念无法写成输入、变换、状态、输出和断言，它通常还没有被真正理解。

11 总结与延伸

一页压缩

本讲的主问题是：怎样把抓取到的异构内容加工为可训练语料，并用过滤、去重、混合和合成数据提高每个 token 的价值？统一答案是：数据处理算法既决定质量也决定分布；过滤器、去重阈值和采样权重必须作为模型配方的一部分记录。

第一，优先理解机制而不是产品名。模型、硬件、数据和评测不断更新，但张量形状、状态位置、目标函数、通信边界和测量误差仍然是稳定的分析对象。第二，所有优化都要写出代价守恒：减少某一种成本通常会增加另一种成本或风险。第三，把小规模实验推广到大规模之前，必须检查瓶颈是否改变、数据分布是否改变、实现常数是否仍在同一数量级。第四，最可靠的课程笔记应允许读者沿时间脚注回到原视频，并沿官方材料找到公式或代码出处。

开放问题

过强过滤会缩窄覆盖，过强去重会删掉合法模板，过采样稀缺源会导致 epoching 和记忆，合成数据还可能放大教师偏差。后续实验应把这一风险写成可观测量和停止条件，而不是留在讨论部分。

11.1 本章小结

完成本讲后，读者应能用统一语言解释每个主题的输入、状态、变换、输出、资源成本和失败模式，并据此设计一个含基线、消融、误差条和证据记录的最小实验。

12 资料来源与审计边界

- 课程主页：<https://cs336.stanford.edu/>。
- 视频：<https://www.youtube.com/watch?v=5sxHosTLPF8>。
- Stanford 官方材料：lecture_14.py；客座讲座若无官方文件则以视频和字幕为主。
- 本地证据：audio.srt、figure_manifest.tsv、figure_verification.txt、teaching_atoms.tsv、numerical_claims.tsv。

12.1 本章小结

本笔记覆盖播放列表中的本讲内容与课程主页当日可取得的官方材料。没有官方讲义的客座讲座不会被伪装成有讲义；讲者口头推测、本笔记分析框架和官方公式在文字中分别标明。