

Stanford CS336: Language Modeling from Scratch

Lecture 15: Mid/Post-Training: SFT and RLHF

Spring 2026 中文精讲笔记

主讲: Tatsunori Hashimoto



频道: Stanford Online

发布日期: 2026-05-27

时长: 1:19:54

视频: <https://www.youtube.com/watch?v=2oH6PWPrYFo>

官方主页: <https://cs336.stanford.edu/>

目录

1 导读：问题、证据与阅读方法	2
2 后训练目标与信息边界	2
3 SFT 数据演进	6
4 知识事实与引用	10
5 安全 SFT 和少量数据	14
6 中训练与数据重配	18
7 人类反馈数据与标注者	22
8 从 SFT 到 PPO	26
9 DPO 与 RLHF 失效模式	30
10 代码化复现：最小机制	34
11 总结与延伸	35
12 资料来源与审计边界	35

1 导读：问题、证据与阅读方法

本讲主问题

怎样用 SFT、偏好数据和奖励优化获得更可控的语言模型，同时避免知识污染、标注偏差和奖励过拟合？

后训练把行为示范、偏好比较和策略优化串起来；数据如何产生与由谁标注，和优化算法同样重要。本笔记以课程视频、人工字幕和 Stanford 官方讲义或代码为共同证据源。图像均来自每十五秒抽帧后的人工接触表审查，时间脚注可回到原视频复核；公式区分课程机制关系和本笔记的决策分析框架。学习时建议先读主问题，再沿“机制-资源-失败模式-验证指标”四列整理自己的实验。

首先排除的误读

模型能复述引用并不代表事实可靠；少量群体的偏好会被放大，优化奖励也会偏离真实用户目标。

1.1 关键数字核对

主张	数值或关系	视频时间
安全 SFT 的显著效果示例	约 500 samples	00:33:00
偏好监督基本单位	成对响应	00:47:00
PPO 裁剪区间	$1 \pm \epsilon$	01:09:00
DPO 比较对象	chosen 与 rejected 两个响应	01:14:00

1.2 本章小结

本章建立证据边界：视频解释提供因果和强调，官方材料提供公式与代码，精选帧提供可核查的视觉状态。后文每个主题都同时回答“为何重要、怎样工作、怎样失败、怎样验证”，避免把课程压缩成术语目录。

2 后训练目标与信息边界

本节路线

本节依次处理：后训练通过可控数据约束语言模型输出、现代闭源后训练配方公开信息有限、FLAN Self-Instruct Alpaca 到工具数据的演进。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L_{\text{SFT}} = - \sum_t \log p_{\theta}(y_t \mid x, y_{<t})$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。

- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_1 = \frac{B_1}{C_1 + \lambda R_1 + \varepsilon}$$

- B_1 是本节方法带来的质量、吞吐或覆盖收益。
- C_1 是新增计算、显存、通信、数据或标注成本。
- R_1 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_1 \leq C_{\max}, \quad R_1 \leq R_{\max}, \quad Q_1 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

2.1 后训练通过可控数据约束语言模型输出

核心判断。“后训练通过可控数据约束语言模型输出”是“后训练目标与信息边界”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 1 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“后训练通过可控数据约束语言模型输出”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Goal today: enable better, tighter controls over LM output

Pretraining data isn't quite what we want (but it scales)..

Can we collect data of behaviors we *do* want and train the LM?

1. What does that data look like?
2. How do we best make use of that data?
3. Do we need scale for this?

图 1: 后训练通过可控数据约束语言模型输出¹

2.2 现代闭源后训练配方公开信息有限

核心判断。“现代闭源后训练配方公开信息有限”是“后训练目标与信息边界”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 2 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“现代闭源后训练配方公开信息有限”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹视频画面时间区间：00:02:45–00:03:00。

Caveat: post-training information is pretty sparse!

Rich information from the pre-chatgpt competition

- Stiennon 2020 (RLHF paper) – contains annotation guidelines, etc
- Bai 2022 (Anthropic HH) – details on how to set up safety annotation, etc

Poor information in modern times..

- Open source: lots of distillation, not too public in open-source release notes
- Closed source: ‘secret sauce’ for data.

In July 2023, a manager ordered workers to study GPT-4's responses closely and figure out why they outperformed Bard's. "Try to come up with feedback that we can share so that experts can write responses better than GPT4 or at least the same," the manager wrote.

Scale AI also created a spreadsheet that compared 1,729 Bard rewrites directly to ChatGPT in October 2023. Each rewrite was rated with labels like "worse than GPT4" or "Needs Some Fixes." In one example, a worker rewrote a Bard review of a nursery chair that managers stamped "worse than GPT" because it "lacks detail compared to GPT4."

图 2: 现代闭源后训练配方公开信息有限²

2.3 FLAN Self-Instruct Alpaca 到工具数据的演进

核心判断。“FLAN Self-Instruct Alpaca 到工具数据的演进”是“后训练目标与信息边界”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 3 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“FLAN Self-Instruct Alpaca 到工具数据的演进”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²视频画面时间区间：00:05:30–00:05:45。

Progression of SFT data (in the open world)




图 3: FLAN Self-Instruct Alpaca 到工具数据的演进³

2.4 本章小结

“后训练目标与信息边界”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。模型能复述引用并不代表事实可靠；少量群体的偏好会被放大，优化奖励也会偏离真实用户目标。

3 SFT 数据演进

本节路线

本节依次处理：开放 SFT 数据集的来源和能力侧重、OpenAssistant 展示响应长度风格和知识差异、SFT 数据在长度知识规模和安全上变化。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$P(y^+ \succ y^-) = \sigma(r_\phi(x, y^+) - r_\phi(x, y^-))$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

³视频画面时间区间：00:08:15–00:08:30。

$$G_2 = \frac{B_2}{C_2 + \lambda R_2 + \epsilon}$$

- B_2 是本节方法带来的质量、吞吐或覆盖收益。
- C_2 是新增计算、显存、通信、数据或标注成本。
- R_2 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_2 \leq C_{\max}, \quad R_2 \leq R_{\max}, \quad Q_2 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

3.1 开放 SFT 数据集的来源和能力侧重

核心判断。“开放 SFT 数据集的来源和能力侧重”是“SFT 数据演进”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 4 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“开放 SFT 数据集的来源和能力侧重”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Progression of SFT data (in the open world)




图 4: 开放 SFT 数据集的来源和能力侧重⁴

3.2 OpenAssistant 展示响应长度风格和知识差异

核心判断。“OpenAssistant 展示响应长度风格和知识差异”是“SFT 数据演进”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 5 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“OpenAssistant 展示响应长度风格和知识差异”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁴视频画面时间区间：00:13:45–00:14:00。

OpenAssistant – random examples

Can you write a short introduction about the relevance of the term "monopsony" in economics? Please use examples related to potential monopsonies in the labour market and cite relevant research.	"Monopsony" refers to a market structure where there is only one buyer for a particular good or service. In economics, this term is particularly relevant in the labor market, where a monopsony employer has significant power over the wages and working conditions of their employees. [...]. Overall, the concept of monopsony is essential to understanding the dynamics of labor markets and the impact of market power on workers. Further research is needed to understand the extent and impact of monopsonies on the economy and to develop policies to address this issue. References: Bivens, J., & Mishel, L. (2013). The Pay of Corporate Executives and Financial Professionals as Evidence of Rents in Top 1 Percent Incomes. Journal of Economic Perspectives, 27(3), 57-78.
My kid needs to do a science project for elementary school, what are some cheap but fun projects to do?	There are many cheap and fun science projects that elementary school kids can do! Here are a few ideas: 1. Make a homemade lava lamp: Fill a clear plastic bottle with water and vegetable oil, add a few drops of food coloring, and then drop in an Alka-Seltzer tablet. The reaction will cause bubbles to rise and fall like a lava lamp. [...]7. Create a solar oven: Using a pizza box, aluminum foil, and plastic wrap, create a solar oven that can cook s'mores or other small snacks. 8. Explore magnets: Using magnets and a variety of objects, have your child experiment with magnetism to see what objects are attracted to magnets and which ones are not. These are just a few ideas to get you started! There are many more cheap and fun science projects that your child can do with household items and a little creativity.

图 5: OpenAssistant 展示响应长度风格和知识差异⁵

3.3 SFT 数据在长度知识规模和安全上变化

核心判断。“SFT 数据在长度知识规模和安全上变化”是“SFT 数据演进”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 6 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“SFT 数据在长度知识规模和安全上变化”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁵视频画面时间区间：00:16:30–00:16:45。

What did we notice across the datasets?

These datasets vary in many ways...

- **Length and bullet points** (style variations)
- **References, other complex knowledge**

Less visible, but important aspects..

- **Scale**
- **Safety**

How do these factors affect the model?

图 6: SFT 数据在长度知识规模和安全上变化⁶

3.4 本章小结

“SFT 数据演进”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。模型能复述引用并不代表事实可靠；少量群体的偏好会被放大，优化奖励也会偏离真实用户目标。

4 知识事实与引用

本节路线

本节依次处理：引用与复杂知识样本可能诱导错误记忆、知识抽取与行为对齐不能简单混为一谈、真实安全 SFT 数据规模通常较小。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L_{RM} = -\log \sigma(r^+ - r^-)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁶视频画面时间区间：00:19:15–00:19:30。

$$G_3 = \frac{B_3}{C_3 + \lambda R_3 + \epsilon}$$

- B_3 是本节方法带来的质量、吞吐或覆盖收益。
- C_3 是新增计算、显存、通信、数据或标注成本。
- R_3 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_3 \leq C_{\max}, \quad R_3 \leq R_{\max}, \quad Q_3 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

4.1 引用与复杂知识样本可能诱导错误记忆

核心判断。“引用与复杂知识样本可能诱导错误记忆”是“知识事实与引用”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 7 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“引用与复杂知识样本可能诱导错误记忆”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

References, complex knowledge, and factuality

Consider this example from open assistant:

Can you write a short introduction about the relevance of the term "monopsony" in economics? Please use examples related to potential monopsonies in the labour market and cite relevant research.	"Monopsony" refers to a market structure where there is only one buyer for a particular good or service. In economics, this term is particularly relevant in the labor market, where a monopsony employer has significant power over the wages and working conditions of their employees. [...] Overall, the concept of monopsony is essential to understanding the dynamics of labor markets and the impact of market power on workers. Further research is needed to understand the extent and impact of monopsonies on the economy and to develop policies to address this issue. References: Bivens, J., & Mishel, L. (2013). The Pay of Corporate Executives and Financial Professionals as Evidence of Rents in Top 1 Percent Incomes. Journal of Economic Perspectives, 27(3), 57-78.
--	---

What is this example teaching the model?

1. Teaching the model about Bivens J & Mishel, L
2. Teaching the model to output citations when asked to do so
(But by what mechanism? Does the model know about cites?)

图 7: 引用与复杂知识样本可能诱导错误记忆⁷

4.2 知识抽取与行为对齐不能简单混为一谈

核心判断。“知识抽取与行为对齐不能简单混为一谈”是“知识事实与引用”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 8 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“知识抽取与行为对齐不能简单混为一谈”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁷视频画面时间区间：00:22:00–00:22:15。

Takeaways on knowledge extraction and alignment

1. You may not want to fine-tune on tail knowledge, even that's the LM use case
2. In principle, 'RL' style correctness feedback could help
3. Knowledge storage and extraction in LMs is messy, and nuanced.

图 8: 知识抽取与行为对齐不能简单混为一谈⁸

4.3 真实安全 SFT 数据规模通常较小

核心判断。“真实安全 SFT 数据规模通常较小”是“知识事实与引用”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 9 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“真实安全 SFT 数据规模通常较小”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁸视频画面时间区间：00:24:45–00:25:00。

Safety SFT in the wild

Details are pretty sparse

Finetuning data. The quality and design of safety training data has a profound impact on performance. Through extensive ablations, we find that the quality is more critical than the quantity. We mainly use human-generated data collected from our data vendors, but find that it can be prone to errors and inconsistencies — particularly for nuanced safety policies. To ensure the highest quality data, we developed AI-assisted annotation tools to support our rigorous quality assurance processes. In addition to collecting adversarial prompts, we also gather a set of similar prompts, which we refer to as **borderline prompts**. These are closely related to the adversarial prompts but with a goal to teach the model to learn to provide helpful responses, thereby reducing the false refusal rate (FRR).

Beyond human annotation, we also leverage synthetic data to improve the quality and coverage of our training datasets. We utilize a range of techniques to generate additional adversarial examples, including in-context learning with carefully crafted system prompts, guided mutation of seed prompts based on new attack vectors, and advanced algorithms including Rainbow Teaming ([Samvelyan et al., 2024](#)), based on MAP-Elites ([Mouret and Clune, 2015](#)), which generate prompts constrained across multiple dimensions of diversity.




Figure 18 Influence of model size on safety mix design for balancing violation rate (VR) and false refusal rate (FRR). Each point of the scatterplot represents a different data mix balancing safety and helpfulness data. Different model sizes retain varying capacities for safety learning. Our experiments show that 8B models require a higher proportion of safety data relative to helpfulness data in the overall SFT mix to achieve comparable safety performance to 70B models. Larger models are more capable of discerning between adversarial and borderline context, resulting in a more favorable balance between VR and FRR.

Examples? ~ few thousand in Llama 2

图 9: 真实安全 SFT 数据规模通常较小⁹

4.4 本章小结

“知识事实与引用”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。模型能复述引用并不代表事实可靠；少量群体的偏好会被放大，优化奖励也会偏离真实用户目标。

5 安全 SFT 和少量数据

本节路线

本节依次处理：约五百条安全样本即可显著改变拒答行为、中训练或两阶段训练改变数据组成、知识与指令数据在中训练阶段重新配比。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$J(\pi) = E_{\pi}[r] - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}})$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁹视频画面时间区间：00:30:15–00:30:30。

$$G_4 = \frac{B_4}{C_4 + \lambda R_4 + \epsilon}$$

- B_4 是本节方法带来的质量、吞吐或覆盖收益。
- C_4 是新增计算、显存、通信、数据或标注成本。
- R_4 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_4 \leq C_{\max}, \quad R_4 \leq R_{\max}, \quad Q_4 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

5.1 约五百条安全样本即可显著改变拒答行为

核心判断。“约五百条安全样本即可显著改变拒答行为”是“安全 SFT 和少量数据”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 10 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“约五百条安全样本即可显著改变拒答行为”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Safety-tuning with just a little data

Significant improvements to safety with ~500 samples.



Adding 500 Alpaca-style examples makes models follow safety guidelines



图 10: 约五百条安全样本即可显著改变拒答行为¹⁰

5.2 中训练或两阶段训练改变数据组成

核心判断。“中训练或两阶段训练改变数据组成”是“安全 SFT 和少量数据”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 11 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“中训练或两阶段训练改变数据组成”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁰视频画面时间区间：00:33:00–00:33:15。




图 11: 中训练或两阶段训练改变数据组成¹¹

5.3 知识与指令数据在中训练阶段重新配比

核心判断。“知识与指令数据在中训练阶段重新配比”是“安全 SFT 和少量数据”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 12 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“知识与指令数据在中训练阶段重新配比”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹¹视频画面时间区间：00:38:30–00:38:45。

$$G_5 = \frac{B_5}{C_5 + \lambda R_5 + \epsilon}$$

- B_5 是本节方法带来的质量、吞吐或覆盖收益。
- C_5 是新增计算、显存、通信、数据或标注成本。
- R_5 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_5 \leq C_{\max}, \quad R_5 \leq R_{\max}, \quad Q_5 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

6.1 生成式偏好与判别式判断存在差距

核心判断。“生成式偏好与判别式判断存在差距”是“中训练与数据重配”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 13 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“生成式偏好与判别式判断存在差距”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Why optimize? G-V gap

People don't always write the thing that they prefer in LM outputs..



From: Zhang et al – “Benchmarking Large Language Models for News Summarization” 2023

图 13: 生成式偏好与判别式判断存在差距¹³

6.2 RLHF 从示范比较到策略优化构造反馈

核心判断。“RLHF 从示范比较到策略优化构造反馈”是“中训练与数据重配”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 14 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“RLHF 从示范比较到策略优化构造反馈”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹³视频画面时间区间：00:44:00–00:44:15。

RLHF Data

What types of pairwise feedback. How do we get (good) pairwise feedback?




图 14: RLHF 从示范比较到策略优化构造反馈¹⁴

6.3 众包平台标注者分布并不代表所有用户

核心判断。“众包平台标注者分布并不代表所有用户”是“中训练与数据重配”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 15 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“众包平台标注者分布并不代表所有用户”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁴视频画面时间区间：00:46:45–00:47:00。

Modern worker distribution

Caveat: many platforms, covers only one (Outlier, ScaleAI)




图 15: 众包平台标注者分布并不代表所有用户¹⁵

6.4 本章小结

“中训练与数据重配”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。模型能复述引用并不代表事实可靠；少量群体的偏好会被放大，优化奖励也会偏离真实用户目标。

7 人类反馈数据与标注者

本节路线

本节依次处理：大规模标注涉及劳动条件和数据伦理、标注者人口结构会改变模型偏好、强模型可生成高相关的成对反馈。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L_{PPO} = -E[\min(r_t A_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) A_t)]$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁵视频画面时间区间：00:49:30–00:49:45。

$$G_6 = \frac{B_6}{C_6 + \lambda R_6 + \epsilon}$$

- B_6 是本节方法带来的质量、吞吐或覆盖收益。
- C_6 是新增计算、显存、通信、数据或标注成本。
- R_6 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_6 \leq C_{\max}, \quad R_6 \leq R_{\max}, \quad Q_6 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

7.1 大规模标注涉及劳动条件和数据伦理

核心判断。“大规模标注涉及劳动条件和数据伦理”是“人类反馈数据与标注者”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 16 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“大规模标注涉及劳动条件和数据伦理”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

RLHF and data – crowdsourcing ethics

Data collection at scale can have significant issues




图 16: 大规模标注涉及劳动条件和数据伦理¹⁶

7.2 标注者人口结构会改变模型偏好

核心判断。“标注者人口结构会改变模型偏好”是“人类反馈数据与标注者”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 17 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“标注者人口结构会改变模型偏好”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁶视频画面时间区间：00:52:15–00:52:30。

RLHF and data - demographics

The annotator distribution for RLHF can significantly shift its behaviors

Table 17: RLHF annotator demographics (left)				Table 18: RLHF annotator preferences (right)													
What gender do you identify as?				Group			A121							OpenAI			
Male	50.0%				J1- grande	J1- jumbo	J1- grande- v2-beta	ada	davinci	text- ada-001	text- davinci- 001	text- davinci- 002	text- davinci- 003				
Female	44.4%			RELIG													
Nonbinary / other	5.6%			Protestant	0.813	0.814	0.797	0.821	0.788	0.709	0.715	0.755	0.694				
What ethnicities do you identify as?				Roman Catholic	0.815	0.820	0.806	0.825	0.794	0.709	0.716	0.759	0.700				
White / Caucasian	31.6%			Mormon	0.792	0.794	0.778	0.803	0.772	0.700	0.709	0.752	0.694				
Southeast Asian	52.6%			Orthodox	0.771	0.776	0.762	0.783	0.754	0.688	0.698	0.733	0.693				
Indigenous / Native American / Alaskan Native	0.0%			Jewish	0.794	0.796	0.785	0.801	0.773	0.699	0.710	0.758	0.706				
East Asian	5.7%			Muslim	0.786	0.796	0.788	0.793	0.775	0.684	0.704	0.730	0.698				
Middle Eastern	0.0%			Buddhist	0.771	0.784	0.776	0.783	0.764	0.682	0.703	0.747	0.709				
Latino	15.8%			Hindu	0.778	0.798	0.793	0.789	0.776	0.683	0.703	0.728	0.707				
Black / of African descent	10.5%			Atheist	0.774	0.778	0.772	0.786	0.761	0.690	0.707	0.766	0.713				
What is your nationality?				Agnostic	0.783	0.789	0.781	0.795	0.768	0.698	0.715	0.771	0.715				
Filipino	22%			Nothing in particular	0.815	0.819	0.802	0.826	0.791	0.712	0.715	0.765	0.698				
Bangladeshi	22%																
American	17%																
Albanian	5%																
Brazilian	5%																
Canadian	5%																
Colombian	5%																
Indian	5%																
Uruguayan	5%																
Zimbabwean	5%																
What is your age?																	
18-24	26.3%																
25-34	47.4%																
35-44	10.5%																
45-54	10.5%																
55-64	5.3%																
65+	0%																
What is your highest attained level of education?																	
Less than high school degree	0%																
High school degree	10.5%																
Undergraduate degree	52.6%																
Master's degree	36.8%																
Doctorate degree	0%																

[Santurkar+ 2023]

图 17: 标注者人口结构会改变模型偏好¹⁷

7.3 强模型可生成高相关的成对反馈

核心判断。“强模型可生成高相关的成对反馈”是“人类反馈数据与标注者”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 18 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“强模型可生成高相关的成对反馈”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁷视频画面时间区间：00:55:00–00:55:15。

RLFH and data - LM-generated

GPT4 is a surprisingly good pairwise feedback system




图 18: 强模型可生成高相关的成对反馈¹⁸

7.4 本章小结

“人类反馈数据与标注者”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。模型能复述引用并不代表事实可靠；少量群体的偏好会被放大，优化奖励也会偏离真实用户目标。

8 从 SFT 到 PPO

本节路线

本节依次处理：AI feedback 推动反馈数据规模扩张、SFT 学分布而 RLHF 优化可测奖励、PPO 通过裁剪比率稳定策略更新。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$r^*(x, y) = \beta \log \frac{\pi^*(y | x)}{\pi_{\text{ref}}(y | x)} + \beta \log Z(x)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁸ 视频画面时间区间：01:00:30–01:00:45。

$$G_7 = \frac{B_7}{C_7 + \lambda R_7 + \epsilon}$$

- B_7 是本节方法带来的质量、吞吐或覆盖收益。
- C_7 是新增计算、显存、通信、数据或标注成本。
- R_7 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_7 \leq C_{\max}, \quad R_7 \leq R_{\max}, \quad Q_7 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

8.1 AI feedback 推动反馈数据规模扩张

核心判断。“AI feedback 推动反馈数据规模扩张”是“从 SFT 到 PPO”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 19 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“AI feedback 推动反馈数据规模扩张”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 19: AI feedback 推动反馈数据规模扩张¹⁹

8.2 SFT 学分布而 RLHF 优化可测奖励

核心判断。“SFT 学分布而 RLHF 优化可测奖励”是“从 SFT 到 PPO”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 20 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“SFT 学分布而 RLHF 优化可测奖励”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁹视频画面时间区间：01:03:15–01:03:30。

From imitation to optimization

Imitation (SFT)

Fit $\hat{p}(y|x) \approx p^*(y|x)$ for some reference distribution $p^*(y|x)$

- Pure generative modelling perspective
- Requires samples from reference policy

Optimization (RLHF)

Find $\hat{p}(y|x)$ such that $\max_p E_p[R(y, x)]$ for a reward $R(y, x)$

- Maximize some reward function that we can measure
- LMs are policies, not a model of some distribution

图 20: SFT 学分布而 RLHF 优化可测奖励²⁰

8.3 PPO 通过裁剪比率稳定策略更新

核心判断。“PPO 通过裁剪比率稳定策略更新”是“从 SFT 到 PPO”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 21 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“PPO 通过裁剪比率稳定策略更新”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁰视频画面时间区间：01:06:00–01:06:15。

PPO – at a conceptual level

A brief (and high level) intro to the various ideas in PPO..

Attempt 1: Policy gradients (variances are too high)

$$\nabla_{\theta} E_{p_{\theta}}[R(z)] = E_{p_{\theta}}[R(z) \nabla_{\theta} \log p_{\theta}(z)]$$

Attempt 2: TRPO (Linearize the problem around the current policy)

$$\begin{aligned} & \underset{\theta}{\text{maximize}} && \hat{\mathbb{E}}_t \left[\frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)} \hat{A}_t \right] \\ & \text{subject to} && \hat{\mathbb{E}}_t [\text{KL}[\pi_{\theta_{\text{old}}}(\cdot | s_t), \pi_{\theta}(\cdot | s_t)]] \leq \delta. \end{aligned}$$

Attempt 3: PPO (Clip the ratios at some eps)

$$L(s, a, \theta_k, \theta) = \min \left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_k}(a|s)} A^{\pi_{\theta_k}}(s, a), \text{clip} \left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_k}(a|s)}, 1 - \epsilon, 1 + \epsilon \right) A^{\pi_{\theta_k}}(s, a) \right)$$

图 21: PPO 通过裁剪比率稳定策略更新²¹

8.4 本章小结

“从 SFT 到 PPO” 的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。模型能复述引用并不代表事实可靠；少量群体的偏好会被放大，优化奖励也会偏离真实用户目标。

9 DPO 与 RLHF 失效模式

本节路线

本节依次处理：DPO 从 KL 正则化最优策略推导偏好目标、DPO 对优选与拒绝响应施加相反梯度、奖励过拟合和模式坍塌是 RLHF 风险。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L_{\text{DPO}} = -\log \sigma \left(\beta \log \frac{\pi_{\theta}(y^+)}{\pi_{\text{ref}}(y^+)} - \beta \log \frac{\pi_{\theta}(y^-)}{\pi_{\text{ref}}(y^-)} \right)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²¹ 视频画面时间区间：01:08:45–01:09:00。

$$G_8 = \frac{B_8}{C_8 + \lambda R_8 + \epsilon}$$

- B_8 是本节方法带来的质量、吞吐或覆盖收益。
- C_8 是新增计算、显存、通信、数据或标注成本。
- R_8 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_8 \leq C_{\max}, \quad R_8 \leq R_{\max}, \quad Q_8 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

9.1 DPO 从 KL 正则化最优策略推导偏好目标

核心判断。“DPO 从 KL 正则化最优策略推导偏好目标”是“DPO 与 RLHF 失效模式”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 22 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“DPO 从 KL 正则化最优策略推导偏好目标”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

DPO – derivation from the RLHF formula

Our goal is to optimize

$$\max_{\pi_{\theta}} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(y|x)} [r_{\phi}(x, y)] - \beta \mathbb{D}_{\text{KL}}[\pi_{\theta}(y|x) \parallel \pi_{\text{ref}}(y|x)]$$

Assume that the policy π is the set of all policies (nonparametric assumption).

The maximizer is then,

$$\pi_r(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right)$$

Solve for the ‘implied reward’

$$r(x, y) = \beta \log \frac{\pi_r(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x).$$

(This is the equivalence also used in the kimi-think paper)

图 22: DPO 从 KL 正则化最优策略推导偏好目标²²

9.2 DPO 对优选与拒绝响应施加相反梯度

核心判断。“DPO 对优选与拒绝响应施加相反梯度”是“DPO 与 RLHF 失效模式”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 23 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“DPO 对优选与拒绝响应施加相反梯度”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²²视频画面时间区间：01:11:30–01:11:45。

DPO updates and components

In some sense, reduces to “pos gradient on good, neg gradient on bad”

What does the DPO update do? For a mechanistic understanding of DPO, it is useful to analyze the gradient of the loss function $\mathcal{L}_{\text{DPO}}$. The gradient with respect to the parameters θ can be written as:

$$\nabla_{\theta} \mathcal{L}_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\beta \mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} \left[\underbrace{\sigma(\hat{r}_{\theta}(x, y_l) - \hat{r}_{\theta}(x, y_w))}_{\text{higher weight when reward estimate is wrong}} \left[\underbrace{\nabla_{\theta} \log \pi(y_w | x)}_{\text{increase likelihood of } y_w} - \underbrace{\nabla_{\theta} \log \pi(y_l | x)}_{\text{decrease likelihood of } y_l} \right] \right],$$

(Scaled by ‘prediction error’ of the implied reward model)

图 23: DPO 对优选与拒绝响应施加相反梯度²³

9.3 奖励过拟合和模式坍缩是 RLHF 风险

核心判断。“奖励过拟合和模式坍缩是 RLHF 风险”是“DPO 与 RLHF 失效模式”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 24 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


常见失效模式

围绕“奖励过拟合和模式坍缩是 RLHF 风险”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²³视频画面时间区间：01:14:15–01:14:30。

Things to watch out for in RLHF

Overoptimization / overfitting on the reward



Mode collapse / entropy




图 24: 奖励过拟合和模式坍缩是 RLHF 风险²⁴

9.4 本章小结

“DPO 与 RLHF 失效模式”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。模型能复述引用并不代表事实可靠；少量群体的偏好会被放大，优化奖励也会偏离真实用户目标。

10 代码化复现：最小机制

下面的片段保留本讲最核心的程序结构，用于把公式和系统过程落到可执行对象。它不是生产实现；实际复现还需补充张量形状断言、数值精度、同步、随机种子、数据版本和端到端测试。

Listing 1: Lecture 15 机制伪代码

```
1 def dpo_loss(logp_pos, logp_neg, ref_pos, ref_neg, beta):  
2     margin = (logp_pos - logp_neg) - (ref_pos - ref_neg)  
3     return -logsigmoid(beta * margin).mean()
```

复现检查单

先写正确性基线，再记录资源基线；每次只改变一个机制；同时保存直接中间量和最终指标；对随机算法报告多次运行；对数据与评测保存不可变版本标识。

²⁴视频画面时间区间：01:17:00–01:17:15。

10.1 本章小结

代码的价值在于暴露状态、顺序和边界。若一个概念无法写成输入、变换、状态、输出和断言，它通常还没有被真正理解。

11 总结与延伸

一页压缩

本讲的主问题是：怎样用 SFT、偏好数据和奖励优化获得更可控的语言模型，同时避免知识污染、标注偏差和奖励过拟合？统一答案是：后训练把行为示范、偏好比较和策略优化串起来；数据如何产生与由谁标注，和优化算法同样重要。

第一，优先理解机制而不是产品名。模型、硬件、数据和评测不断更新，但张量形状、状态位置、目标函数、通信边界和测量误差仍然是稳定的分析对象。第二，所有优化都要写出代价守恒：减少某一种成本通常会增加另一种成本或风险。第三，把小规模实验推广到大规模之前，必须检查瓶颈是否改变、数据分布是否改变、实现常数是否仍在同一数量级。第四，最可靠的课程笔记应允许读者沿时间轴注回到原视频，并沿官方材料找到公式或代码出处。

开放问题

模型能复述引用并不代表事实可靠；少量群体的偏好会被放大，优化奖励也会偏离真实用户目标。后续实验应把这一风险写成可观测量和停止条件，而不是留在讨论部分。

11.1 本章小结

完成本讲后，读者应能用统一语言解释每个主题的输入、状态、变换、输出、资源成本和失败模式，并据此设计一个含基线、消融、误差条和证据记录的最小实验。

12 资料来源与审计边界

- 课程主页：<https://cs336.stanford.edu/>。
- 视频：<https://www.youtube.com/watch?v=2oH6PWPrYFo>。
- Stanford 官方材料：lecture_15.pdf；客座讲座若无官方文件则以视频和字幕为主。
- 本地证据：audio.srt、figure_manifest.tsv、figure_verification.txt、teaching_atoms.tsv、numerical_claims.tsv。

12.1 本章小结

本笔记覆盖播放列表中的本讲内容与课程主页当日可取得的官方材料。没有官方讲义的客座讲座不会被伪装成有讲义；讲者口头推测、本笔记分析框架和官方公式在文字中分别标明。