

Stanford CS336: Language Modeling from Scratch

Lecture 16: Post-Training: RLVR

Spring 2026 中文精讲笔记

主讲: Tatsunori Hashimoto



频道: Stanford Online

发布日期: 2026-05-27

时长: 1:15:50

视频: <https://www.youtube.com/watch?v=dIFAi87Ws4E>

官方主页: <https://cs336.stanford.edu/>

目录

1 导读：问题、证据与阅读方法	2
2 RLVR 的目标	2
3 PPO GAE 与语言模型	7
4 GRPO 组相对优势	11
5 长度偏差和目标修正	15
6 R1 Kimi 与蒸馏	19
7 数据课程和奖励验证	23
8 RL 推理基础设施	27
9 专家迭代与智能体 RL	31
10 代码化复现：最小机制	35
11 总结与延伸	36
12 资料来源与审计边界	36

1 导读：问题、证据与阅读方法

本讲主问题

可验证奖励怎样让模型在数学、代码和智能体环境中通过强化学习提高推理能力，哪些现象又可能只是目标偏差？

RLVR 的闭环由采样、验证、优势估计、策略更新和新数据课程组成；任何一环的偏差都会改变最终行为。本笔记以课程视频、人工字幕和 Stanford 官方讲义或代码为共同证据源。图像均来自每十五秒抽帧后的人工接触表审查，时间脚注可回到原视频复核；公式区分课程机制关系和本笔记的决策分析框架。学习时建议先读主问题，再沿“机制-资源-失败模式-验证指标”四列整理自己的实验。

首先排除的误读

组内归一化、长度归一化和基础模型先验会制造伪涌现；高通过率也可能来自奖励漏洞或测试污染。

1.1 关键数字核对

主张	数值或关系	视频时间
GRPO 优势归一化范围	组内 G 个样本	00:15:00
Kimi 蒸馏轨迹	约 800K	00:36:00
Qwen 少量 GRPO 数据	3995 examples	00:58:00
SWE-Hero 智能体轨迹	约 13K	01:08:00

1.2 本章小结

本章建立证据边界：视频解释提供因果和强调，官方材料提供公式与代码，精选帧提供可核查的视觉状态。后文每个主题都同时回答“为何重要、怎样工作、怎样失败、怎样验证”，避免把课程压缩成术语目录。

2 RLVR 的目标

本节路线

本节依次处理：可验证奖励把强化学习扩展到数学代码等任务、PPO 是通用强化学习优化器基线、语言模型 PPO 包含策略价值奖励和参考模型、广义优势估计平衡偏差与方差。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$A_t^{\text{GAE}} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。

- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_1 = \frac{B_1}{C_1 + \lambda R_1 + \varepsilon}$$

- B_1 是本节方法带来的质量、吞吐或覆盖收益。
- C_1 是新增计算、显存、通信、数据或标注成本。
- R_1 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_1 \leq C_{\max}, \quad R_1 \leq R_{\max}, \quad Q_1 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

2.1 可验证奖励把强化学习扩展到数学代码等任务

核心判断。“可验证奖励把强化学习扩展到数学代码等任务”是“RLVR 的目标”中的一个可检验设计选择，而不是只需记忆的产品名。可验证奖励要明确验证器覆盖和漏洞，组相对优势要检查方差与长度偏差；能力变化需用新题和执行轨迹验证，不能只看训练奖励。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 1 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“可验证奖励把强化学习扩展到数学代码等任务”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

The goal – expand the scope and power of RL

With RLHF: we can't cleanly scale out due to overoptimization



Can we work in domains where RL excels? Where we optimize *exactly* what we want




图 1: 可验证奖励把强化学习扩展到数学代码等任务¹

2.2 PPO 是通用强化学习优化器基线

核心判断。“PPO 是通用强化学习优化器基线”是“RLVR 的目标”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 2 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


复现实验记录

围绕“PPO 是通用强化学习优化器基线”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹视频画面时间区间：00:02:30–00:02:45。

PPO

Policy gradient method for optimizing rewards in actual RL tasks..



From the PPO announcement blog (2017)



OpenAI Five (2019)

图 2: PPO 是通用强化学习优化器基线²

2.3 语言模型 PPO 包含策略价值奖励和参考模型

核心判断。“语言模型 PPO 包含策略价值奖励和参考模型”是“RLVR 的目标”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 3 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


常见失效模式

围绕“语言模型 PPO 包含策略价值奖励和参考模型”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²视频画面时间区间：00:05:15–00:05:30。

PPO – idealization (?) for language models

In the language model setting..



Pretty similar to the RL formulation. Actions operate over tokens, big dense reward at the very end operating on full sequence

[From Zheng et al 2023]

图 3: 语言模型 PPO 包含策略价值奖励和参考模型³

2.4 广义优势估计平衡偏差与方差

核心判断。“广义优势估计平衡偏差与方差”是“RLVR 的目标”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 4 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“广义优势估计平衡偏差与方差”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

³视频画面时间区间：00:07:45–00:08:00。

PPO in practice – generalized advantage estimate

Instead of reward, we use advantages

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} := \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}^V \quad \text{where} \quad \delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t),$$

```
88 def _estimate_advantage(self, rewards: Tensor, values: Tensor) -> Dict[str, Tensor]:
89     """Generalized advantage estimation.
90
91     Reference:
92     https://arxiv.org/abs/1506.02438
93
94     """
95     if self.args.whiten_rewards:
96         rewards = torch_ops.whiten(rewards, shift_mean=False)
97     lastgaelam = 0
98     advantages_reversed = []
99     gen_length = self.args.response_len
100     for t in reversed(range(gen_length)):
101         nextvalues = values[t, t+1] if t < gen_length - 1 else 0.0
102         delta = rewards[t, t] + self.args.gamma * nextvalues - values[t, t]
103         lastgaelam = delta + self.args.gamma * self.args.lam * lastgaelam
104         advantages_reversed.append(lastgaelam)
105     advantages = torch.stack(advantages_reversed[::-1], dim=1)
106     returns = advantages + values
107     advantages = torch_ops.whiten(advantages, shift_mean=True)
108     return dict(returns=returns, advantages=advantages)
```

Funny detail – this is a bandit problem and gamma=lambda=1 works – this is the reward-to-go vs the value



图 4: 广义优势估计平衡偏差与方差⁴

2.5 本章小结

“RLVR 的目标”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。组内归一化、长度归一化和基础模型先验会制造伪涌现；高通过率也可能来自奖励漏洞或测试污染。

3 PPO GAE 与语言模型

本节路线

本节依次处理：GRPO 用组内归一化奖励替代价值网络、GRPO 与 PPO 的目标函数对照、组内 z-score 构成 GRPO 优势。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁴视频画面时间区间：00:10:30–00:10:45。

$$G_2 = \frac{B_2}{C_2 + \lambda R_2 + \epsilon}$$

- B_2 是本节方法带来的质量、吞吐或覆盖收益。
- C_2 是新增计算、显存、通信、数据或标注成本。
- R_2 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_2 \leq C_{\max}, \quad R_2 \leq R_{\max}, \quad Q_2 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

3.1 GRPO 用组内归一化奖励替代价值网络

核心判断。“GRPO 用组内归一化奖励替代价值网络”是“PPO GAE 与语言模型”中的一个可检验设计选择，而不是只需记忆的产品名。可验证奖励要明确验证器覆盖和漏洞，组相对优势要检查方差与长度偏差；能力变化需用新题和执行轨迹验证，不能只看训练奖励。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 5 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“GRPO 用组内归一化奖励替代价值网络”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

New kid on the block: GRPO

What's GRPO?

- Start with PPO (many parts are similar)
- Remove the value function / advantage computation
- Calculate the advantage as “z-score within group”

Group Relative Policy Optimization In order to save the training costs of RL, we adopt Group Relative Policy Optimization (GRPO) (Shao et al., 2024), which foregoes the critic model that is typically the same size as the policy model, and estimates the baseline from group scores instead. Specifically, for each question q , GRPO samples a group of outputs $\{o_1, o_2, \dots, o_G\}$ from the old policy $\pi_{\theta_{old}}$ and then optimizes the policy model π_{θ} by maximizing the following objective:

$$\mathcal{J}_{GRPO}(\theta) = \mathbb{E}[q \sim P(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{old}}(O|q)] \frac{1}{G} \sum_{i=1}^G \left(\min \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)} A_i, \text{clip} \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)}, 1 - \epsilon, 1 + \epsilon \right) A_i \right) - \beta \mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) \right), \quad (1)$$

$$\mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) = \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - \log \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - 1, \quad (2)$$

where ϵ and β are hyper-parameters, and A_i is the advantage, computed using a group of rewards $\{r_1, r_2, \dots, r_G\}$ corresponding to the outputs within each group:

$$A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \dots, r_G\})}{\text{std}(\{r_1, r_2, \dots, r_G\})}. \quad (3)$$

(PPO for reference)

$$\min \left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_k}(a|s)} A^{\pi_{\theta_k}}(s, a), \text{clip} \left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_k}(a|s)}, 1 - \epsilon, 1 + \epsilon \right) A^{\pi_{\theta_k}}(s, a) \right)$$

In the *online* case (rollout+immediate update), this is just policy gradient with group normalized rewards



图 5: GRPO 用组内归一化奖励替代价值网络⁵

3.2 GRPO 与 PPO 的目标函数对照

核心判断。“GRPO 与 PPO 的目标函数对照”是“PPO GAE 与语言模型”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 6 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“GRPO 与 PPO 的目标函数对照”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁵视频画面时间区间：00:13:00–00:13:15。

New kid on the block: GRPO

What's GRPO?

- Start with PPO (many parts are similar)
- Remove the value function / advantage computation
- Calculate the advantage as “z-score within group”

Group Relative Policy Optimization In order to save the training costs of RL, we adopt Group Relative Policy Optimization (GRPO) (Shao et al., 2024), which foregoes the critic model that is typically the same size as the policy model, and estimates the baseline from group scores instead. Specifically, for each question q , GRPO samples a group of outputs $\{o_1, o_2, \dots, o_G\}$ from the old policy $\pi_{\theta_{old}}$ and then optimizes the policy model π_{θ} by maximizing the following objective:

$$\mathcal{J}_{GRPO}(\theta) = \mathbb{E}[q \sim P(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{old}}(O|q)] \frac{1}{G} \sum_{i=1}^G \left(\min \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)} A_i, \text{clip} \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)}, 1 - \epsilon, 1 + \epsilon \right) A_i \right) - \beta \mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) \right), \quad (1)$$

$$\mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) = \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - \log \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - 1, \quad (2)$$

where ϵ and β are hyper-parameters, and A_i is the advantage, computed using a group of rewards $\{r_1, r_2, \dots, r_G\}$ corresponding to the outputs within each group:

$$A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \dots, r_G\})}{\text{std}(\{r_1, r_2, \dots, r_G\})}. \quad (3)$$

(PPO for reference)

$$\min \left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_k}(a|s)} A^{\pi_{\theta_k}}(s, a), \text{clip} \left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_k}(a|s)}, 1 - \epsilon, 1 + \epsilon \right) A^{\pi_{\theta_k}}(s, a) \right)$$

In the *online* case (rollout+immediate update), this is just policy gradient with group normalized rewards



图 6: GRPO 与 PPO 的目标函数对照⁶

3.3 组内 z-score 构成 GRPO 优势

核心判断。“组内 z-score 构成 GRPO 优势”是“PPO GAE 与语言模型”中的一个可检验设计选择，而不是只需记忆的产品名。可验证奖励要明确验证器覆盖和漏洞，组相对优势要检查方差与长度偏差；能力变化需用新题和执行轨迹验证，不能只看训练奖励。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 7 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“组内 z-score 构成 GRPO 优势”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁶视频画面时间区间：00:15:30–00:15:45。

Advantage computation is also very simple..

Basically just the ‘vanilla’ GRPO setup.

Main difference here is just the $1e-4$ stability factor in the std calculation

```
assert len(all_generations) == len(all_finish_reasons)
assert len(all_generations) == len(samples) * GENERATIONS_PER_SAMPLE

# Process responses and calculate rewards
groups = [
    list(range(i, i + GENERATIONS_PER_SAMPLE))
    for i in range(0, len(all_generations), GENERATIONS_PER_SAMPLE)
]
# example: [[0, 1, 2], [3, 4, 5], [6, 7, 8]]
all_query_token_ids, all_responses_token_ids, all_advantages = [], [], []

stats = {
    "response_length": [],
    "rewards": [],
    "non_stop_rate": [],
}

for sample, group_indices in zip(samples, groups):
    finish_reasons = [all_finish_reasons[i] for i in group_indices]
    response_token_ids = [all_generations[i] for i in group_indices]
    responses = tokenizer.batch_decode(response_token_ids, skip_special_tokens=False)

    rewards_and_metrics = [compute_reward(resp, sample) for resp in responses]
    rewards, reward_metrics = zip(*rewards_and_metrics)

    rewards = np.array(rewards) # (group_size)
    response_advantages = (rewards - rewards.mean()) / (rewards.std() + 1e-4)

    advantages = []
    (resp_adv, resp) in zip(response_advantages, response_token_ids):
        all_query_token_ids.extend([sample["input_ids"] + GENERATIONS_PER_SAMPLE])
        all_responses_token_ids.extend(response_token_ids)
        all_advantages.extend(advantages)

    stats["rewards"].extend(rewards)
    stats["non_stop_rate"].extend([fr != "stop" for fr in finish_reasons])
    stats["response_length"].extend([len(ids) for ids in response_token_ids])
    for m, v in reward_metrics:
        stats.setdefault(f"reward_metrics/{m}", []).append(v)

episodes = {
    "all_query_token_ids": all_query_token_ids,
    "all_response_token_ids": all_responses_token_ids,
    "all_advantages": all_advantages,
}

return episodes, stats
```



图 7: 组内 z-score 构成 GRPO 优势⁷

3.4 本章小结

“PPO GAE 与语言模型”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。组内归一化、长度归一化和基础模型先验会制造伪涌现；高通过率也可能来自奖励漏洞或测试污染。

4 GRPO 组相对优势

本节路线

本节依次处理：leave-one-out 基线解释组相对优势、长度归一化会改变 GRPO 对响应的偏好、DeepSeek R1 Kimi K1.5 与 Qwen 的 RLVR 配方。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$A_i = \frac{r_i - \text{mean}(r_{1:G})}{\text{std}(r_{1:G}) + \epsilon}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁷视频画面时间区间：00:18:15–00:18:30。

$$G_3 = \frac{B_3}{C_3 + \lambda R_3 + \epsilon}$$

- B_3 是本节方法带来的质量、吞吐或覆盖收益。
- C_3 是新增计算、显存、通信、数据或标注成本。
- R_3 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_3 \leq C_{\max}, \quad R_3 \leq R_{\max}, \quad Q_3 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

4.1 leave-one-out 基线解释组相对优势

核心判断。“leave-one-out 基线解释组相对优势”是“GRPO 组相对优势”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 8 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“leave-one-out 基线解释组相对优势”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Thinking carefully about the GRPO objective..

The key difference in GRPO vs PPO: the advantage

$$A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \dots, r_G\})}{\text{std}(\{r_1, r_2, \dots, r_G\})}.$$

Is this good? A minor RL detour..

Baselining: We can subtract any state-dependent term from our rewards

13.4 REINFORCE with Baseline

The policy gradient theorem (13.5) can be generalized to include a comparison of the action value to an arbitrary *baseline* $b(s)$:

$$\nabla J(\theta) \propto \sum_s \mu(s) \sum_a (q_\pi(s, a) - b(s)) \nabla \pi(a|s, \theta). \quad (13.10)$$

The baseline can be any function, even a random variable, as long as it does not vary with a ; the equation remains valid because the subtracted quantity is zero:

$$\sum_a b(s) \nabla \pi(a|s, \theta) = b(s) \nabla \sum_a \pi(a|s, \theta) = b(s) \nabla 1 = 0.$$

The policy gradient theorem with baseline (13.10) can be used to derive an update rule using similar steps as in the previous section. The update rule that we end up with is a new version of REINFORCE that includes a general baseline:

$$\theta_{t+1} \leftarrow \theta_t + \alpha \left(G_t - b(S_t) \right) \frac{\nabla \pi(A_t|S_t, \theta_t)}{\pi(A_t|S_t, \theta_t)}. \quad (13.11)$$

Sutton and Barto

图 8: leave-one-out 基线解释组相对优势⁸

4.2 长度归一化会改变 GRPO 对响应的偏好

核心判断。“长度归一化会改变 GRPO 对响应的偏好”是“GRPO 组相对优势”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 9 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“长度归一化会改变 GRPO 对响应的偏好”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁸视频画面时间区间：00:20:45–00:21:00。

Length biases of GRPO

What do these terms do? **Stdev** – upweights too easy or hard questions.

Length normalization:

Response-level length bias: This arises from dividing by $|o_i|$. For positive advantages ($\hat{A}_{i,j} > 0$, indicating a correct response), this bias results in greater gradient updates for shorter responses, leading the policy to favor brevity in correct answers. Conversely, for negative advantages ($\hat{A}_{i,j} < 0$, indicating an incorrect response), longer responses are penalized less due to their larger $|o_i|$, causing the policy to prefer lengthier responses among incorrect ones.

What does the fix do?




图 9: 长度归一化会改变 GRPO 对响应的偏好⁹

4.3 DeepSeek R1 Kimi K1.5 与 Qwen 的 RLVR 配方

核心判断。“DeepSeek R1 Kimi K1.5 与 Qwen 的 RLVR 配方”是“GRPO 组相对优势”中的一个可检验设计选择，而不是只需记忆的产品名。可验证奖励要明确验证器覆盖和漏洞，组相对优势要检查方差与长度偏差；能力变化需用新题和执行轨迹验证，不能只看训练奖励。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 10 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“DeepSeek R1 Kimi K1.5 与 Qwen 的 RLVR 配方”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁹视频画面时间区间：00:23:30–00:23:45。

Case studies

Let's look at a few representative open models with RLVR.




图 10: DeepSeek R1 Kimi K1.5 与 Qwen 的 RLVR 配方¹⁰

4.4 本章小结

“GRPO 组相对优势”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。组内归一化、长度归一化和基础模型先验会制造伪涌现；高通过率也可能来自奖励漏洞或测试污染。

5 长度偏差和目标修正

本节路线

本节依次处理：R1-Zero 直接从基础模型进行可验证奖励训练、Dr. GRPO 分析长度偏差与基础模型先验、SFT 初始化改善冷启动但来源并不总透明。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\text{old}}(a_t | s_t)}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁰视频画面时间区间：00:26:00–00:26:15。

$$G_4 = \frac{B_4}{C_4 + \lambda R_4 + \epsilon}$$

- B_4 是本节方法带来的质量、吞吐或覆盖收益。
- C_4 是新增计算、显存、通信、数据或标注成本。
- R_4 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_4 \leq C_{\max}, \quad R_4 \leq R_{\max}, \quad Q_4 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

5.1 R1-Zero 直接从基础模型进行可验证奖励训练

核心判断。“R1-Zero 直接从基础模型进行可验证奖励训练”是“长度偏差和目标修正”中的一个可检验设计选择，而不是只需记忆的产品名。每种并行都要列出切分维、复制状态和通信原语；端到端收益由通信是否可隐藏、链路拓扑和负载均衡决定。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 11 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“R1-Zero 直接从基础模型进行可验证奖励训练”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Controlled setting – R1 zero.

Setup:

Rewards

- Accuracy rewards (is it correct?)
- Format rewards (use thinking tags)

Data (not public)

Base model: Deepseek-V3

Results: a bit worse than Openai O1

Model	AIME 2024		MATH-500	GPQA Diamond	LiveCode Bench	CodeForces
	pass@1	cons@64	pass@1	pass@1	pass@1	rating
OpenAI-o1-mini	63.6	80.0	90.0	60.0	53.8	1820
OpenAI-o1-0912	74.4	83.3	94.8	77.3	63.4	1843
DeepSeek-R1-Zero	71.0	86.7	95.9	73.3	50.0	1444

图 11: R1-Zero 直接从基础模型进行可验证奖励训练¹¹

5.2 Dr. GRPO 分析长度偏差与基础模型先验

核心判断。“Dr. GRPO 分析长度偏差与基础模型先验”是“长度偏差和目标修正”中的一个可检验设计选择，而不是只需记忆的产品名。可验证奖励要明确验证器覆盖和漏洞，组相对优势要检查方差与长度偏差；能力变化需用新题和执行轨迹验证，不能只看训练奖励。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 12 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录


围绕“Dr. GRPO 分析长度偏差与基础模型先验”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹¹视频画面时间区间：00:28:45–00:29:00。

But maybe a bit overstated

From some follow-up analyses in Dr. GRPO..

Length due to
biased objective?



Base model
already has 'aha'

图 12: Dr. GRPO 分析长度偏差与基础模型先验¹²

5.3 SFT 初始化改善冷启动但来源并不总透明

核心判断。“SFT 初始化改善冷启动但来源并不总透明”是“长度偏差和目标修正”中的一个可检验设计选择，而不是只需记忆的产品名。先区分示范分布、成对偏好和策略奖励三类监督；训练记录必须保留参考策略、采样温度、标注者群体和 KL 或熵轨迹。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 13 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“SFT 初始化改善冷启动但来源并不总透明”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹²视频画面时间区间：00:31:15–00:31:30。

SFT initialization..

Unlike DeepSeek-R1-Zero, to prevent the early unstable cold start phase of RL training from the base model, for DeepSeek-R1 we construct and collect a small amount of long CoT data to fine-tune the model as the initial RL actor. To collect such data, we have explored several approaches: using few-shot prompting with a long CoT as an example, directly prompting models to generate detailed answers with reflection and verification, gathering DeepSeek-R1-Zero outputs in a readable format, and refining the results through post-processing by human annotators.

Start with plain ol (long) CoT, then maybe additional verification (vague)

- **Claimed Benefit:** interpretability
- **Note:** Origins on the data not quite clear..

图 13: SFT 初始化改善冷启动但来源并不总透明¹³

5.4 本章小结

“长度偏差和目标修正”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。组内归一化、长度归一化和基础模型先验会制造伪涌现；高通过率也可能来自奖励漏洞或测试污染。

6 R1 Kimi 与蒸馏

本节路线

本节依次处理：蒸馏把长思维链能力转移给较小模型、课程难度失败率和格式共同决定 RL 数据筛选、Kimi 使用参考策略正则化的奖励目标。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$J_{\text{GRPO}} = E[\min(r_t A_i, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) A_i) - \beta K L]$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹³视频画面时间区间：00:33:45–00:34:00。

$$G_5 = \frac{B_5}{C_5 + \lambda R_5 + \epsilon}$$

- B_5 是本节方法带来的质量、吞吐或覆盖收益。
- C_5 是新增计算、显存、通信、数据或标注成本。
- R_5 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_5 \leq C_{\max}, \quad R_5 \leq R_{\max}, \quad Q_5 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

6.1 蒸馏把长思维链能力转移给较小模型

核心判断。“蒸馏把长思维链能力转移给较小模型”是“R1 Kimi 与蒸馏”中的一个可检验设计选择，而不是只需记忆的产品名。可验证奖励要明确验证器覆盖和漏洞，组相对优势要检查方差与长度偏差；能力变化需用新题和执行轨迹验证，不能只看训练奖励。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 14 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“蒸馏把长思维链能力转移给较小模型”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Distillation – can we get non-reasoning models to reason?

Pipeline

Have R1 generate CoT traces (800k!)

Teach Qwen 2.5 via distillation

Model	AIME 2024		MATH-500	GPQA Diamond	LiveCode Bench	CodeForces
	pass@1	cons@64	pass@1	pass@1	pass@1	rating
GPT-4o-0513	9.3	13.4	74.6	49.9	32.9	759
Claude-3.5-Sonnet-1022	16.0	26.7	78.3	65.0	38.9	717
OpenAI-o1-mini	63.6	80.0	90.0	60.0	53.8	1820
QwQ-32B-Preview	50.0	60.0	90.6	54.5	41.9	1316
DeepSeek-R1-Distill-Qwen-1.5B	28.9	52.7	83.9	33.8	16.9	954
DeepSeek-R1-Distill-Qwen-7B	55.5	83.3	92.8	49.1	37.6	1189
DeepSeek-R1-Distill-Qwen-14B	69.7	80.0	93.9	59.1	53.1	1481
DeepSeek-R1-Distill-Qwen-32B	72.6	83.3	94.3	62.1	57.2	1691
DeepSeek-R1-Distill-Llama-8B	50.4	80.0	89.1	49.0	39.6	1205
DeepSeek-R1-Distill-Llama-70B	70.0	86.7	94.5	65.2	57.5	1633

图 14: 蒸馏把长思维链能力转移给较小模型¹⁴

6.2 课程难度失败率和格式共同决定 RL 数据筛选

核心判断。“课程难度失败率和格式共同决定 RL 数据筛选”是“R1 Kimi 与蒸馏”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 15 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“课程难度失败率和格式共同决定 RL 数据筛选”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁴视频画面时间区间：00:36:30–00:36:45。

Data curation + SFT

Data curation

- Standard curation across math-style settings, balancing topics

To achieve diverse coverage in the prompt set, we employ automatic filters to select questions that require rich reasoning and are straightforward to evaluate. Our dataset includes problems from various domains, such as STEM fields, competitions, and general reasoning tasks, incorporating both text-only and image-text question-answering data. Furthermore, we developed a tagging system to categorize prompts by domain and discipline, ensuring balanced representation across different subject areas (M. Li et al. 2023; W. Liu et al. 2023).

- Exclude multiple choice / true false (false positives)
- Select only examples that models fail on best-of-8

We adopt a model-based approach that leverages the model's own capacity to adaptively assess the difficulty of each prompt. Specifically, for every prompt, an SFT model generates answers ten times using a relatively high sampling temperature. The pass rate is then calculated and used as a proxy for the prompt's difficulty—the lower the pass rate, the higher the difficulty. This approach allows difficulty evaluation to be aligned with the model's intrinsic capabilities, making it highly effective for RL training. By leveraging this method, we can prefilter most trivial cases and easily explore different sampling strategies during RL training.

SFT – little description, just described as ‘prompt engineering’ (distillation?)



图 15: 课程难度失败率和格式共同决定 RL 数据筛选¹⁵

6.3 Kimi 使用参考策略正则化的奖励目标

核心判断。“Kimi 使用参考策略正则化的奖励目标”是“R1 Kimi 与蒸馏”中的一个可检验设计选择，而不是只需记忆的产品名。可验证奖励要明确验证器覆盖和漏洞，组相对优势要检查方差与长度偏差；能力变化需用新题和执行轨迹验证，不能只看训练奖励。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 16 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“Kimi 使用参考策略正则化的奖励目标”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁵视频画面时间区间：00:41:45–00:42:00。

Kimi RL

In kimi – reference based reward model, so the optimization problem is

$$\max_{\theta} \mathbb{E}_{(x, y^*) \sim \mathcal{D}} [\mathbb{E}_{(y, z) \sim \pi_{\theta}} [r(x, y, y^*)] - \tau \text{KL}(\pi_{\theta}(x) || \pi_{\theta_i}(x))] ,$$

RL algorithm inspired by DPO-type derivation.

$$r(x, y, y^*) - \tau \log Z = \tau \log \frac{\pi^*(y, z|x)}{\pi_{\theta_i}(y, z|x)} .$$

(Nonparametric assumption + solve for r)

$$L(\theta) = \mathbb{E}_{(x, y^*) \sim \mathcal{D}} \left[\mathbb{E}_{(y, z) \sim \pi_{\theta_i}} \left[\left(r(x, y, y^*) - \tau \log Z - \tau \log \frac{\pi_{\theta}(y, z|x)}{\pi_{\theta_i}(y, z|x)} \right)^2 \right] \right] .$$

Use squared loss as a surrogate

Baselined policy gradient w/ regularization

$$\frac{1}{k} \sum_{j=1}^k \left(\nabla_{\theta} \log \pi_{\theta}(y_j, z_j|x) (r(x, y_j, y^*) - \bar{r}) - \frac{\tau}{2} \nabla_{\theta} \left(\log \frac{\pi_{\theta}(y_j, z_j|x)}{\pi_{\theta_i}(y_j, z_j|x)} \right)^2 \right) .$$



图 16: Kimi 使用参考策略正则化的奖励目标¹⁶

6.4 本章小结

“R1 Kimi 与蒸馏”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。组内归一化、长度归一化和基础模型先验会制造伪涌现；高通过率也可能来自奖励漏洞或测试污染。

7 数据课程和奖励验证

本节路线

本节依次处理：训练思维链变长并不自动等于推理涌现、课程学习和代码数学验证器改善采样效率、rollout 训练与推理系统切换是 RL 基础设施瓶颈。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$R = R_{\text{correct}} + R_{\text{format}} + R_{\text{process}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁶视频画面时间区间：00:44:15–00:44:30。

$$G_6 = \frac{B_6}{C_6 + \lambda R_6 + \epsilon}$$

- B_6 是本节方法带来的质量、吞吐或覆盖收益。
- C_6 是新增计算、显存、通信、数据或标注成本。
- R_6 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_6 \leq C_{\max}, \quad R_6 \leq R_{\max}, \quad Q_6 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

7.1 训练中思维链变长并不自动等于推理涌现


核心判断。“训练中思维链变长并不自动等于推理涌现”是“数据课程和奖励验证”中的一个可检验设计选择，而不是只需记忆的产品名。prefill 可以沿序列并行而 decode 逐 token 串行；服务评估要同时报告首 token、token 间隔、吞吐、尾延迟和显存峰值。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 17 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“训练中思维链变长并不自动等于推理涌现”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Interesting phenomena (?)



Longer CoTs during training

Question: If $a > 1$, then the sum of the real solutions of $\sqrt{a - \sqrt{a + x}} = x$ is equal to

Response: <think>

To solve the equation $\sqrt{a - \sqrt{a + x}} = x$, let's start by squaring both ...

$$(\sqrt{a - \sqrt{a + x}})^2 = x^2 \implies a - \sqrt{a + x} = x^2.$$

Rearrange to isolate the inner square root term:

$$(a - x^2)^2 = a + x \implies a^2 - 2ax^2 + (x^2)^2 = a + x \implies x^4 - 2ax^2 - x + (a^2 - a) = 0$$

...

Wait, wait. Wait. That's an aha moment I can flag here.

Let's reevaluate this step-by-step to identify if the correct sum can be ...

We started with the equation:

$$\sqrt{a - \sqrt{a + x}} = x$$

First, let's square both sides:

$$a - \sqrt{a + x} = x^2 \implies \sqrt{a + x} = a - x^2$$

Next, I could square both sides again, treating the equation: ...

...

'aha' moment?



图 17: 训练中思维链变长并不自动等于推理涌现¹⁷

7.2 课程学习和代码数学验证器改善采样效率

核心判断。“课程学习和代码数学验证器改善采样效率”是“数据课程和奖励验证”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 18 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“课程学习和代码数学验证器改善采样效率”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁷视频画面时间区间：00:46:45–00:47:00。

Additional details

Curriculum

- Assign difficulty labels to dataset, go from easy to hard
- Sample problems proportional to $(1 - \text{success_rate})$ to avoid repeating solved ones

Rewards

- For code – take problems with ground truth solutions, generate new test cases
- For math – 800k samples to train a CoT reward model for answer equivalence checks

During our manual spot checks, the Classic RM achieved an accuracy of approximately **84.4**, while the Chain-of-Thought RM reached **98.5** accuracy. In the RL training process, we adopted the Chain-of-Thought RM to ensure more correct feedback.



图 18: 课程学习和代码数学验证器改善采样效率¹⁸

7.3 rollout 训练与推理系统切换是 RL 基础设施瓶颈

核心判断。“rollout 训练与推理系统切换是 RL 基础设施瓶颈”是“数据课程和奖励验证”中的一个可检验设计选择，而不是只需记忆的产品名。prefill 可以沿序列并行而 decode 逐 token 串行；服务评估要同时报告首 token、token 间隔、吞吐、尾延迟和显存峰值。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 19 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“rollout 训练与推理系统切换是 RL 基础设施瓶颈”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁸视频画面时间区间：00:49:30–00:49:45。

RL Infra

Systems and utilization aspects of RL are very important.

Why is RL hard to make efficient?

- On policy = rollouts, which means (slow) inference
- Switching from training to rollouts often means different frameworks
- Long CoTs can make batches very uneven.




图 19: rollout 训练与推理系统切换是 RL 基础设施瓶颈¹⁹

7.4 本章小结

“数据课程和奖励验证”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。组内归一化、长度归一化和基础模型先验会制造伪涌现；高通过率也可能来自奖励漏洞或测试污染。

8 RL 推理基础设施

本节路线

本节依次处理：RL 与专家迭代的消融比较、Qwen 组合过滤蒸馏与少量 GRPO 数据、推理指令和通用 RLHF 阶段会相互影响。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$p_{\text{sample}}(x) \propto 1 - \text{success_rate}(x)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁹视频画面时间区间：00:52:00–00:52:15。

$$G_7 = \frac{B_7}{C_7 + \lambda R_7 + \epsilon}$$

- B_7 是本节方法带来的质量、吞吐或覆盖收益。
- C_7 是新增计算、显存、通信、数据或标注成本。
- R_7 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_7 \leq C_{\max}, \quad R_7 \leq R_{\max}, \quad Q_7 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。


8.1 RL 与专家迭代的消融比较

核心判断。“RL 与专家迭代的消融比较”是“RL 推理基础设施”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 20 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“RL 与专家迭代的消融比较”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。



Could we avoid RL-style negative gradients and just learn from positives?

图 20: RL 与专家迭代的消融比较²⁰

8.2 Qwen 组合过滤蒸馏与少量 GRPO 数据

核心判断。“Qwen 组合过滤蒸馏与少量 GRPO 数据”是“RL 推理基础设施”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 21 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Qwen 组合过滤蒸馏与少量 GRPO 数据”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁰视频画面时间区间：00:54:45-00:55:00。

SFT + Reasoning RL

We know the playbook by now, and Qwen uses a lot of this..

- Filtering for difficulty (by best-of-n, like kimi)
 - Remove things that the model gets right w/o CoT
 - Remove things too similar to validation data
- Manual filtering for the quality of CoTs (guessing vs getting it right)
- RL with GRPO on **only 3995 examples**



图 21: Qwen 组合过滤蒸馏与少量 GRPO 数据²¹

8.3 推理指令和通用 RLHF 阶段会相互影响

核心判断。“推理指令和通用 RLHF 阶段会相互影响”是“RL 推理基础设施”中的一个可检验设计选择，而不是只需记忆的产品名。prefill 可以沿序列并行而 decode 逐 token 串行；服务评估要同时报告首 token、token 间隔、吞吐、尾延迟和显存峰值。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 22 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“推理指令和通用 RLHF 阶段会相互影响”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²¹视频画面时间区间：00:57:15–00:57:30。

Composition of the different stages

	Benchmark	Stage 2 Reasoning RL	Stage 3 Thinking Mode Fusion		Stage 4 General RL	
		Thinking	Thinking	Non-Thinking	Thinking	Non-Thinking
General Tasks	LiveBench 2024-11-25	68.6	70.9 ^{+2.3}	57.1	74.9 ^{+4.0}	59.8 ^{+2.8}
	Arena-Hard	86.8	89.4 ^{+2.6}	88.5	93.8 ^{+4.4}	92.8 ^{+4.3}
	CounterFactQA*	50.4	61.3 ^{+10.9}	64.3	68.1 ^{+6.8}	66.4 ^{+2.1}
Instruction & Format Following	IFEval strict prompt	73.0	78.4 ^{+5.4}	78.4	85.0 ^{+6.6}	83.2 ^{+4.8}
	Multi-IF	61.4	64.6 ^{+3.2}	65.2	73.0 ^{+8.4}	70.7 ^{+5.5}
	LengthCtrl*	62.6	70.6 ^{+8.0}	84.9	73.5 ^{+2.9}	87.3 ^{+2.4}
	ThinkFollow*	-	88.7		98.9 ^{+10.2}	
Agent	BFCL v3	69.0	68.4 ^{-0.6}	61.5	70.3 ^{+1.9}	63.0 ^{+1.5}
	ToolUse*	63.3	70.4 ^{+7.1}	73.2	85.5 ^{+15.1}	86.5 ^{+13.3}
Knowledge & STEM	MMLU-Redux	91.4	91.0 ^{-0.4}	86.7	90.9 ^{-0.1}	85.7 ^{-1.0}
	GPQA-Diamond	68.8	69.0 ^{+0.2}	50.4	68.4 ^{-0.6}	54.6 ^{+4.3}
Math & Coding	AIME'24	83.8	81.9 ^{-1.9}	28.5	81.4 ^{-0.5}	31.0 ^{+2.5}
	LiveCodeBench v5	68.4	67.2 ^{-1.2}	31.1	65.7 ^{-1.5}	31.3 ^{+0.2}

Note that math/stem abilities go down (a bit) with general purpose RLHF

🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍

图 22: 推理指令和通用 RLHF 阶段会相互影响²²

8.4 本章小结

“RL 推理基础设施”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。组内归一化、长度归一化和基础模型先验会制造伪涌现；高通过率也可能来自奖励漏洞或测试污染。

9 专家迭代与智能体 RL

本节路线

本节依次处理：代码中训练使用仓库级和合成轨迹、Web UX 与 QA 专家数据使用可执行检查、智能体 RL 依赖环境交互与执行反馈。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$\eta_{\text{RL}} = \frac{\text{verified useful tokens}}{\text{rollout GPU seconds}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²²视频画面时间区间：01:00:00–01:00:15。

$$G_8 = \frac{B_8}{C_8 + \lambda R_8 + \epsilon}$$

- B_8 是本节方法带来的质量、吞吐或覆盖收益。
- C_8 是新增计算、显存、通信、数据或标注成本。
- R_8 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_8 \leq C_{\max}, \quad R_8 \leq R_{\max}, \quad Q_8 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

9.1 代码中训练使用仓库级和合成轨迹

核心判断。“代码中训练使用仓库级和合成轨迹”是“专家迭代与智能体 RL”中的一个可检验设计选择，而不是只需记忆的产品名。过滤和去重同时改变质量与覆盖，阈值应通过保留率、重复率和下游损失联合选择；混合权重还要换算成每个来源的有效 epoch。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 23 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“代码中训练使用仓库级和合成轨迹”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Midtraining

Coding and other mid-training data sources

Github

Long-context “repository level” data (concat files) – 600 Billion tokens
Pull request (w/ RAG retrieved context of the repository state)

Common crawl

Joint text+code documents + LLM based parsing of HTML

Synthetic data

LM prompted QA for web documents about coding
Trajectories generated by running coding agents on various environments

Instruction following / Fill-in-the-middle data

图 23: 代码中训练使用仓库级和合成轨迹²³

9.2 Web UX 与 QA 专家数据使用可执行检查

核心判断。“Web UX 与 QA 专家数据使用可执行检查”是“专家迭代与智能体 RL”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 24 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Web UX 与 QA 专家数据使用可执行检查”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²³视频画面时间区间：01:02:30–01:02:45。

Web dev / UX / QA expert

Web dev expert

- SFT on “valid web code” based on checks (VLM + agent actions)

UX expert (train on many tool formats)



QA (standard single turn code synthesis – just more data)

图 24: Web UX 与 QA 专家数据使用可执行检查²⁴

9.3 智能体 RL 依赖环境交互与执行反馈

核心判断。“智能体 RL 依赖环境交互与执行反馈”是“专家迭代与智能体 RL”中的一个可检验设计选择，而不是只需记忆的产品名。可验证奖励要明确验证器覆盖和漏洞，组相对优势要检查方差与长度偏差；能力变化需用新题和执行轨迹验证，不能只看训练奖励。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 25 个图像证据在本讲 25 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“智能体 RL 依赖环境交互与执行反馈”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁴视频画面时间区间：01:05:00–01:05:15。

Agent RL




Figure 7: **Left:** SWE-bench Verified performance vs. RL steps with a reinforced reward-hacking blocker. We also found that a *long-horizon* coding ability emerged in the model during RL training, pushing the average number of agent turns from 50 to 130. **Right:** Performance without the blocker. Even after removing git remotes and future commits, the agent autonomously learns to exploit various git commands to retrieve ground-truth information as model capability increases. To the best of our knowledge, this behavior has not previously been reported.

Model	Size	SWE-Bench Verified		
		SWE-Agent	MiniSWE-Agent	OpenHands
<i>Proprietary Models</i>				
Claude-Opus-4.5	?	78.2	77.8	79.0
Claude-Sonnet-4.5	?	76.0	68.4	74.6
<i>Open-source Models</i>				
DeepSeek-V3.2	671A37	70.2	67.2	72.6
GLM-4.7	358A32	74.2	70.4	70.6
MiniMax-M2.1	230A10	74.8	70.4	71.0
Kimi-K2.5	1000A32	73.2	70.8	–
Qwen3-Coder-Next	80A3	70.6	71.1	71.3

图 25: 智能体 RL 依赖环境交互与执行反馈²⁵

9.4 本章小结

“专家迭代与智能体 RL”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。组内归一化、长度归一化和基础模型先验会制造伪涌现；高通过率也可能来自奖励漏洞或测试污染。

10 代码化复现：最小机制

下面的片段保留本讲最核心的程序结构，用于把公式和系统过程落到可执行对象。它不是生产实现；实际复现还需补充张量形状断言、数值精度、同步、随机种子、数据版本和端到端测试。

Listing 1: Lecture 16 机制伪代码

```

1 reward = verifier(prompt, response)
2 adv = (reward - reward.mean(dim=1, keepdim=True)) / (
3     reward.std(dim=1, keepdim=True) + 1e-6)
4 loss = clipped_policy_loss(policy, old_policy, response, adv)

```

复现检查单

先写正确性基线，再记录资源基线；每次只改变一个机制；同时保存直接中间量和最终指标；对随机算法报告多次运行；对数据与评测保存不可变版本标识。

²⁵视频画面时间区间：01:07:45–01:08:00。

10.1 本章小结

代码的价值在于暴露状态、顺序和边界。若一个概念无法写成输入、变换、状态、输出和断言，它通常还没有被真正理解。

11 总结与延伸

一页压缩

本讲的主问题是：可验证奖励怎样让模型在数学、代码和智能体环境中通过强化学习提高推理能力，哪些现象又可能只是目标偏差？统一答案是：RLVR 的闭环由采样、验证、优势估计、策略更新和新数据课程组成；任何一环的偏差都会改变最终行为。

第一，优先理解机制而不是产品名。模型、硬件、数据和评测不断更新，但张量形状、状态位置、目标函数、通信边界和测量误差仍然是稳定的分析对象。第二，所有优化都要写出代价守恒：减少某一种成本通常会增加另一种成本或风险。第三，把小规模实验推广到大规模之前，必须检查瓶颈是否改变、数据分布是否改变、实现常数是否仍在同一数量级。第四，最可靠的课程笔记应允许读者沿时间脚注回到原视频，并沿官方材料找到公式或代码出处。

开放问题

组内归一化、长度归一化和基础模型先验会制造伪涌现；高通过率也可能来自奖励漏洞或测试污染。后续实验应把这一风险写成可观测量和停止条件，而不是留在讨论部分。

11.1 本章小结

完成本讲后，读者应能用统一语言解释每个主题的输入、状态、变换、输出、资源成本和失败模式，并据此设计一个含基线、消融、误差条和证据记录的最小实验。

12 资料来源与审计边界

- 课程主页：<https://cs336.stanford.edu/>。
- 视频：<https://www.youtube.com/watch?v=dIFAi87Ws4E>。
- Stanford 官方材料：lecture_16.pdf；客座讲座若无官方文件则以视频和字幕为主。
- 本地证据：audio.srt、figure_manifest.tsv、figure_verification.txt、teaching_atoms.tsv、numerical_claims.tsv。

12.1 本章小结

本笔记覆盖播放列表中的本讲内容与课程主页当日可取得的官方材料。没有官方讲义的客座讲座不会被伪装成有讲义；讲者口头推测、本笔记分析框架和官方公式在文字中分别标明。