


Lecture 17: Alignment and Multimodality

Spring 2026 中文精讲笔记

主讲: Percy Liang



频道: Stanford Online

发布日期: 2026-06-04

时长: 1:17:39

视频: <https://www.youtube.com/watch?v=26FtD08ZpOU>

官方主页: <https://cs336.stanford.edu/>

目录

1 导读：问题、证据与阅读方法	2
2 omni 模型与 token 化问题	2
3 CLIP 对比学习	6
4 Vision Transformer 与 SigLIP	10
5 视觉特征注入语言模型	14
6 LLaVA 两阶段训练	18
7 多图视频与动态分辨率	22
8 Qwen-VL 系列	26
9 离散视觉 token 与原生多模态	30
10 代码化复现：最小机制	33
11 总结与延伸	34
12 资料来源与审计边界	34

1 导读：问题、证据与阅读方法

本讲主问题

怎样把图像和视频编码为 Transformer 可消费的表示，并在语义对齐、空间细节、序列长度和训练稳定性之间取舍？

多模态系统由视觉编码器、投影适配器、语言模型和数据课程组成，生成模型还要增加离散 tokenizer 或扩散解码器。本笔记以课程视频、人工字幕和 Stanford 官方讲义或代码为共同证据源。图像均来自每十五秒抽帧后的人工接触表审查，时间脚注可回到原视频复核；公式区分课程机制关系和本笔记的决策分析框架。学习时建议先读主问题，再沿“机制-资源-失败模式-验证指标”四列整理自己的实验。

首先排除的误读

图文对比只保证粗粒度语义；固定分辨率损失细节，视频 token 又会迅速占满上下文，文本和图像熵差异还会破坏联合训练。

1.1 关键数字核对

主张	数值或关系	视频时间
CLIP 图文对	约 400M	00:09:00
CLIP 训练资源	256 TPUv3 × 10 days	00:27:00
SigLIP 训练资源示例	32 TPUv4 × 5 days	00:27:00
常见 CLIP 输入分辨率	336×336	00:11:00
Qwen-VL 长上下文	256K	00:54:00
Qwen2-VL 最大视觉 token	16,384	00:51:00
原生多模态预训练文本	约 2.9T text tokens	01:13:00

1.2 本章小结

本章建立证据边界：视频解释提供因果和强调，官方材料提供公式与代码，精选帧提供可核查的视觉状态。后文每个主题都同时回答“为何重要、怎样工作、怎样失败、怎样验证”，避免把课程压缩成术语目录。

2 omni 模型与 token 化问题

本节路线

本节依次处理：omni 模型统一理解和生成多种模态、CLIP 利用大规模图文对比学习、图像与文本编码器通过批内对比目标对齐。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$s_{ij} = \frac{f_I(I_i)^\top f_T(T_j)}{\tau}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_1 = \frac{B_1}{C_1 + \lambda R_1 + \varepsilon}$$

- B_1 是本节方法带来的质量、吞吐或覆盖收益。
- C_1 是新增计算、显存、通信、数据或标注成本。
- R_1 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_1 \leq C_{\max}, \quad R_1 \leq R_{\max}, \quad Q_1 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

2.1 omni 模型统一理解和生成多种模态

核心判断。“omni 模型统一理解和生成多种模态”是“omni 模型与 token 化问题”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 1 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“omni 模型统一理解和生成多种模态”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 1: omni 模型统一理解和生成多种模态¹

2.2 CLIP 利用大规模图文对比学习

核心判断。“CLIP 利用大规模图文对比学习”是“omni 模型与 token 化问题”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 2 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“CLIP 利用大规模图文对比学习”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹视频画面时间区间：00:02:45–00:03:00。




图 2: CLIP 利用大规模图文对比学习²

2.3 图像与文本编码器通过批内对比目标对齐

核心判断。“图像与文本编码器通过批内对比目标对齐”是“omni 模型与 token 化问题”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 3 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“图像与文本编码器通过批内对比目标对齐”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²视频画面时间区间：00:05:15–00:05:30。




图 3: 图像与文本编码器通过批内对比目标对齐³

2.4 本章小结

“omni 模型与 token 化问题”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。图文对比只保证粗粒度语义；固定分辨率损失细节，视频 token 又会迅速占满上下文，文本和图像熵差异还会破坏联合训练。

3 CLIP 对比学习

本节路线

本节依次处理：图文数据清洗与图像分辨率处理、Vision Transformer 把图像切成 patch token、CLIP 图像数量增长带来零样本精度提升。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L_{\text{CLIP}} = \frac{1}{2}(L_{I \rightarrow T} + L_{T \rightarrow I})$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

³视频画面时间区间：00:08:00–00:08:15。

$$G_2 = \frac{B_2}{C_2 + \lambda R_2 + \epsilon}$$

- B_2 是本节方法带来的质量、吞吐或覆盖收益。
- C_2 是新增计算、显存、通信、数据或标注成本。
- R_2 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_2 \leq C_{\max}, \quad R_2 \leq R_{\max}, \quad Q_2 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

3.1 图文数据清洗与图像分辨率处理

核心判断。“图文数据清洗与图像分辨率处理”是“CLIP 对比学习”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 4 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“图文数据清洗与图像分辨率处理”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 4: 图文数据清洗与图像分辨率处理⁴

3.2 Vision Transformer 把图像切成 patch token

核心判断。“Vision Transformer 把图像切成 patch token”是“CLIP 对比学习”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 5 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Vision Transformer 把图像切成 patch token”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁴视频画面时间区间：00:10:45–00:11:00。




图 5: Vision Transformer 把图像切成 patch token⁵

3.3 CLIP 图像数量增长带来零样本精度提升

核心判断。“CLIP 图像数量增长带来零样本精度提升”是“CLIP 对比学习”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 6 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“CLIP 图像数量增长带来零样本精度提升”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁵视频画面时间区间：00:13:15–00:13:30。




图 6: CLIP 图像数量增长带来零样本精度提升⁶

3.4 本章小结

“CLIP 对比学习”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。图文对比只保证粗粒度语义；固定分辨率损失细节，视频 token 又会迅速占满上下文，文本和图像熵差异还会破坏联合训练。

4 Vision Transformer 与 SigLIP

本节路线

本节依次处理：SigLIP 用 sigmoid 损失改善设备扩展、视觉编码注入语言模型的主要架构、投影器把视觉特征映射到语言嵌入空间。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$L_{\text{SigLIP}} = - \sum_{ij} \log \sigma(z_{ij}s_{ij})$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁶视频画面时间区间：00:21:30–00:21:45。

$$G_3 = \frac{B_3}{C_3 + \lambda R_3 + \epsilon}$$

- B_3 是本节方法带来的质量、吞吐或覆盖收益。
- C_3 是新增计算、显存、通信、数据或标注成本。
- R_3 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_3 \leq C_{\max}, \quad R_3 \leq R_{\max}, \quad Q_3 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

4.1 SigLIP 用 sigmoid 损失改善设备扩展

核心判断。“SigLIP 用 sigmoid 损失改善设备扩展”是“Vision Transformer 与 SigLIP”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 7 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“SigLIP 用 sigmoid 损失改善设备扩展”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

4.2 视觉编码注入语言模型的主要架构

核心判断。“视觉编码注入语言模型的主要架构”是“Vision Transformer 与 SigLIP” 中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 8 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“视觉编码注入语言模型的主要架构”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁷视频画面时间区间：00:26:45—00:27:00。




图 8: 视觉编码注入语言模型的主要架构⁸

4.3 投影器把视觉特征映射到语言嵌入空间

核心判断。“投影器把视觉特征映射到语言嵌入空间”是“Vision Transformer 与 SigLIP”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 9 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“投影器把视觉特征映射到语言嵌入空间”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁸视频画面时间区间：00:29:30–00:29:45。

Answer: The image features a black sport utility vehicle (SUV) ...<omitted>

Response type 2: detailed description

The image is an underground parking area with a black sport utility vehicle (SUV) parked. There are three people in the scene, with one person standing closer to the left side of the vehicle, another person in the middle, and the third person on the right side. They are all working together to pack their luggage into the SUV for a trip. ...<omitted>

Response type 3: complex reasoning

Question: What challenges do these people face?

Answer: In the image, a group of people is standing outside a black SUV in a parking area, surrounded by various pieces of luggage, including suitcases and backpacks. They are facing the challenge of fitting all their luggage into the black SUV. There are multiple suitcases and backpacks to be packed, which suggests that the group has a significant amount of belongings ...<omitted>

136

137 Model:

- Encode images with CLIP (ViT-L/14)
- Linear projection (W) into embedding space (Flamingo and Q-former are more complex)

138

139

140

The diagram illustrates the CLIP architecture. At the bottom, a 'Vision Encoder' processes an input image, producing a visual feature vector Z_v . This vector is then passed through a 'Projection W' block, which maps it to a sequence of hidden states H_v . These states are fed into a 'Language Model f_ϕ '. The language model also takes a 'Language Response' X_a as input and produces a sequence of hidden states H_q . The diagram shows the interaction between the visual and language components, with arrows indicating the flow of information and the projection of visual features into the language embedding space.

图 9: 投影器把视觉特征映射到语言嵌入空间⁹

4.4 本章小结

“Vision Transformer 与 SigLIP” 的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。图文对比只保证粗粒度语义；固定分辨率损失细节，视频 token 又会迅速占满上下文，文本和图像熵差异还会破坏联合训练。

5 视觉特征注入语言模型

本节路线

本节依次处理：LLaVA 分两阶段训练适配器和语言模型、高分辨率图像需要裁剪或多尺度编码、单图多图和视频被转换为不同长度 token 序列。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$N_{\text{patch}} = \frac{HW}{P^2}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁹视频画面时间区间：00:32:00–00:32:15。

$$G_4 = \frac{B_4}{C_4 + \lambda R_4 + \epsilon}$$

- B_4 是本节方法带来的质量、吞吐或覆盖收益。
- C_4 是新增计算、显存、通信、数据或标注成本。
- R_4 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_4 \leq C_{\max}, \quad R_4 \leq R_{\max}, \quad Q_4 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

5.1 LLaVA 分两阶段训练适配器和语言模型

核心判断。“LLaVA 分两阶段训练适配器和语言模型”是“视觉特征注入语言模型”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 10 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“LLaVA 分两阶段训练适配器和语言模型”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

142

Training:

143

- Stage 1 (alignment): freeze vision encoder and language model, only train W

144

- Stage 2 (fine-tuning): freeze vision encoder and train W and language model

145

Visual input example, Extreme Ironing:



Source: <https://www.barnorama.com/wp-content/uploads/2016/12/03-Confusing-Pictures.jpg>

User

What is unusual about this image?

LLaVA

The unusual aspect of this image is a man ironing clothes on the back of a minivan or van. This is not a typical place to perform this activity, as one would usually iron clothes in a more stationary and safe location, such as a home, using a regular ironing board. The scene depicted in the image is peculiar as it involves a makeshift ironing setup on a vehicle, which can be both unsafe and unconventional. Additionally, it is not clear how the man is able to maintain balance and stability while ironing clothes in such an unstable environment.

User

[Start a new conversation, and clear the history]

User

What's happening in the scene?

LLaVA

The image depicts a man standing on top of a yellow SUV in a busy city street. He is holding a portable ladder, seemingly ironing clothes while standing on the vehicle. Around the scene, there are other cars, a traffic light, and a fire hydrant. Additionally, there are

图 10: LLaVA 分两阶段训练适配器和语言模型¹⁰

5.2 高分辨率图像需要裁剪或多尺度编码

核心判断。“高分辨率图像需要裁剪或多尺度编码”是“视觉特征注入语言模型”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 11 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“高分辨率图像需要裁剪或多尺度编码”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁰视频画面时间区间：00:34:45–00:35:00。

16




图 11: 高分辨率图像需要裁剪或多尺度编码¹¹

5.3 单图多图和视频被转换为不同长度 token 序列

核心判断。“单图多图和视频被转换为不同长度 token 序列”是“视觉特征注入语言模型”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 12 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“单图多图和视频被转换为不同长度 token 序列”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹¹视频画面时间区间：00:37:30–00:37:45。




图 12: 单图多图和视频被转换为不同长度 token 序列¹²

5.4 本章小结

“视觉特征注入语言模型”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。图文对比只保证粗粒度语义；固定分辨率损失细节，视频 token 又会迅速占满上下文，文本和图像熵差异还会破坏联合训练。

6 LLaVA 两阶段训练

本节路线

本节依次处理：从图文对齐到视觉指令微调的课程式训练、视觉语言模型由编码器投影器和语言模型组成、高质量任务数据和分辨率在第二阶段增加。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$Z_v = W_p f_I(I)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹²视频画面时间区间：00:40:00–00:40:15。

$$G_5 = \frac{B_5}{C_5 + \lambda R_5 + \epsilon}$$

- B_5 是本节方法带来的质量、吞吐或覆盖收益。
- C_5 是新增计算、显存、通信、数据或标注成本。
- R_5 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_5 \leq C_{\max}, \quad R_5 \leq R_{\max}, \quad Q_5 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

6.1 从图文对齐到视觉指令微调的课程式训练

核心判断。“从图文对齐到视觉指令微调的课程式训练”是“LLaVA 两阶段训练”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 13 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“从图文对齐到视觉指令微调的课程式训练”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 13: 从图文对齐到视觉指令微调的课程式训练¹³

6.2 视觉语言模型由编码器投影器和语言模型组成

核心判断。“视觉语言模型由编码器投影器和语言模型组成”是“LLaVA 两阶段训练”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 14 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“视觉语言模型由编码器投影器和语言模型组成”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹³视频画面时间区间：00:42:45–00:43:00。




图 14: 视觉语言模型由编码器投影器和语言模型组成¹⁴

6.3 高质量任务数据和分辨率在第二阶段增加

核心判断。“高质量任务数据和分辨率在第二阶段增加”是“LLaVA 两阶段训练”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 15 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“高质量任务数据和分辨率在第二阶段增加”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁴视频画面时间区间：00:45:30–00:45:45。

English	CC12M	12M	8M	66%
	CC3M	3M	3M	100%
	SBU	1M	0.8M	80%
	COCO Caption	0.6M	0.6M	100%
Chinese	LAION-zh	108M	105M	97%
	In-house Data	220M	220M	100%
Total		5B	1.4B	28%

207 • Stage 2: higher quality task-specific data, increase resolution; train all parameters

Task	# Samples	Dataset
Captioning	19.7M	LAION-en & zh, DataComp, Coyo, CC12M & 3M, SBU, COCO, In-house Data
VQA	3.6M	GQA, VGQA, VQA-v2, DVQA, OCR-VQA, DocVQA, TextVQA, ChartQA, AIZD
Grounding ²	3.5M	GRIT
Ref Grounding	8.7M	GRIT, Visual Genome, RefCOCO, RefCOCO+, RefCOCOg
Grounded Cap.	8.7M	GRIT, Visual Genome, RefCOCO, RefCOCO+, RefCOCOg
OCR	24.8M	SynthDoG-en & zh, Common Crawl pdf & HTML
Pure-text Autoregression	7.8M	In-house Data

208 • Stage 3: instruction tuning data; freeze visual encoder, train adaptor + LM

图 15: 高质量任务数据和分辨率在第二阶段增加¹⁵

6.4 本章小结

“LLaVA 两阶段训练”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。图文对比只保证粗粒度语义；固定分辨率损失细节，视频 token 又会迅速占满上下文，文本和图像熵差异还会破坏联合训练。

7 多图视频与动态分辨率

本节路线

本节依次处理：Qwen2-VL 用动态分辨率和视频采样、Qwen3-VL 支持长上下文图像和视频理解、交错 MRoPE 编码时间宽度和高度位置。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$p(y \mid I, x) = \prod_t p(y_t \mid Z_v, x, y_{<t})$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁵视频画面时间区间：00:48:00–00:48:15。

$$G_6 = \frac{B_6}{C_6 + \lambda R_6 + \epsilon}$$

- B_6 是本节方法带来的质量、吞吐或覆盖收益。
- C_6 是新增计算、显存、通信、数据或标注成本。
- R_6 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_6 \leq C_{\max}, \quad R_6 \leq R_{\max}, \quad Q_6 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

7.1 Qwen2-VL 用动态分辨率和视频采样

核心判断。“Qwen2-VL 用动态分辨率和视频采样”是“多图视频与动态分辨率”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 16 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“Qwen2-VL 用动态分辨率和视频采样”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 16: Qwen2-VL 用动态分辨率和视频采样¹⁶

7.2 Qwen3-VL 支持长上下文图像和视频理解

核心判断。“Qwen3-VL 支持长上下文图像和视频理解”是“多图视频与动态分辨率”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 17 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“Qwen3-VL 支持长上下文图像和视频理解”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁶视频画面时间区间：00:50:45–00:51:00。




图 17: Qwen3-VL 支持长上下文图像和视频理解¹⁷

7.3 交错 MRoPE 编码时间宽度和高度位置

核心判断。“交错 MRoPE 编码时间宽度和高度位置”是“多图视频与动态分辨率”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 18 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“交错 MRoPE 编码时间宽度和高度位置”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁷视频画面时间区间：00:53:30–00:53:45。

- Qwen-3 models (dense and MoE models up to 235B-A22B)
- Long context understanding (256K)

Vision encoder:

- SigLIP-2 (same architecture as SigLIP) [Tschannen+ 2025]
- Interleaved MRoPE: distribute all axes (temporal, width, height) to low- and high-frequency bar ... [t w h t w h t w h t w h] rather than [t t t t w w w h h h h]
- Add explicit video timestamps (as separate tokens rather in positional embeddings)
- Square-root-normalized per-token loss: balance text and multimodal data (video examples are l want to dominate)

Adapter:

- DeepStack: cross-layer fusion to inject visual information into multiple layers [Meng+ 2024]

Training:

- Pre-training has 4 stages (train adapter, train all parameters on 8K, 32K, 256K lengths)

Stage	Objective	Training	Token Budget	Sequence Length
S0	Vision-Language Alignment	Merge	67B	8 192

图 18: 交错 MRoPE 编码时间宽度和高度位置¹⁸

7.4 本章小结

“多图视频与动态分辨率”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。图文对比只保证粗粒度语义；固定分辨率损失细节，视频 token 又会迅速占满上下文，文本和图像熵差异还会破坏联合训练。

8 Qwen-VL 系列

本节路线

本节依次处理：Qwen3-VL 的分阶段预训练和后训练、多模态模型在多类视觉基准上的表现、VQ-VAE 把图像映射到离散视觉 token。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$N_{\text{video}} = F \cdot N_{\text{patch/frame}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁸视频画面时间区间：00:56:00–00:56:15。

$$G_7 = \frac{B_7}{C_7 + \lambda R_7 + \epsilon}$$

- B_7 是本节方法带来的质量、吞吐或覆盖收益。
- C_7 是新增计算、显存、通信、数据或标注成本。
- R_7 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_7 \leq C_{\max}, \quad R_7 \leq R_{\max}, \quad Q_7 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

8.1 Qwen3-VL 的分阶段预训练和后训练

核心判断。“Qwen3-VL 的分阶段预训练和后训练”是“Qwen-VL 系列”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 19 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“Qwen3-VL 的分阶段预训练和后训练”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

54 Training:

55 • Pre-training has 4 stages (train adapter, train all parameters on 8K, 32K, 256K lengths)

56

Stage	Objective	Training	Token Budget	Sequence Length
S0	Vision-Language Alignment	Merger	67B	8,192
S1	Multimodal Pre-Training	All	~1T	8,192
S2	Long-Context Pre-Training	All	~1T	32,768
S3	Ultra-Long-Context Adaptation	All	100B	262,144

57 • Post-training: SFT on long CoT data, knowledge distillation, RL

58

59

	Benchmark	Qwen3-VL 235B-A22B		Gemini 2.5 Pro		OpenAI GPT-5		Claude Opus 4.1	
		thinking	instruct	thinking	budget-128	high	minimal	thinking	non-thinking
STEM Puzzle	MMMU	80.6	78.7	81.7*	80.9	84.2*	74.4*	78.4	77.2
	MMMU-Pro	69.3	68.1	68.8*	71.2	78.4*	62.7*	64.8	60.7
	MathVista _{mini}	85.8	84.9	82.7*	77.7	81.3	50.9	75.5	74.5
	MathVision	74.6	66.5	73.3*	66.0	70.9	45.8	64.3	57.7
	MathVision _{wp}	63.8	57.0	63.2	56.9	62.8	40.1	54.0	46.4
	We-Math	74.8	67.5	80.6	74.5	73.8	51.8	65.2	60.2
	MathVerse _{mini}	85.0	72.5	82.9	65.9	84.1	43.0	70.6	68.1
	DynaMath	82.8	79.4	80.0	78.5	85.4	74.0	75.1	72.0
	Math-VR	66.8	65.0	64.7*	54.3	58.1	21.7	54.3	38.0
	ZeroBench	4	2	3	1	2	2	3	1
	VlmsAreBlind	79.5	80.4	86.1	78.5	80.5	53.4	77.8	72.2
	LogicVista	72.2	65.8	72.0	68.7	71.8	46.3	67.3	63.5
	VisuLogic	34.4	29.9	31.6	26.9	28.5	27.2	27.9	27.2
	VisuID _{visualize}	57.2	54.7	60.0	56.0	57.2	47.0	49.8	47.6

图 19: Qwen3-VL 的分阶段预训练和后训练¹⁹

8.2 多模态模型在多类视觉基准上的表现

核心判断。“多模态模型在多类视觉基准上的表现”是“Qwen-VL 系列”中的一个可检验设计选择，而不是只需记忆的产品名。先定义样本分布和唯一打分规则，再检查长度归一化、提示敏感性、裁判偏差与置信区间；公开测试集还要做污染和重复样本审计。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 20 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“多模态模型在多类视觉基准上的表现”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁹视频画面时间区间：00:58:45–00:59:00。

	MMVU	71.1	68.1	74.9	72.2	73.0	68.1	66.4	61.4
Perception with Tool	V*	85.9	93.7 ⁺	83.8	72.7	72.8	56.7	-	-
	HRBench4K	84.3	85.4 ⁺	87.3	84.8	-	-	-	-
	HRBench8K	76.6	82.4 ⁺	85.4	80.1	-	-	-	-
Multi-Modal Coding	Design2Code	93.4	92.0	89.2	90.3	92.5	88.9	88.5	85.3
	ChartMimic	78.4	80.5	83.9	79.9	62.1	41.4	85.2	82.9
	UniSVG	65.8	69.8	70.0	67.9	71.7	74.5	73.0	72.5
Multi-Modal Agent	ScreenSpot Pro	61.8	62.0	-	-	-	-	-	-
	OSWorldG	68.3	66.7	45.2	-	-	-	-	-
	AndroidWorld	62.0	63.7	-	-	-	-	-	-
	OSWorld	38.1	31.6	-	-	-	-	-	44.4
	WindowsAA	32.1	28.9	-	-	-	-	-	-

260

261 Summary:

262 • SOTA performance

263 • Lots of data work, but not many details

264 • Minor but potentially important architectural improvements

265 • Scale up

266

267

268 `def chameleon():`

269 Chameleon [Chameleon Team 2024]

图 20: 多模态模型在多类视觉基准上的表现²⁰

8.3 VQ-VAE 把图像映射到离散视觉 token

核心判断。“VQ-VAE 把图像映射到离散视觉 token”是“Qwen-VL 系列”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 21 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“VQ-VAE 把图像映射到离散视觉 token”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁰视频画面时间区间：01:06:45–01:07:00。




图 21: VQ-VAE 把图像映射到离散视觉 token²¹

8.4 本章小结

“Qwen-VL 系列”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。图文对比只保证粗粒度语义；固定分辨率损失细节，视频 token 又会迅速占满上下文，文本和图像熵差异还会破坏联合训练。

9 离散视觉 token 与原生多模态

本节路线

本节依次处理：原生多模态训练平衡文本和图像 token 熵、连续编码器 Transformer 与扩散生成的组合。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$z_q = \arg \min_{e_k \in \mathcal{E}} \|z - e_k\|_2$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²¹视频画面时间区间：01:09:30–01:09:45。

$$G_8 = \frac{B_8}{C_8 + \lambda R_8 + \epsilon}$$

- B_8 是本节方法带来的质量、吞吐或覆盖收益。
- C_8 是新增计算、显存、通信、数据或标注成本。
- R_8 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_8 \leq C_{\max}, \quad R_8 \leq R_{\max}, \quad Q_8 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

9.1 原生多模态训练平衡文本和图像 token 熵

核心判断。“原生多模态训练平衡文本和图像 token 熵”是“离散视觉 token 与原生多模态”中的一个可检验设计选择，而不是只需记忆的产品名。视觉输入先被切片或量化为 token，再经投影器进入语言模型；关键核算包括视觉 token 数、分辨率、对齐损失和文本图像采样比例。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 22 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“原生多模态训练平衡文本和图像 token 熵”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 22: 原生多模态训练平衡文本和图像 token 熵²²

9.2 连续编码器 Transformer 与扩散生成的组合

核心判断。“连续编码器 Transformer 与扩散生成的组合”是“离散视觉 token 与原生多模态”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 23 个图像证据在本讲 23 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“连续编码器 Transformer 与扩散生成的组合”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²²视频画面时间区间：01:12:15–01:12:30。




图 23: 连续编码器 Transformer 与扩散生成的组合²³

9.3 本章小结

“离散视觉 token 与原生多模态”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。图文对比只保证粗粒度语义；固定分辨率损失细节，视频 token 又会迅速占满上下文，文本和图像熵差异还会破坏联合训练。

10 代码化复现：最小机制

下面的片段保留本讲最核心的程序结构，用于把公式和系统过程落到可执行对象。它不是生产实现；实际复现还需补充张量形状断言、数值精度、同步、随机种子、数据版本和端到端测试。

Listing 1: Lecture 17 机制伪代码

```

1 image_tokens = projector(vision_encoder(images))
2 tokens = torch.cat([text_prefix, image_tokens, text_suffix], dim=1)
3 logits = language_model(inputs_embeds=tokens).logits

```

复现检查单

先写正确性基线，再记录资源基线；每次只改变一个机制；同时保存直接中间量和最终指标；对随机算法报告多次运行；对数据与评测保存不可变版本标识。

²³视频画面时间区间：01:14:45–01:15:00。

10.1 本章小结

代码的价值在于暴露状态、顺序和边界。若一个概念无法写成输入、变换、状态、输出和断言，它通常还没有被真正理解。

11 总结与延伸

一页压缩

本讲的主问题是：怎样把图像和视频编码为 Transformer 可消费的表达，并在语义对齐、空间细节、序列长度和训练稳定性之间取舍？统一答案是：多模态系统由视觉编码器、投影适配器、语言模型和数据课程组成，生成模型还要增加离散 tokenizer 或扩散解码器。

第一，优先理解机制而不是产品名。模型、硬件、数据和评测不断更新，但张量形状、状态位置、目标函数、通信边界和测量误差仍然是稳定的分析对象。第二，所有优化都要写出代价守恒：减少某一种成本通常会增加另一种成本或风险。第三，把小规模实验推广到大规模之前，必须检查瓶颈是否改变、数据分布是否改变、实现常数是否仍在同一数量级。第四，最可靠的课程笔记应允许读者沿时间轴注回到原视频，并沿官方材料找到公式或代码出处。

开放问题

图文对比只保证粗粒度语义；固定分辨率损失细节，视频 token 又会迅速占满上下文，文本和图像熵差异还会破坏联合训练。后续实验应把这一风险写成可观测量和停止条件，而不是留在讨论部分。

11.1 本章小结

完成本讲后，读者应能用统一语言解释每个主题的输入、状态、变换、输出、资源成本和失败模式，并据此设计一个含基线、消融、误差条和证据记录的最小实验。

12 资料来源与审计边界

- 课程主页：<https://cs336.stanford.edu/>。
- 视频：<https://www.youtube.com/watch?v=26FtD08Zp0U>。
- Stanford 官方材料：lecture_17.py；客座讲座若无官方文件则以视频和字幕为主。
- 本地证据：audio.srt、figure_manifest.tsv、figure_verification.txt、teaching_atoms.tsv、numerical_claims.tsv。

12.1 本章小结

本笔记覆盖播放列表中的本讲内容与课程主页当日可取得的官方材料。没有官方讲义的客座讲座不会被伪装成有讲义；讲者口头推测、本笔记分析框架和官方公式在文字中分别标明。