


Stanford CS336: Language Modeling from Scratch

Lecture 18: Guest Lecture: Dan Fu

Spring 2026 中文精讲笔记

主讲: Dan Fu



频道: Stanford Online

发布日期: 2026-06-05

时长: 1:11:40

视频: <https://www.youtube.com/watch?v=9EE4iMAF5s>

官方主页: <https://cs336.stanford.edu/>

目录

1 导读：问题、证据与阅读方法	2
2 推理成为智能服务引擎	2
3 负载形状与 SLA	6
4 请求到 token 的生命周期	10
5 连续批处理和并行	14
6 生产调试与 KV 分层	18
7 prefill decode 解耦	22
8 拖尾和细粒度重叠	26
9 Parcae 循环模型与缩放	30
10 代码化复现：最小机制	34
11 总结与延伸	35
12 资料来源与审计边界	35

1 导读：问题、证据与阅读方法

本讲主问题

生产推理怎样围绕 SLA、动态批处理、KV cache 和并行拓扑运行，循环共享模型又能否改变参数与计算的缩放方式？

客座讲座把线上推理和新模型结构连接起来：服务端控制 token 生命周期，模型端尝试用循环深度提高每参数智能。本笔记以课程视频、人工字幕和 Stanford 官方讲义或代码为共同证据源。图像均来自每十五秒抽帧后的人工接触表审查，时间脚注可回到原视频复核；公式区分课程机制关系和本笔记的决策分析框架。学习时建议先读主问题，再沿“机制-资源-失败模式-验证指标”四列整理自己的实验。

首先排除的误读

离线吞吐不能代表线上 SLA；KV 预取错误、拖尾请求和隐藏数值故障会放大到全局，而循环模型还必须满足动力学稳定性。

1.1 关键数字核对

主张	数值或关系	视频时间
模型规模演进	约 100M 到 500B	00:03:00
目标首 token 时间	$TTFT < 500 \text{ ms}$	00:10:00
目标 token 间隔	$TBT < 30 \text{ ms}$	00:10:00
服务吞吐指标	target QPS per GPU	00:10:00
循环模型稳定条件	谱半径小于 1	00:50:00

1.2 本章小结

本章建立证据边界：视频解释提供因果和强调，官方材料提供公式与代码，精选帧提供可核查的视觉状态。后文每个主题都同时回答“为何重要、怎样工作、怎样失败、怎样验证”，避免把课程压缩成术语目录。

2 推理成为智能服务引擎

本节路线

本节依次处理：模型参数在四年内从一亿扩展到五千亿、推理系统把模型计算图转为在线智能服务、一个 token 从请求进入到输出的完整生命周期。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$TTFT = T_{\text{queue}} + T_{\text{prefill}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。

- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

$$G_1 = \frac{B_1}{C_1 + \lambda R_1 + \varepsilon}$$

- B_1 是本节方法带来的质量、吞吐或覆盖收益。
- C_1 是新增计算、显存、通信、数据或标注成本。
- R_1 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_1 \leq C_{\max}, \quad R_1 \leq R_{\max}, \quad Q_1 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

2.1 模型参数在四年内从一亿扩展到五千亿

核心判断。“模型参数在四年内从一亿扩展到五千亿”是“推理成为智能服务引擎”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 1 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“模型参数在四年内从一亿扩展到五千亿”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

ML Models Scaling in Parameters...



Scaling in Model Size:
100M to 500B in Four Years

图 1: 模型参数在四年内从一亿扩展到五千亿¹

2.2 推理系统把模型计算图转为在线智能服务

核心判断。“推理系统把模型计算图转为在线智能服务”是“推理成为智能服务引擎”中的一个可检验设计选择，而不是只需记忆的产品名。prefill 可以沿序列并行而 decode 逐 token 串行；服务评估要同时报告首 token、token 间隔、吞吐、尾延迟和显存峰值。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 2 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“推理系统把模型计算图转为在线智能服务”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹视频画面时间区间：00:02:30–00:02:45。

And Inference is the Engine Turning Electricity into Intelligence



ML Models are DAGs
of Operations

Stanford

图 2: 推理系统把模型计算图转为在线智能服务²

2.3 一个 token 从请求进入到输出的完整生命周期

核心判断。“一个 token 从请求进入到输出的完整生命周期”是“推理成为智能服务引擎”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 3 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“一个 token 从请求进入到输出的完整生命周期”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²视频画面时间区间：00:05:00–00:05:15。

Lifetime of a Token



Austin Silveria

Stanford

图 3: 一个 token 从请求进入到输出的完整生命周期³

2.4 本章小结

“推理成为智能服务引擎”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。离线吞吐不能代表线上 SLA；KV 预取错误、拖尾请求和隐藏数值故障会放大到全局，而循环模型还必须满足动力学稳定性。

3 负载形状与 SLA

本节路线

本节依次处理：TTFT TBT 与每 GPU QPS 共同定义服务目标、输入输出长度缓存命中和多轮会话塑造负载、请求经历分词调度 prefill decode 和反分词。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$TBT = T_{\text{decode step}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

³视频画面时间区间：00:07:30–00:07:45。

$$G_2 = \frac{B_2}{C_2 + \lambda R_2 + \epsilon}$$

- B_2 是本节方法带来的质量、吞吐或覆盖收益。
- C_2 是新增计算、显存、通信、数据或标注成本。
- R_2 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_2 \leq C_{\max}, \quad R_2 \leq R_{\max}, \quad Q_2 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

3.1 TTFT TBT 与每 GPU QPS 共同定义服务目标

核心判断。“TTFT TBT 与每 GPU QPS 共同定义服务目标”是“负载形状与 SLA”中的一个可检验设计选择，而不是只需记忆的产品名。把算子映射到线程或矩阵单元，并明确数据位于寄存器、片上 SRAM 还是 HBM；瓶颈判断依赖算术强度，而不是只比较峰值 FLOP/s。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 4 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“TTFT TBT 与每 GPU QPS 共同定义服务目标”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 4: TTFT TBT 与每 GPU QPS 共同定义服务目标⁴

3.2 输入输出长度缓存命中和多轮会话塑造负载

核心判断。“输入输出长度缓存命中和多轮会话塑造负载”是“负载形状与 SLA”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 5 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“输入输出长度缓存命中和多轮会话塑造负载”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁴视频画面时间区间：00:09:45–00:10:00。




图 5: 输入输出长度缓存命中和多轮会话塑造负载⁵

3.3 请求经历分词调度 prefill decode 和反分词

核心判断。“请求经历分词调度 prefill decode 和反分词”是“负载形状与 SLA”中的一个可检验设计选择，而不是只需记忆的产品名。prefill 可以沿序列并行而 decode 逐 token 串行；服务评估要同时报告首 token、token 间隔、吞吐、尾延迟和显存峰值。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 6 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“请求经历分词调度 prefill decode 和反分词”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁵视频画面时间区间：00:12:15–00:12:30。




图 6: 请求经历分词调度 prefill decode 和反分词⁶

3.4 本章小结

“负载形状与 SLA” 的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。离线吞吐不能代表线上 SLA；KV 预取错误、拖尾请求和隐藏数值故障会放大到全局，而循环模型还必须满足动力学稳定性。

4 请求到 token 的生命周期

本节路线

本节依次处理：连续批处理按每一步活跃请求重组批次、张量并行与专家并行处理不同维度、生产可观测性发现 NaN 工具调用和长度异常。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$\text{QPS/GPU} = \frac{\text{completed requests}}{\text{GPU seconds}}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁶视频画面时间区间：00:14:45–00:15:00。

$$G_3 = \frac{B_3}{C_3 + \lambda R_3 + \epsilon}$$

- B_3 是本节方法带来的质量、吞吐或覆盖收益。
- C_3 是新增计算、显存、通信、数据或标注成本。
- R_3 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_3 \leq C_{\max}, \quad R_3 \leq R_{\max}, \quad Q_3 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

4.1 连续批处理按每一步活跃请求重组批次

核心判断。“连续批处理按每一步活跃请求重组批次”是“请求到 token 的生命周期”中的一个可检验设计选择，而不是只需记忆的产品名。prefill 可以沿序列并行而 decode 逐 token 串行；服务评估要同时报告首 token、token 间隔、吞吐、尾延迟和显存峰值。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 7 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“连续批处理按每一步活跃请求重组批次”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。




图 7: 连续批处理按每一步活跃请求重组批次⁷

4.2 张量并行与专家并行处理不同维度

核心判断。“张量并行与专家并行处理不同维度”是“请求到 token 的生命周期”中的一个可检验设计选择，而不是只需记忆的产品名。token 先由路由分数选择少量专家，再经 dispatch、专家计算和 combine 返回原顺序；直接指标是每专家 token 数、all-to-all 字节数、丢弃率和路由熵。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 8 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“张量并行与专家并行处理不同维度”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁷视频画面时间区间：00:17:15–00:17:30。




图 8: 张量并行与专家并行处理不同维度⁸

4.3 生产可观测性发现 NaN 工具调用和长度异常

核心判断。“生产可观测性发现 NaN 工具调用和长度异常”是“请求到 token 的生命周期”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 9 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“生产可观测性发现 NaN 工具调用和长度异常”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

⁸视频画面时间区间：00:19:45–00:20:00。



图 9: 生产可观测性发现 NaN 工具调用和长度异常⁹

4.4 本章小结

“请求到 token 的生命周期”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。离线吞吐不能代表线上 SLA；KV 预取错误、拖尾请求和隐藏数值故障会放大到全局，而循环模型还必须满足动力学稳定性。

5 连续批处理和并行

本节路线

本节依次处理：输出率和 token 值分布暴露线上故障、KV cache 在 GPU CPU 与 NVMe 间预取卸载和共享、调度器提前预取冷块并共享热门前缀。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$M_{KV} = 2BSLKHb$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

⁹视频画面时间区间：00:22:15–00:22:30。

$$G_4 = \frac{B_4}{C_4 + \lambda R_4 + \epsilon}$$

- B_4 是本节方法带来的质量、吞吐或覆盖收益。
- C_4 是新增计算、显存、通信、数据或标注成本。
- R_4 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_4 \leq C_{\max}, \quad R_4 \leq R_{\max}, \quad Q_4 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

5.1 输出率和 token 值分布暴露线上故障

核心判断。“输出率和 token 值分布暴露线上故障”是“连续批处理和并行”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 10 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“输出率和 token 值分布暴露线上故障”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。



图 10: 输出率和 token 值分布暴露线上故障¹⁰

5.2 KV cache 在 GPU CPU 与 NVMe 间预取卸载和共享

核心判断。“KV cache 在 GPU CPU 与 NVMe 间预取卸载和共享”是“连续批处理和并行”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 11 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“KV cache 在 GPU CPU 与 NVMe 间预取卸载和共享”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁰视频画面时间区间：00:24:45–00:25:00。




图 11: KV cache 在 GPU CPU 与 NVMe 间预取卸载和共享¹¹

5.3 调度器提前预取冷块并共享热门前缀

核心判断。“调度器提前预取冷块并共享热门前缀”是“连续批处理和并行”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 12 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“调度器提前预取冷块并共享热门前缀”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹¹视频画面时间区间：00:27:00–00:27:15。




图 12: 调度器提前预取冷块并共享热门前缀¹²

5.4 本章小结

“连续批处理和并行”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。离线吞吐不能代表线上 SLA；KV 预取错误、拖尾请求和隐藏数值故障会放大到全局，而循环模型还必须满足动力学稳定性。

6 生产调试与 KV 分层

本节路线

本节依次处理：prefill 与 decode 分离并通过 RDMA 传递 KV、LLM decode 的串行性导致低算术强度、拖尾请求与内核启动造成设备空闲。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$T_{\text{service}} = \max(T_{\text{compute}}, T_{\text{memory}}, T_{\text{network}})$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹²视频画面时间区间：00:29:30–00:29:45。

$$G_5 = \frac{B_5}{C_5 + \lambda R_5 + \epsilon}$$

- B_5 是本节方法带来的质量、吞吐或覆盖收益。
- C_5 是新增计算、显存、通信、数据或标注成本。
- R_5 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_5 \leq C_{\max}, \quad R_5 \leq R_{\max}, \quad Q_5 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

6.1 prefill 与 decode 分离并通过 RDMA 传递 KV

核心判断。“prefill 与 decode 分离并通过 RDMA 传递 KV” 是“生产调试与 KV 分层”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 13 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“prefill 与 decode 分离并通过 RDMA 传递 KV”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Cache-aware prefill-decode disaggregation (CPD)




图 13: prefill 与 decode 分离并通过 RDMA 传递 KV¹³

6.2 LLM decode 的串行性导致低算术强度

核心判断。“LLM decode 的串行性导致低算术强度”是“生产调试与 KV 分层”中的一个可检验设计选择，而不是只需记忆的产品名。prefill 可以沿序列并行而 decode 逐 token 串行；服务评估要同时报告首 token、token 间隔、吞吐、尾延迟和显存峰值。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 14 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“LLM decode 的串行性导致低算术强度”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹³视频画面时间区间：00:32:00–00:32:15。

The LLM Decode Challenge

Stanford

图 14: LLM decode 的串行性导致低算术强度¹⁴

6.3 拖尾请求与内核启动造成设备空闲

核心判断。“拖尾请求与内核启动造成设备空闲”是“生产调试与 KV 分层”中的一个可检验设计选择，而不是只需记忆的产品名。先用张量形状推出程序实例和掩码，再决定分块、向量化和片上复用；基准必须预热、同步并与高精度参考实现逐元素比较。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 15 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“拖尾请求与内核启动造成设备空闲”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁴视频画面时间区间：00:34:30–00:34:45。

Challenge: Stragglers and Kernel Launch




图 15: 拖尾请求与内核启动造成设备空闲¹⁵

6.4 本章小结

“生产调试与 KV 分层”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。离线吞吐不能代表线上 SLA；KV 预取错误、拖尾请求和隐藏数值故障会放大到全局，而循环模型还必须满足动力学稳定性。

7 prefill decode 解耦

本节路线

本节依次处理：细粒度重叠 QKV RoPE 与 KV 加载、Parcae 约束循环模型以获得稳定性、循环共享 Transformer 块以增加计算深度。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$h_{t+1} = \bar{A}h_t + \bar{B}e + \mathcal{R}(h_t, e)$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁵视频画面时间区间：00:37:00–00:37:15。

$$G_6 = \frac{B_6}{C_6 + \lambda R_6 + \epsilon}$$

- B_6 是本节方法带来的质量、吞吐或覆盖收益。
- C_6 是新增计算、显存、通信、数据或标注成本。
- R_6 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_6 \leq C_{\max}, \quad R_6 \leq R_{\max}, \quad Q_6 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

7.1 细粒度重叠 QKV RoPE 与 KV 加载

核心判断。“细粒度重叠 QKV RoPE 与 KV 加载”是“prefill decode 解耦”中的一个可检验设计选择，而不是只需记忆的产品名。先区分 query 侧计算、历史 key/value 状态和完整注意力矩阵；核算时同时写出序列长度依赖与缓存字节数，验证时观察有效带宽、核函数时间和质量变化。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 16 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“细粒度重叠 QKV RoPE 与 KV 加载”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Fine-Grained Overlapping of Workloads




图 16: 细粒度重叠 QKV RoPE 与 KV 加载¹⁶

7.2 Parcae 约束循环模型以获得稳定性

核心判断。“Parcae 约束循环模型以获得稳定性”是“prefill decode 解耦”中的一个可检验设计选择，而不是只需记忆的产品名。共享块通过多次递归增加计算深度而不增加同等参数量；必须检查残差动力学、谱半径、梯度传播和固定 FLOPs 下的最优循环次数。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 17 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录


围绕“Parcae 约束循环模型以获得稳定性”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁶视频画面时间区间：00:39:30–00:39:45。

Sometime New: Stable Looped Models with Parcae



Hayden
Prairie



Zachary
Novak



Taylor Berg-
Kirkpatrick

Stanford

图 17: Parcae 约束循环模型以获得稳定性¹⁷

7.3 循环共享 Transformer 块以增加计算深度

核心判断。“循环共享 Transformer 块以增加计算深度”是“prefill decode 解耦”中的一个可检验设计选择，而不是只需记忆的产品名。共享块通过多次递归增加计算深度而不增加同等参数量；必须检查残差动力学、谱半径、梯度传播和固定 FLOPs 下的最优循环次数。


复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 18 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“循环共享 Transformer 块以增加计算深度”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁷视频画面时间区间：00:42:00–00:42:15。

Looped Models - Pass the Activations Back



Advantages:

- Increase FLOPs, keep parameters constant
- Higher expressivity
- What's the best "intelligence per parameter" we can do?

LOOPED TRANSFORMERS ARE BETTER AT LEARNING LEARNING ALGORITHMS

Liu Yang, Kangwook Lee, Robert D. Nowak & Dimitris Papailiopoulos
University of Wisconsin, Madison, USA

ABSTRACT

Transformers have demonstrated effectiveness in *in-context solving* data-fitting problems from various (latent) models, as reported by Garg et al. (2022). However, the absence of an inherent iterative structure in the transformer architecture presents a challenge in emulating the iterative algorithms, which are commonly employed in traditional machine learning methods. To address this, we propose the utilization of *looped* transformer architecture and its associated training methodology, with the aim of incorporating iterative characteristics into the transformer architectures. Experimental results suggest that the looped transformer achieves performance comparable to the standard transformer in solving various data-fitting problems, while utilizing less than 10% of the parameter count.¹

52

图 18: 循环共享 Transformer 块以增加计算深度¹⁸

7.4 本章小结

“prefill decode 解耦”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。离线吞吐不能代表线上 SLA；KV 预取错误、拖尾请求和隐藏数值故障会放大到全局，而循环模型还必须满足动力学稳定性。

8 拖尾和细粒度重叠

本节路线

本节依次处理：循环模型稳定性的关键在残差动力学、线性化系统分析谱半径与稳定性、负对角和归一化约束 A B 矩阵。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$\rho(\bar{A}) < 1$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

¹⁸视频画面时间区间：00:44:30–00:44:45。

$$G_7 = \frac{B_7}{C_7 + \lambda R_7 + \epsilon}$$

- B_7 是本节方法带来的质量、吞吐或覆盖收益。
- C_7 是新增计算、显存、通信、数据或标注成本。
- R_7 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_7 \leq C_{\max}, \quad R_7 \leq R_{\max}, \quad Q_7 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

8.1 循环模型稳定性的关键在残差动力学


核心判断。“循环模型稳定性的关键在残差动力学”是“拖尾和细粒度重叠”中的一个可检验设计选择，而不是只需记忆的产品名。共享块通过多次递归增加计算深度而不增加同等参数量；必须检查残差动力学、谱半径、梯度传播和固定 FLOPs 下的最优循环次数。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 19 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“循环模型稳定性的关键在残差动力学”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Our Basic Insight: It's All About the Residual



57

图 19: 循环模型稳定性的关键在残差动力学¹⁹

8.2 线性化系统分析谱半径与稳定性

核心判断。“线性化系统分析谱半径与稳定性”是“拖尾和细粒度重叠”中的一个可检验设计选择，而不是只需记忆的产品名。共享块通过多次递归增加计算深度而不增加同等参数量；必须检查残差动力学、谱半径、梯度传播和固定 FLOPs 下的最优循环次数。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 20 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录

围绕“线性化系统分析谱半径与稳定性”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

¹⁹视频画面时间区间：00:46:45–00:47:00。

Stability Analysis: Linearize the System!

$$h_{t+1} = \overline{A}h_t + \overline{B}e + \overline{\mathcal{R}}(h_t, e)$$

Residual Dominates Magnitude

59

图 20: 线性化系统分析谱半径与稳定性²⁰

8.3 负对角和归一化约束 A B 矩阵

核心判断。“负对角和归一化约束 A B 矩阵”是“拖尾和细粒度重叠”中的一个可检验设计选择，而不是只需记忆的产品名。把该主题拆成输入、变换、持久状态和输出四部分，再分别记录直接机制指标、资源成本和最终质量；若中间量不按预测变化，应优先检查实现和数据边界。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 21 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。


常见失效模式

围绕“负对角和归一化约束 A B 矩阵”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²⁰视频画面时间区间：00:49:15–00:49:30。

Parcae: Constrain A, B for Stability

Negative Diagonal



Method	$\bar{A}$	$\bar{B}$	$\rho(\bar{A})$	LTI Stability
Addition	I	I	$\rho(\bar{A}) = 1$	<i>marginally-stable</i>
Concatenation	$\mathbb{R}^{d_h \times d_h}$	$\mathbb{R}^{d_h \times d_e}$	$\rho(\bar{A}) \in \mathbb{R}$	<i>unstable</i>
PARCAE (ours)	$\text{ZOH}(\text{Diag}(-\exp(\mathbb{R}^{d_h})))$	$\text{Euler}(\mathbb{R}^{d_h \times d_e})$	$\rho(\bar{A}) < 1$	<i>stable</i>

60

图 21: 负对角和归一化约束 A B 矩阵²¹

8.4 本章小结

“拖尾和细粒度重叠”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。离线吞吐不能代表线上 SLA；KV 预取错误、拖尾请求和隐藏数值故障会放大到全局，而循环模型还必须满足动力学稳定性。

9 Parcae 循环模型与缩放

本节路线

本节依次处理：固定参数与 FLOPs 下选择循环次数、更多训练数据对应更多最优递归、循环扩展在验证损失和下游任务上的收益。它们共享一个资源与信息流边界，因而必须联合阅读，不能把其中某张图当成独立结论。

$$C_{\text{loop}} = r C_{\text{block}}, \quad N_{\text{param}} \text{ fixed}$$

- 公式中的大写字母表示张量规模、样本规模、设备数或资源总量，具体语义由本节上下文给出。
- 小写字母和希腊字母表示权重、比例、阈值、延迟或拟合参数；下标用于区分样本、设备、专家或时间步。
- 等号给出机制关系，近似号表示课程中的资源估算；实际系统还要用实测常数校准。

²¹视频画面时间区间：00:51:45–00:52:00。

$$G_8 = \frac{B_8}{C_8 + \lambda R_8 + \epsilon}$$

- B_8 是本节方法带来的质量、吞吐或覆盖收益。
- C_8 是新增计算、显存、通信、数据或标注成本。
- R_8 是错误、偏差、失稳或不可复现风险； λ 表示对风险的惩罚强度。

$$C_8 \leq C_{\max}, \quad R_8 \leq R_{\max}, \quad Q_8 \geq Q_{\min}$$

- $C_{\max}$ 和 $R_{\max}$ 分别是资源预算与风险上限。
- $Q_{\min}$ 是必须守住的质量、正确率或服务水平下界。
- 这组约束是本笔记用于复现实验决策的分析框架，并非把课程中的所有方法压缩为单一分数。

9.1 固定参数与 FLOPs 下选择循环次数

核心判断。“固定参数与 FLOPs 下选择循环次数”是“Parcae 循环模型与缩放”中的一个可检验设计选择，而不是只需记忆的产品名。共享块通过多次递归增加计算深度而不增加同等参数量；必须检查残差动力学、谱半径、梯度传播和固定 FLOPs 下的最优循环次数。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 22 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

应记住的判断

围绕“固定参数与 FLOPs 下选择循环次数”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

Part 3: Scaling Laws - When to Loop?

Stanford

图 22: 固定参数与 FLOPs 下选择循环次数²²

9.2 更多训练数据对应更多最优递归

核心判断。“更多训练数据对应更多最优递归”是“Parcae 循环模型与缩放”中的一个可检验设计选择，而不是只需记忆的产品名。共享块通过多次递归增加计算深度而不增加同等参数量；必须检查残差动力学、谱半径、梯度传播和固定 FLOPs 下的最优循环次数。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 23 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

复现实验记录


围绕“更多训练数据对应更多最优递归”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²²视频画面时间区间：00:54:15–00:54:30。

Parcae Scaling Laws: To Loop or Not To Loop?

Setup:

- ISO-param, ISO-FLOP curves
- Varying: recurrence x training data
- **More data -> more recurrence is optimal!**



Down and to the right:
Scale both

66

图 23: 更多训练数据对应更多最优递归²³

9.3 循环扩展在验证损失和下游任务上的收益

核心判断。“循环扩展在验证损失和下游任务上的收益”是“Parcae 循环模型与缩放”中的一个可检验设计选择，而不是只需记忆的产品名。共享块通过多次递归增加计算深度而不增加同等参数量；必须检查残差动力学、谱半径、梯度传播和固定 FLOPs 下的最优循环次数。

复现与诊断。实验记录至少包含输入形状或数据范围、关键状态位置、阈值与精度、资源测量和质量基线。先检查直接中间量，再检查最终指标；若最终分数改变而中间量没有按机制预测变化，应优先怀疑实现、基准或数据泄漏。第 24 个图像证据在本讲 24 个主题中的作用，是把这一判断固定到可回看的原始画面和时间区间。

常见失效模式

围绕“循环扩展在验证损失和下游任务上的收益”，至少记录直接机制指标、最终质量指标和一个反事实基线。若只给最终分数而没有中间量，就无法区分真正的机制收益、额外预算和测量误差。

²³视频画面时间区间：00:56:45–00:57:00。

Scaling Recurrences > No Recurrence, More Data




图 24: 循环扩展在验证损失和下游任务上的收益²⁴

9.4 本章小结

“Parcae 循环模型与缩放”的关键不是记住若干实现名称，而是建立选择顺序：先确定目标和状态边界，再核算计算、存储、通信或数据成本，随后检查本节公式的假设，最后用原始画面对应的中间量验证因果链。离线吞吐不能代表线上 SLA；KV 预取错误、拖尾请求和隐藏数值故障会放大到全局，而循环模型还必须满足动力学稳定性。

10 代码化复现：最小机制

下面的片段保留本讲最核心的程序结构，用于把公式和系统过程落到可执行对象。它不是生产实现；实际复现还需补充张量形状断言、数值精度、同步、随机种子、数据版本和端到端测试。

Listing 1: Lecture 18 机制伪代码

```
1 while scheduler.has_work():
2     batch = scheduler.select_active_sequences()
3     logits = model.decode(batch.tokens, batch.kv_pages)
4     scheduler.commit(sample(logits), batch)
```

复现检查单

先写正确性基线，再记录资源基线；每次只改变一个机制；同时保存直接中间量和最终指标；对随机算法报告多次运行；对数据与评测保存不可变版本标识。

²⁴视频画面时间区间：00:59:15–00:59:30。

10.1 本章小结

代码的价值在于暴露状态、顺序和边界。若一个概念无法写成输入、变换、状态、输出和断言，它通常还没有被真正理解。

11 总结与延伸

一页压缩

本讲的主问题是：生产推理怎样围绕 SLA、动态批处理、KV cache 和并行拓扑运行，循环共享模型又能否改变参数与计算的缩放方式？统一答案是：客座讲座把线上推理和新模型结构连接起来：服务端控制 token 生命周期，模型端尝试用循环深度提高每参数智能。

第一，优先理解机制而不是产品名。模型、硬件、数据和评测不断更新，但张量形状、状态位置、目标函数、通信边界和测量误差仍然是稳定的分析对象。第二，所有优化都要写出代价守恒：减少某一种成本通常会增加另一种成本或风险。第三，把小规模实验推广到大规模之前，必须检查瓶颈是否改变、数据分布是否改变、实现常数是否仍在同一数量级。第四，最可靠的课程笔记应允许读者沿时间脚注回到原视频，并沿官方材料找到公式或代码出处。

开放问题

离线吞吐不能代表线上 SLA；KV 预取错误、拖尾请求和隐藏数值故障会放大到全局，而循环模型还必须满足动力学稳定性。后续实验应把这一风险写成可观测量和停止条件，而不是留在讨论部分。

11.1 本章小结

完成本讲后，读者应能用统一语言解释每个主题的输入、状态、变换、输出、资源成本和失败模式，并据此设计一个含基线、消融、误差条和证据记录的最小实验。

12 资料来源与审计边界

- 课程主页：<https://cs336.stanford.edu/>。
- 视频：<https://www.youtube.com/watch?v=9EE4iMAF5s>。
- Stanford 官方材料：none；客座讲座若无官方文件则以视频和字幕为主。
- 本地证据：audio.srt、figure_manifest.tsv、figure_verification.txt、teaching_atoms.tsv、numerical_claims.tsv。

12.1 本章小结

本笔记覆盖播放列表中的本讲内容与课程主页当日可取得的官方材料。没有官方讲义的客座讲座不会被伪装成有讲义；讲者口头推测、本笔记分析框架和官方公式在文字中分别标明。