课程笔记

大规模非线性能源系统的多层优化策略

Texas A&M Distinguished Lecture Series in Energy

讲者：Dr. Lorenz T. (Larry) Biegler, Carnegie Mellon University

lecture-to-notes

2026 年 3 月 24 日

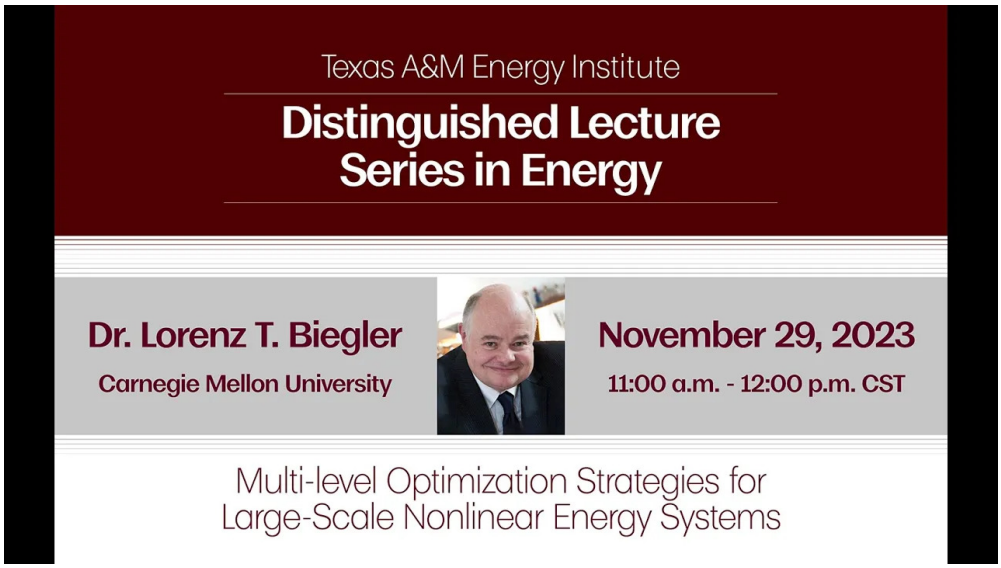

视频作者/频道：Texas A&M Energy Institute
发布日期：November 29, 2023
视频时长：45 分钟
视频链接：`https://www.youtube.com/watch?v=mst-tJ6ELTE`

目录

1 引言：为什么需要非线性优化？ **2**
1.1 从 Truth Model 到优化 2
1.2 本章小结 3

2 非线性模型预测控制（NMPC） **4**
2.1 NMPC 问题形式化 4
2.2 IGCC 电厂案例：SOC 燃料电池控制 5
2.3 灵敏度加速：降低在线计算成本 6
2.4 本章小结 6

3 多周期优化的分解方法 **7**
3.1 多周期问题的结构 7
3.2 Nested Schur 分解 8
3.3 m 和 M 的增广 9
3.4 本章小结 9

4 代理模型优化（Surrogate Model Optimization） **10**
4.1 为什么需要模型降阶? 10
4.2 Trust Region Filter (TRF) 算法 11
4.3 CO_2 捕集案例 12
4.4 本章小结 13

5 总结与延伸 **13**
5.1 讲者的核心信息 13
5.2 结构化提炼 14
5.3 跨章节关联 14
5.4 开放问题 14
5.5 拓展阅读 14

1 引言：为什么需要非线性优化？

Larry Biegler 教授是 Carnegie Mellon 的化学工程教授，专注于大规模非线性规划（NLP）求解器开发及其在过程工程中的应用。本讲围绕一个核心问题：如何将高级优化方法应用于大规模、复杂的能源系统？

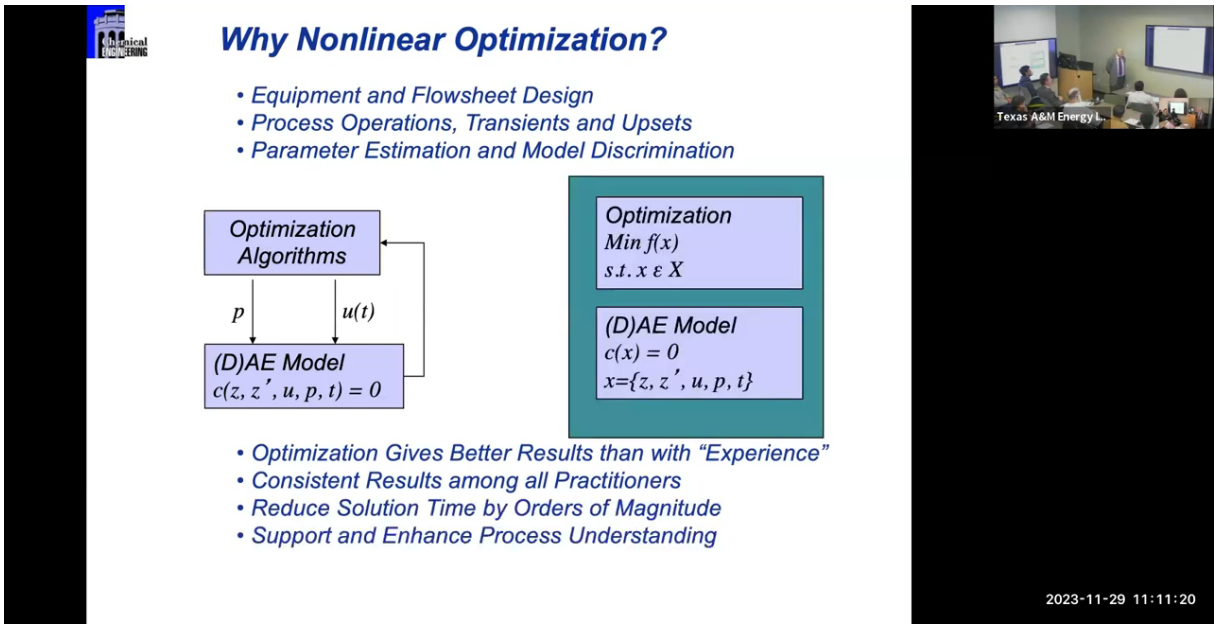

图 1: 为什么需要非线性优化？优化 vs. 案例研究[1]

1.1 从 Truth Model 到优化

Biegler 的出发点：给定一个你信任的“真实模型”（Truth Model），基于第一性原理，如何用它来改进真实世界的系统？

优化 vs. 案例研究

传统方法是“案例研究”（Case Study）——手动调参数看效果。而优化方法的优势：

- 可以证明解的质量（“how good your solution is”）
- 不会遗漏更好的解（“haven't overlooked anything”）
- 不需要“大师”或专家——任何理解过程的人都能用

优化问题的标准形式：

$$\min_{z,p} \quad F(z)$$

$$\text{s.t.} \quad c(z) = 0, \quad z^L \le z \le z^U$$

- z：优化变量（可能是时间/空间的函数）

[1] 视频画面时间区间：00:02:15–00:02:45。

- p：参数（不随时间变化的设计决策）
- $c(z) = 0$：等式约束（DAE 模型方程）
- z^L, z^U：变量的上下界

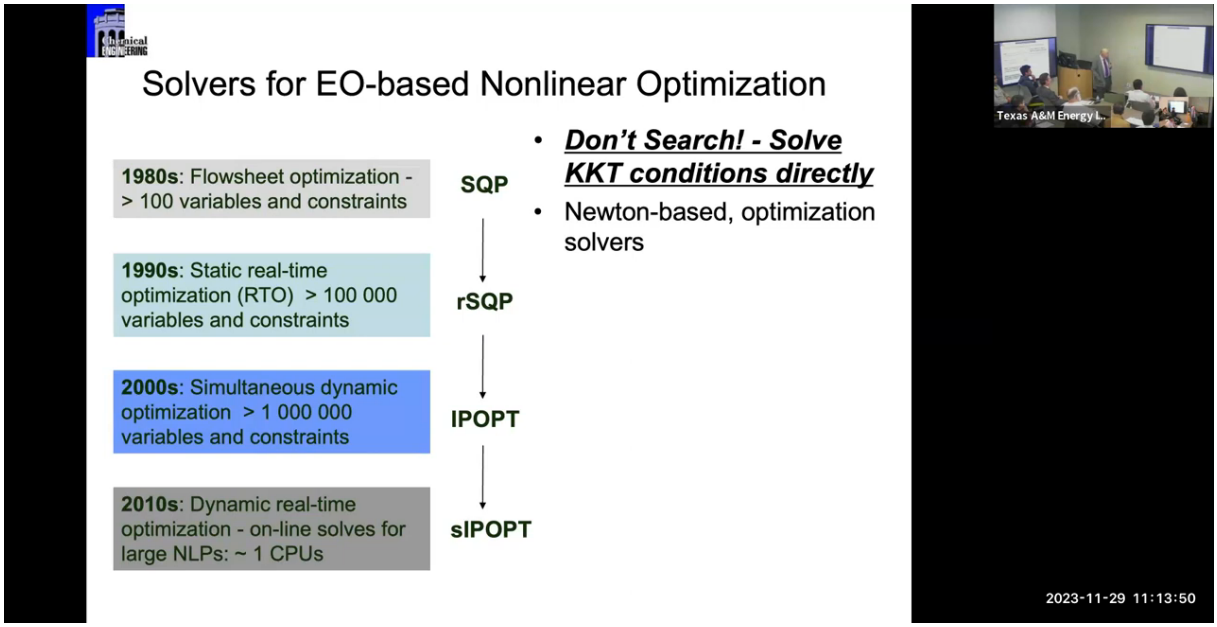

图 2: EO-based 非线性优化求解器的发展历程[2]

核心 Mantra：Don't Search — Solve!

不要搜索最优解——直接求解 KKT 最优性条件！
传统优化器（如遗传算法）在解空间中"搜索"；而 Newton-based 求解器直接求解一阶最优性条件（KKT），收敛速度快几个数量级。这是 EO (Equation-Oriented) 方法的核心优势。

求解器发展时间线：

- **1980s**：Flowsheet 优化，SQP，~100 变量
- **1990s**：实时优化（RTO），rSQP，>100,000 变量
- **2000s**：同步动态优化，IPOPT，~1,000,000 变量
- **2010s**：动态实时优化，sIPOPT，大规模 NLP ~1 CPU

1.2 本章小结

非线性优化的核心理念：用 Newton-based 方法直接求解 KKT 条件，而非在解空间中搜索。EO 方法使得百万级变量的 NLP 问题在单 CPU 上可解。

[2] 视频画面时间区间：00:04:45–00:05:15。

2 非线性模型预测控制（NMPC）

2.1 NMPC 问题形式化

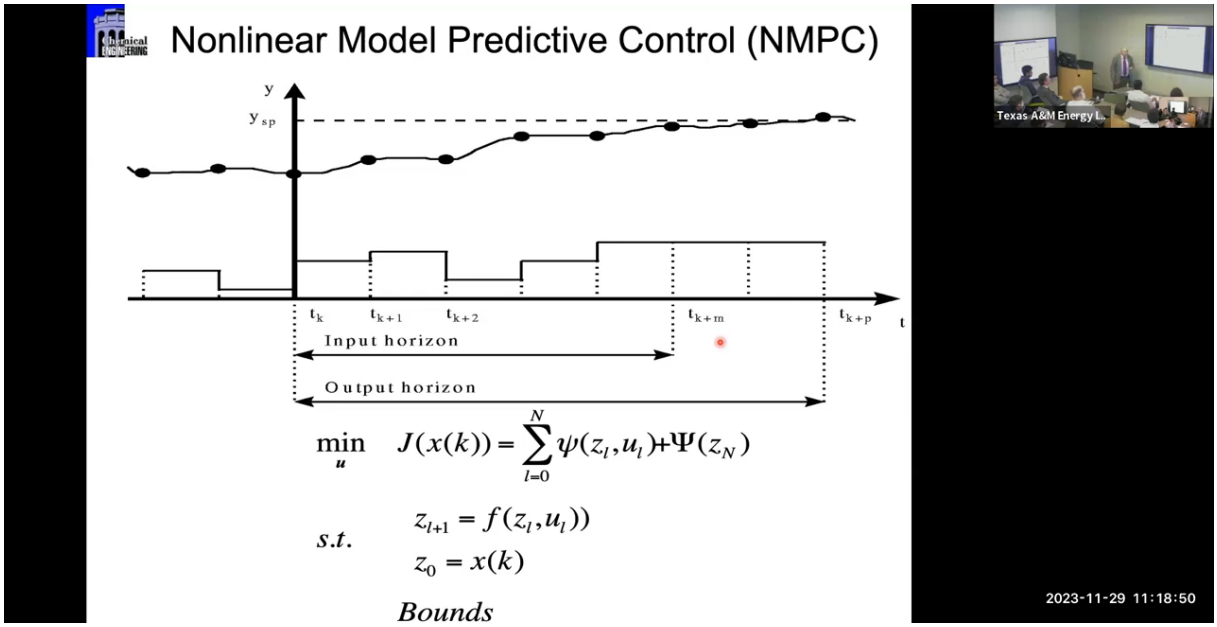

图 3: NMPC 问题的数学形式化[3]

NMPC 在每个时间步求解一个有限时域优化问题：

$$\min_{u_k} \quad J(x(k)) = \sum_{i=0}^{N-1} \varphi(z_i, u_i) + \Psi(z_N)$$

$$\text{s.t.} \quad z_{i+1} = f(z_i, u_i), \quad z_0 = x(k)$$

- $x(k)$：当前时刻的状态测量值
- z_i：预测状态轨迹
- u_i：控制输入序列
- $\varphi(\cdot)$：阶段代价函数
- $\Psi(\cdot)$：终端代价函数
- N：预测时域长度
- Bounds：状态和控制的约束

NMPC 的“滚动时域”思想

NMPC 在每个采样时刻都重新求解一个优化问题。虽然优化的是整个预测时域，但**只执行第一步控制动作**，然后用新的测量更新状态，再重新优化。这就是“滚动时域”（Receding Horizon）策略——在线反馈补偿模型误差和扰动。

[3] 视频画面时间区间：00:09:45–00:10:15。

2.2 IGCC 电厂案例：SOC 燃料电池控制

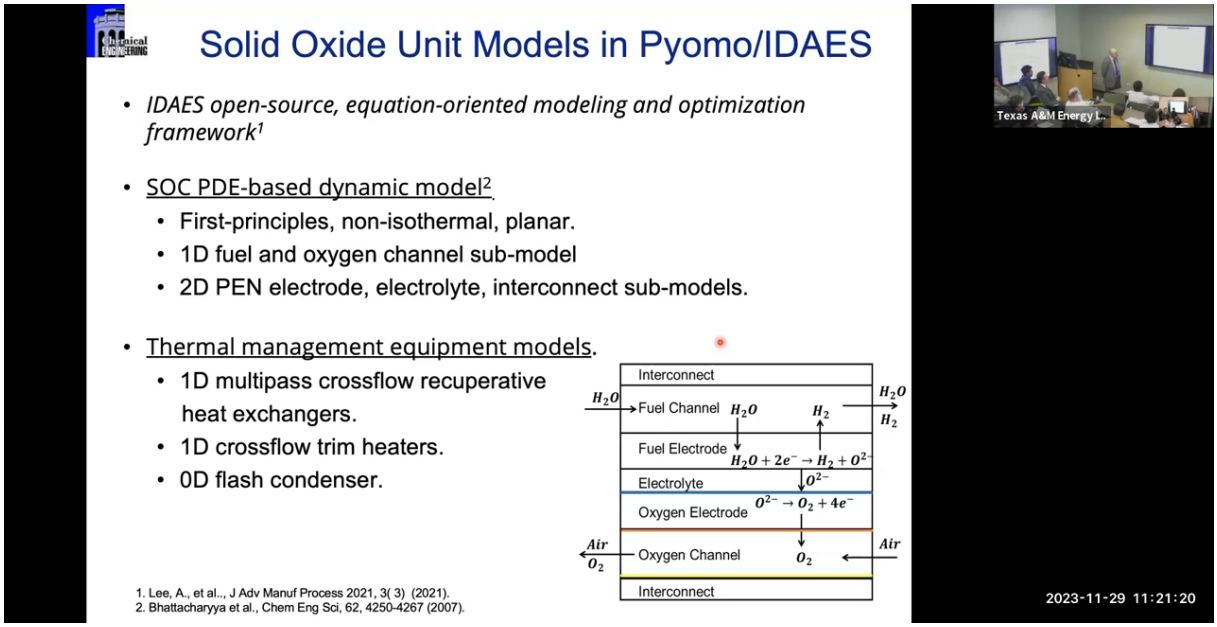

图 4: IGCC 电厂 Pyropower 流程图[4]

Biegler 展示了 IGCC（Integrated Gasification Combined Cycle，整体气化联合循环）电厂的 NMPC 应用。关键挑战：

- SOC（Solid Oxide Cell）燃料电池包含复杂的电化学和热力学耦合
- 需要追踪快速变化的功率需求
- 多个操纵变量（蒸汽流量、加热器占空比、回流比等）

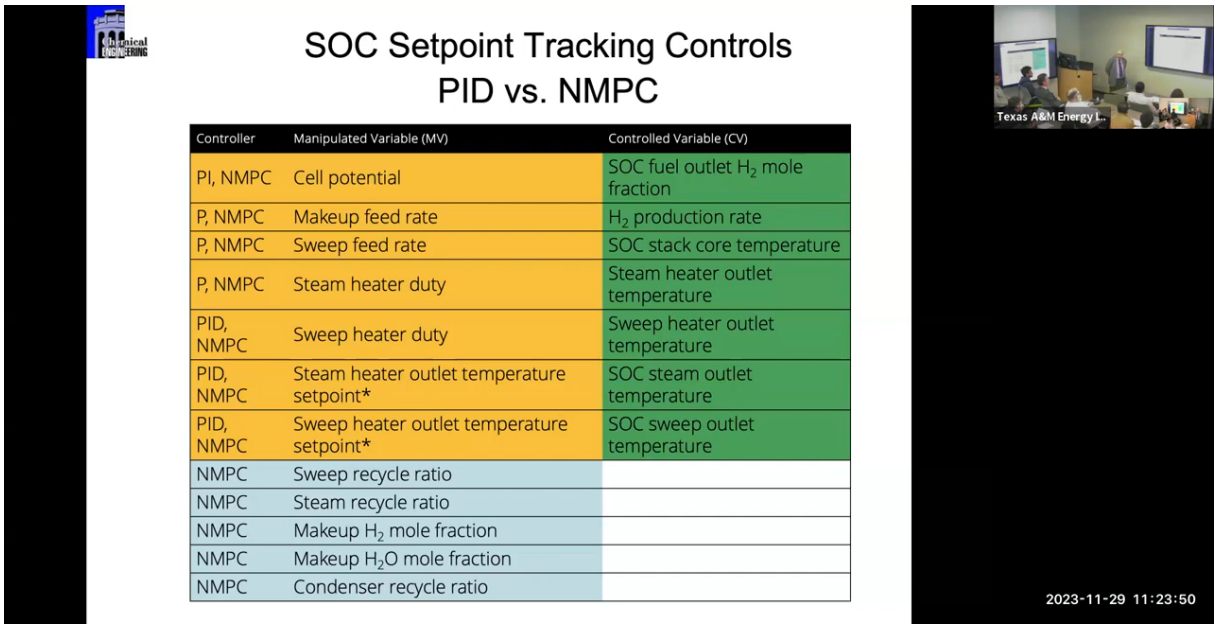

图 5: SOC 设定点追踪：PID vs. NMPC 的操纵变量对比[5]

[4]视频画面时间区间：00:07:30–00:08:00。

NMPC 相对 PID 的优势

在 SOC 燃料电池控制中，NMPC 相比传统 PID 的关键优势：

- PID 只能控制少量变量（通常单输入单输出）
- NMPC 可以同时优化 10+ 个操纵变量（如表中所示）
- NMPC 可以处理约束（温度上限、流量下限等）
- NMPC 预测未来行为，提前响应，而非事后补偿

2.3 灵敏度加速：降低在线计算成本

Biegler 强调了一个关键技术：**Advanced-step NMPC**——利用灵敏度分析（sensitivity calculations）大幅减少在线优化时间。

核心思想：在等待新测量数据时，提前计算优化问题对参数变化的灵敏度。当新测量到达时，只需做一步灵敏度修正，而非重新求解整个 NLP。

在线求解 NLP 的时间约束

NMPC 需要在一个采样周期内完成优化求解。如果 NLP 求解时间超过采样周期，控制器就会“来不及”——这在快速动态系统中是致命的。灵敏度加速将在线计算从“求解 NLP”降为“一次矩阵乘法”，使实时 NMPC 成为可能。

2.4 本章小结

NMPC 通过在线滚动求解 NLP 实现最优控制。在 IGCC/SOC 案例中，NMPC 显著优于 PID，能处理多变量、约束和非线性耦合。灵敏度加速是使 NMPC 适用于实时系统的关键技术。

[5] 视频画面时间区间：00:14:30–00:15:00。

3 多周期优化的分解方法

3.1 多周期问题的结构

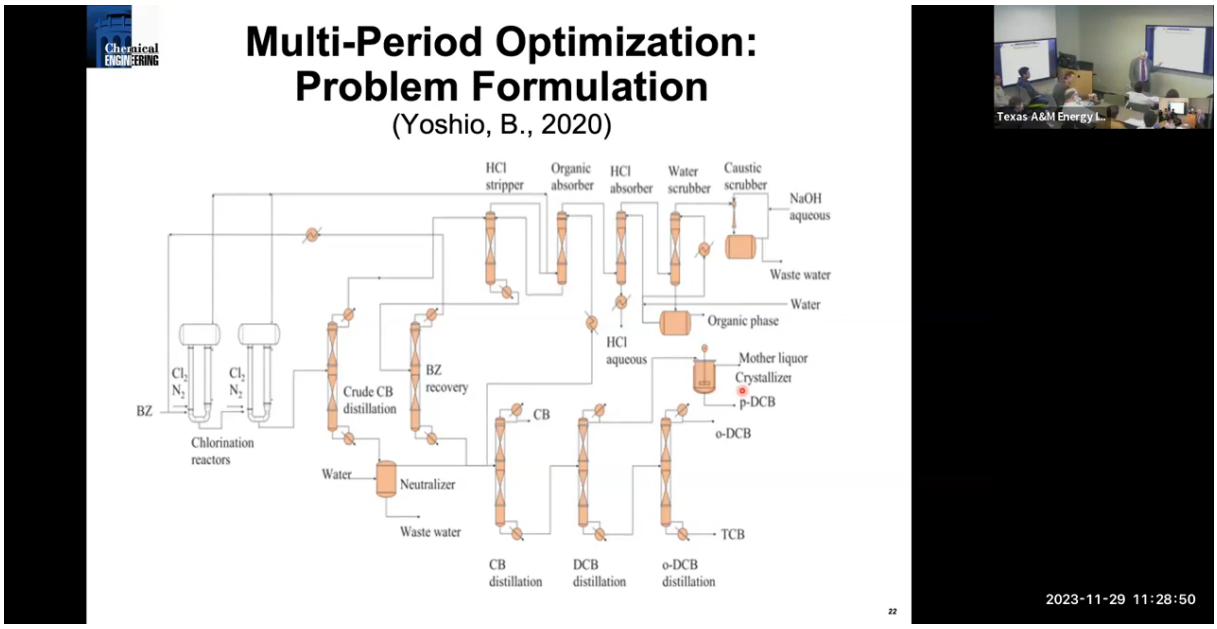

图 6: 多周期优化：问题形式化与流程图[6]

多周期优化（Multi-Period Optimization）的典型场景：需求侧优化，同一个系统在不同时间段（周期）运行在不同工况下，但共享某些**耦合变量**（如设备尺寸、管道直径等设计参数）。

$$\min_{x,y_1,\ldots,y_T} \quad \sum_{t=1}^{T} f_t(x, y_t)$$

$$\text{s.t.} \quad c_t(x, y_t) = 0, \quad t = 1, \ldots, T$$

- x：耦合变量（跨周期共享，如设备设计参数）
- y_t：第 t 个周期的局部变量（操作条件）
- $c_t(\cdot)$：各周期的模型方程
- T：总周期数

[6] 视频画面时间区间：00:19:30–00:20:00。

3.2 Nested Schur 分解

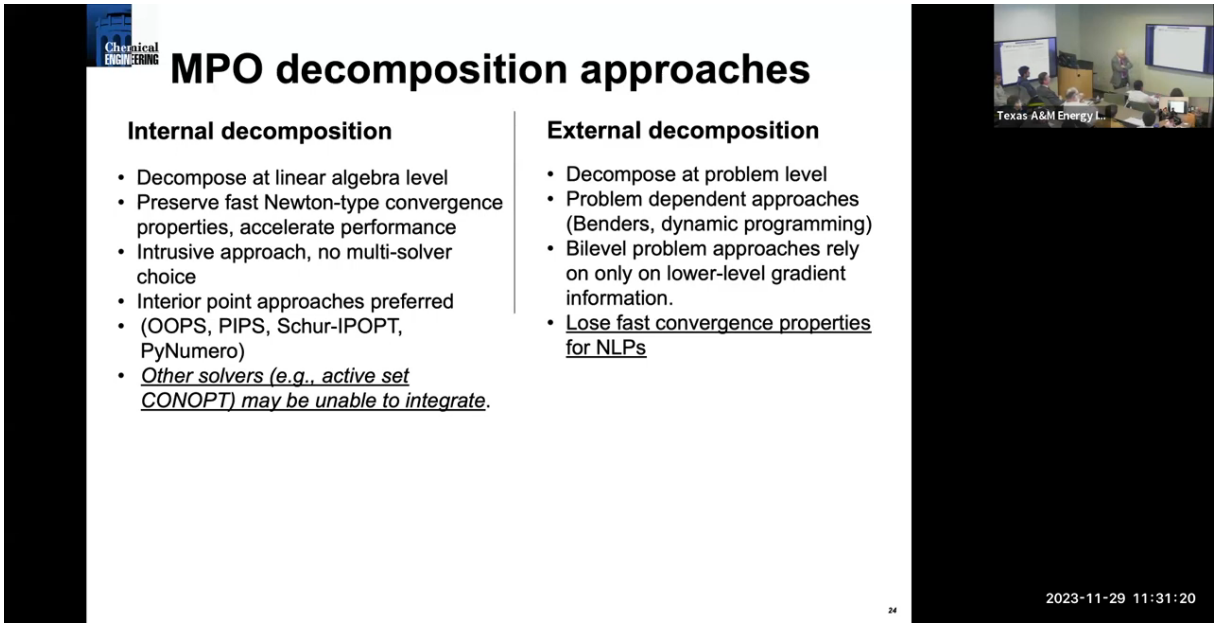

图 7: MFO 分解方法：Benders vs. Lagrangean vs. Nested Schur[7]

传统分解方法的问题：

- **Benders 分解 / Lagrangean 松弛**：可以用不同求解器处理不同子问题，但**收敛速度慢**（线性收敛）
- **直接全尺寸 NLP**：Newton 收敛快，但**内存不够**

Nested Schur 分解：两全其美

Nested Schur 分解利用了多周期问题的**块对角结构**：
整体 KKT 系统的 Jacobian 矩阵呈块对角形式——每个周期对应一个对角块（K_i），耦合变量对应右下角的小矩阵。
关键步骤：

1. 并行求解各周期的子问题（对角块）→ 可分布式计算
2. 将子问题信息传递给上层协调问题（Schur complement）
3. 上层问题只涉及耦合变量 x，规模小

结果：保持了 Newton 的快速收敛，同时获得了并行分解的可扩展性。

[7] 视频画面时间区间：00:21:30–00:22:00。

3.3 m 和 M 的增广

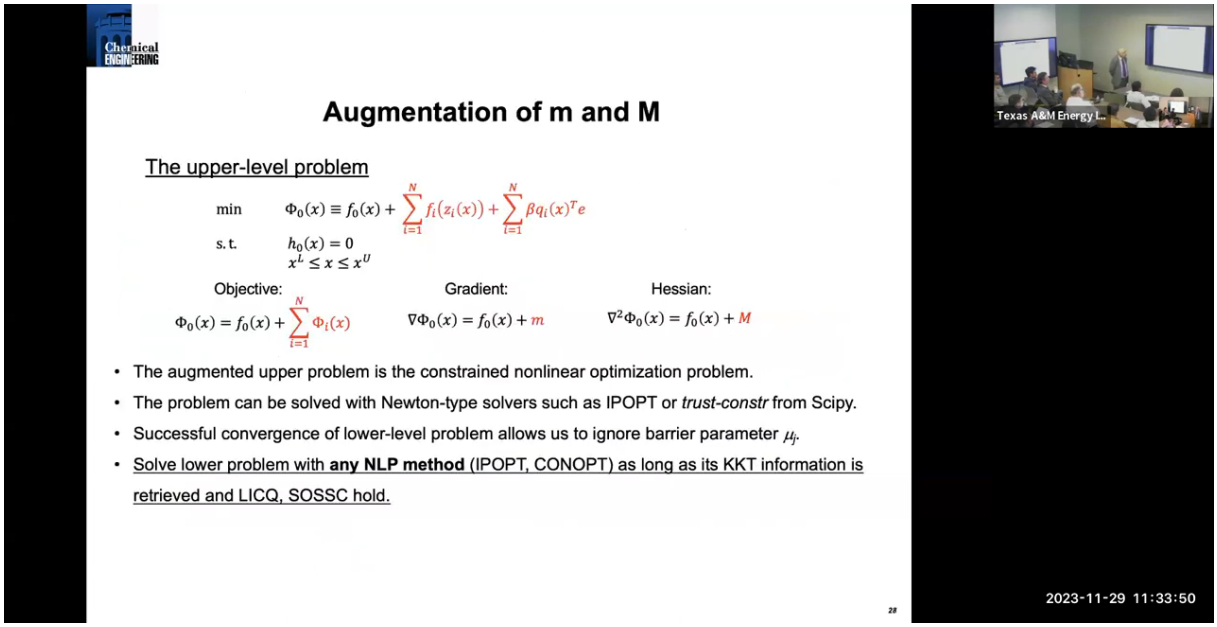

图 8: 上层问题的增广形式化[8]

上层问题的形式：

$$\min_{x} \quad \theta(x) \triangleq f(x) + \sum_{t=1}^{T} \theta_t(x)$$

其中每个 $\theta_t(x)$ 来自第 t 个子问题的最优值函数。

为什么 Nested Schur 能忽略较差的初始参数？

Biegler 指出：增广上层问题可以用 IPOPT 或 trust-cone 求解器处理。下层子问题的成功收敛使得上层可以忽略较差的初始参数——**只要 KKT 信息被正确传递**。这就像“每个部门把自己的事做好，总部只需协调”.

3.4 本章小结

多周期优化的核心挑战是耦合变量。Nested Schur 分解通过利用 KKT 系统的块对角结构，实现了“Newton 收敛速度 + 并行分解可扩展性”的最佳组合。

[8] 视频画面时间区间：00:24:30–00:25:00。

4 代理模型优化（Surrogate Model Optimization）

4.1 为什么需要模型降阶？

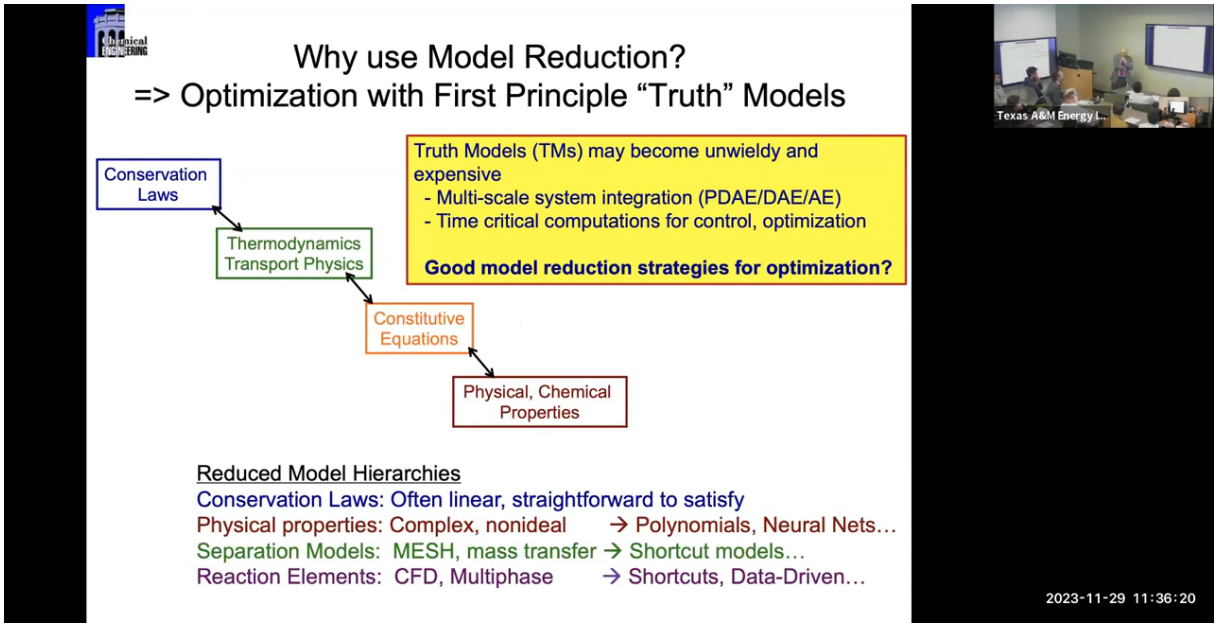

图 9: 为什么需要模型降阶？Truth Model vs. 代理模型[9]

Truth Model（第一性原理模型）的问题：

- 可能过于**笨重且昂贵**（如 CFD 模拟）
- 多尺度系统集成（PAE/DAE/AE）计算量巨大
- 实时控制/优化中没有时间做完整模拟

模型降阶的层次

守恒定律（Conservation Laws）	通常是线性的，容易处理
物性关系（Complex, nonlinear）	→ 多项式、神经网络
分离模型（MESH, mass transfer）	→ Shortcut 模型
反应模型（CFD, Multiphase）	→ Shortcuts, 数据驱动

[9] 视频画面时间区间：00:27:00–00:27:45。

4.2 Trust Region Filter (TRF) 算法

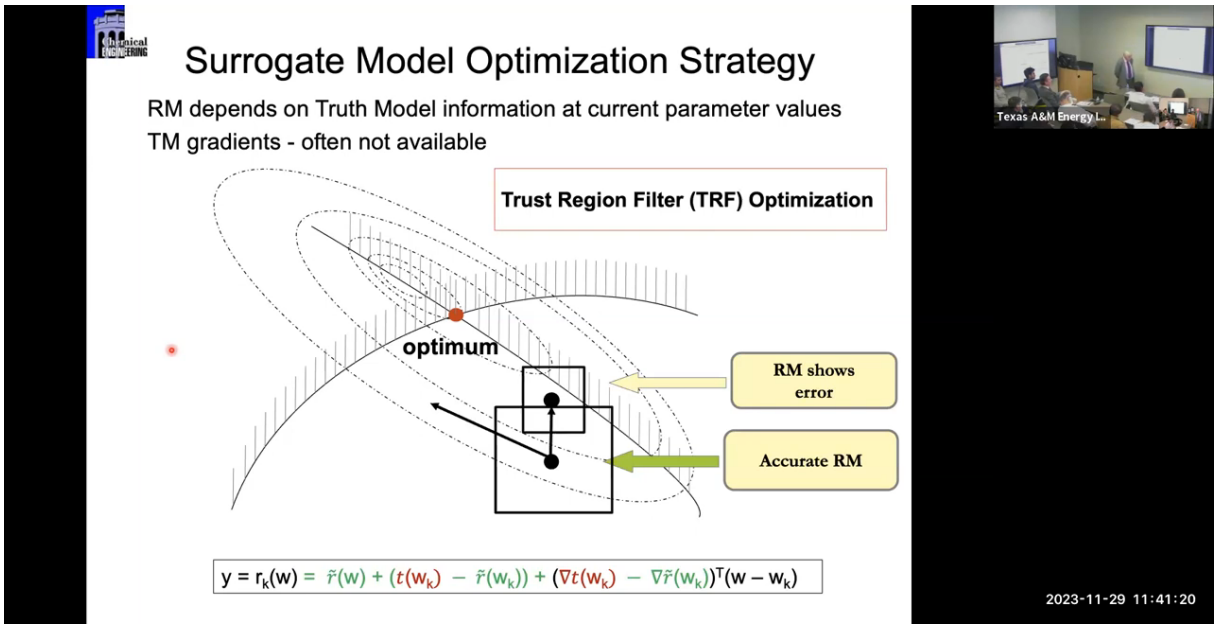

图 10: Surrogate Model Optimization 策略：Trust Region Filter[10]

TRF 的核心思想：

$$y = f_r(w) = F(w) + \underbrace{[f(w_k) - F(w_k)]}_{\text{校准项}} + \underbrace{\nabla[f(w_k) - F(w_k)]^T(w - w_k)}_{\text{一阶校正}}$$

- $F(w)$：代理模型（Reduced Model, RM）——快速但不精确
- $f(w)$：真实模型（Truth Model, TM）——精确但昂贵
- 校准项使得 RM 在当前点 w_k 处与 TM 值一致
- 一阶校正使得梯度也一致

TRF 的收敛保证

Trust Region Filter 算法保证收敛到 Truth Model 的最优解——即使代理模型本身并不精确。关键机制：

1. 如果 RM 预测与 TM 误差小 → 接受步（Accept RM）
2. 如果误差大 → 缩小信赖域（Shrink Trust Region）
3. 通过 Filter 机制避免“陷入循环”

最终效果：用少量 TM 评估（昂贵的）+ 大量 RM 评估（便宜的）达到 TM 的最优解。

[10] 视频画面时间区间：00:32:00–00:32:45。

4.3 CO_2 捕集案例

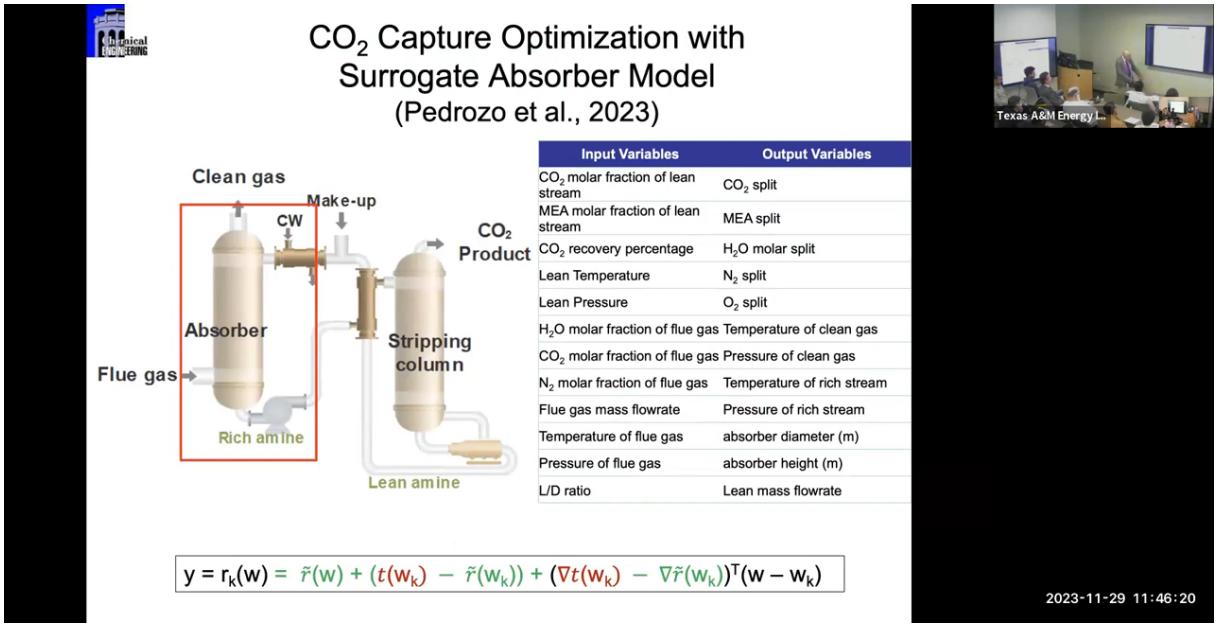

图 11: CO_2 捕集吸收塔的代理模型优化[11]

Biegler 展示了 CO_2 捕集吸收塔的优化案例（Pedrozo et al., 2023）：
优化变量：溶剂摩尔分数、CO_2 回收百分比、贫液温度、蒸汽比等
Truth Model：完整的传质-热力学模型
代理模型：简化的吸收塔模型

$$y = g_r(w) = f(w_k) + \nabla F(w_k)^T(w - w_k) + \dots$$

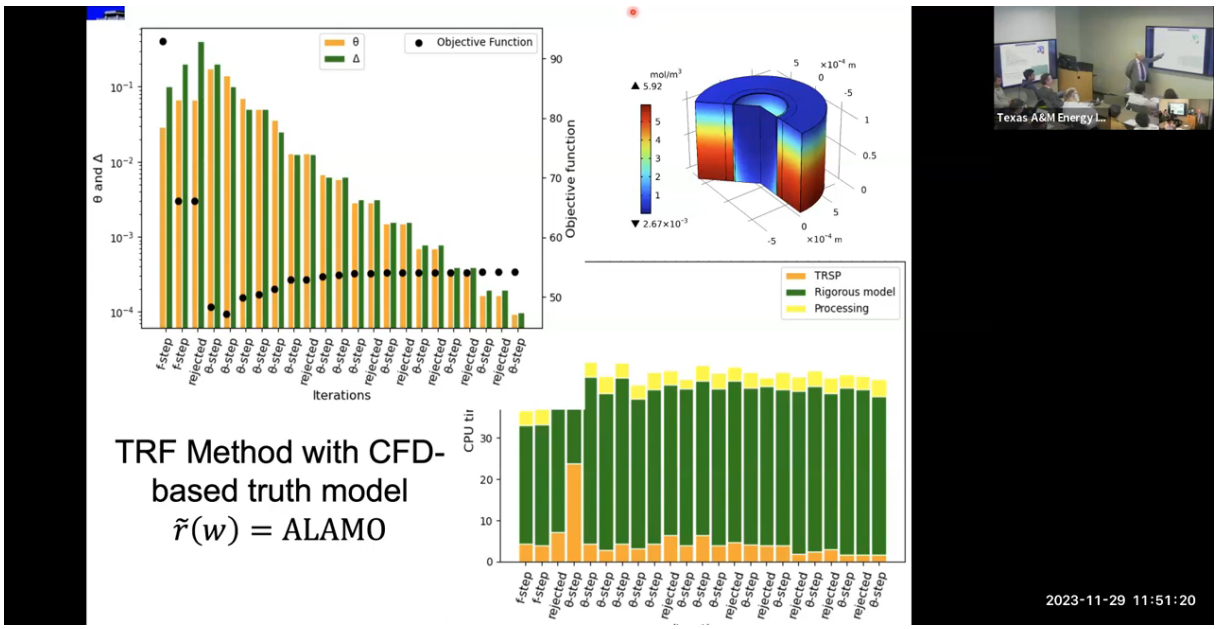

图 12: TRF 方法与 CFD Truth Model 的收敛表现：$F(w) = \text{ALAMO}$[12]

[11] 视频画面时间区间：00:37:00–00:37:45。

ALAMO：自动学习代数模型

ALAMO（Automated Learning of Algebraic Models for Optimization）是一种自动构建代理模型的工具。它从数据中学习简洁的代数表达式，比神经网络更可解释，且更适合嵌入优化问题。TRF + ALAMO 的组合在 CO_2 捕集和 CFD 优化中表现出色。

4.4 本章小结

当 Truth Model 太贵时，用代理模型替代——但通过 Trust Region Filter 保证最终收敛到 Truth Model 的最优解。TRF 的校准 + 一阶校正确保了代理模型在迭代点附近的局部精度。CO_2 捕集案例验证了 TRF + ALAMO 的实用性。

5 总结与延伸

5.1 讲者的核心信息

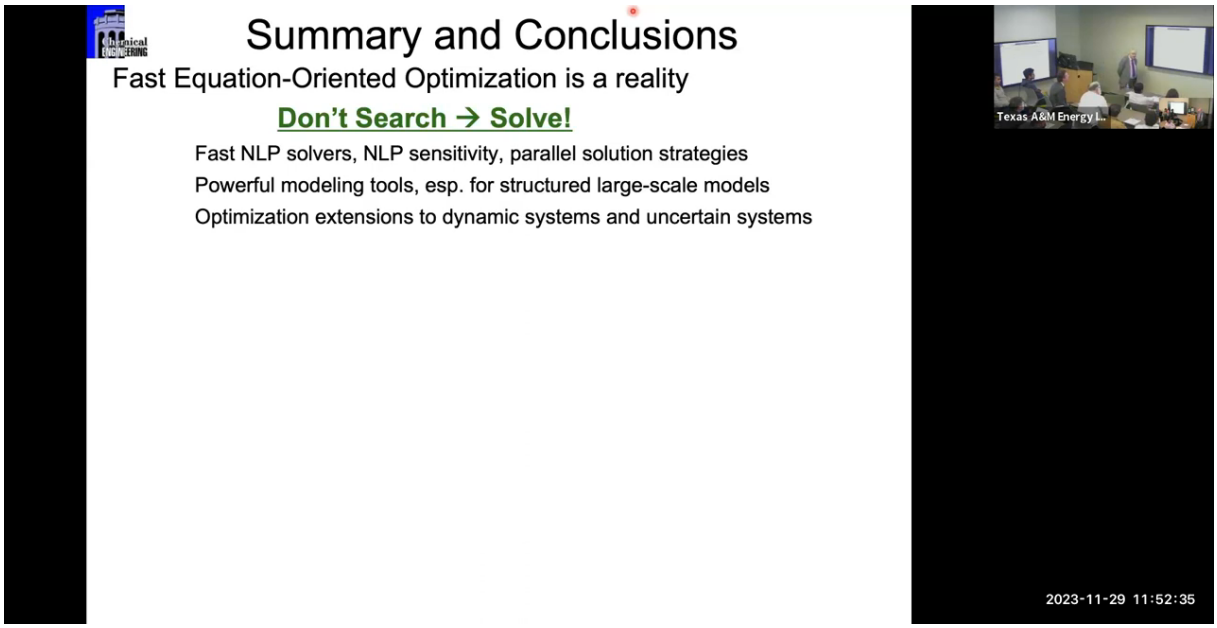

图 13: 总结幻灯片[13]

Biegler 总结了三个层次的优化策略：

1. **Fast EO-based Optimization**：不要搜索，求解 KKT 条件。Newton-based 求解器（IPOPT）+ 结构化大规模模型
2. **Real-time Dynamic Optimization**：NMPC + 灵敏度加速，用第一性原理模型实现实时控制
3. **Decomposition for Structured NLPs**：Nested Schur 分解利用多周期问题的块对角结构，并行求解

[12] 视频画面时间区间：00:42:00–00:42:30。
[13] 视频画面时间区间：00:43:30–00:44:00。

4. **Surrogate-based Optimization**：TRF 算法 + AI/代理模型，保证收敛到 Truth Model 最优解

5.2 结构化提炼

四个核心 Takeaway

1. **Don't Search, Solve!**——用 Newton 方法直接求解 KKT 最优性条件，比搜索类算法快几个数量级。这是一切高级优化方法的基础。
2. **灵敏度是万能钥匙**——从 NMPC 的实时加速到 Nested Schur 分解，灵敏度分析将"重新求解"变为"一步修正"，是将离线方法推向在线应用的关键。
3. **结构即效率**——多周期问题的块对角结构、NMPC 的时域结构、代理模型的层次结构——认识到问题的数学结构，就能设计出高效的分解算法。
4. **Trust Region = 安全的近似**——代理模型可以不精确，但 TRF 保证最终收敛到真实最优解。这是"用廉价近似驱动昂贵精确计算"的通用范式。

5.3 跨章节关联

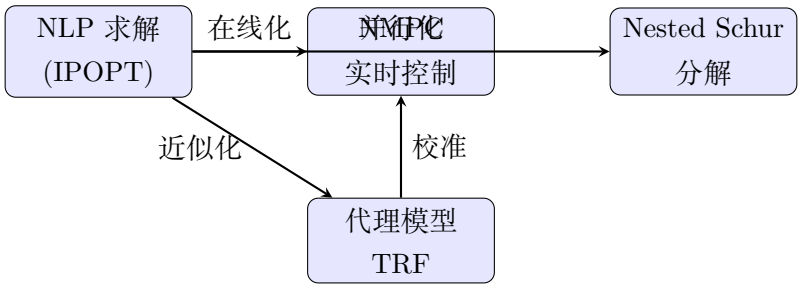

所有方法共享同一个基础：Newton-based NLP 求解。NMPC 是时间维度的展开，Nested Schur 是空间维度的分解，代理模型是精度维度的近似。

5.4 开放问题

1. 当代理模型使用深度神经网络时，TRF 的收敛性是否仍然成立？
2. Nested Schur 分解能否与 GPU 并行计算结合？
3. AI Agent 能否自动选择合适的代理模型精度和 Trust Region 参数？
4. 在碳中和场景下，多能源系统的多周期优化规模能到多大？

5.5 拓展阅读

- Biegler, L.T. *Nonlinear Programming: Concepts, Algorithms, and Applications to Chemical Processes*. SIAM, 2010.
- Wächter, A. and Biegler, L.T. "On the implementation of an interior-point filter line-search algorithm for large-scale nonlinear programming." *Mathematical Programming*, 106(1):25–57, 2006.（IPOPT 论文）

- ALAMO: `https://idaes.org/`